Cloudra：面向自主反应机理探索的几何推理与科学有效性检验

杨程驿 [1,*]、Qianxin Zhou [2,†]、李洋 [1,†]

[1] 长沙理工大学化学与医药工程学院，长沙 410114，中国
[2] 福州大学化学学院，能源与环境光催化国家重点实验室，福州 350002，中国
[*] 通讯作者：杨程驿（Chengyi Yang）。电子邮箱：202509240114@csust.edu.cn。
[†]Qianxin Zhou 与李洋为共同第二作者。

工作审阅稿 — 2026 年 10 月 31 日

摘要

自主反应机理探索需要提出反应步骤、准备三维结构，并确定计算所得鞍点连接哪些反应物和产物。大语言模型（LLM）智能体可能误判空间关系，也可能把计算得到的结构误认为原先想研究的物种或步骤。

本文提出 Cloudra，一个通过 Delivery DAG 约束智能体机理交付的多智能体框架。该图以化学对象表示机理：物种节点承载分子几何与成键拓扑，基元步骤的边承载过渡态及其连接的物种。化学信息学算法确定分子身份和原子对应关系；按照“智能克制”的原则，确定性算法测量和变换这些结构，构造候选几何。频率和 IRC 计算确定所得驻点的性质及其连接物种。智能体据此检验候选步骤、比较竞争路径并修订机理。

CloudraBench 用于衡量这套框架的端到端机理计算能力，包含 50 题，覆盖基元反应、多步机理、立体化学竞争及计算方法局限。四种工作流配置共完成 200 次运行，Cloudra 的平均综合得分为 0.793，同一模型的 Standard 基线为 0.581。在 Hard 任务中，平均得分由 0.689 提高至 0.958。40 道非 Impossible 任务中，Cloudra 的自洽性评分分量在 24 题达到满分，Standard 为 7 题。行为分析进一步考察智能体如何利用键长和二面角测量、优化结构及 IRC 端点修订局部机理判断。

1 引言

1.1 自主反应机理研究的物理要求

有机反应机理的科学有效性检验，需要核对每个物种和基元步骤所对应的分子几何、反应路径与量子化学结果。几何优化正常终止（exit 0）说明计算程序已完成运行。判断所得结构是否为稳定中间体，还需通过频率计算确认极小值；为一阶鞍点指定反应步骤，则需通过 IRC 确定两侧连接的物种。IRC 若到达另一个解离产物或立体异构体，相应能量计算的机理归属也随之改变。包含多个基元步骤或竞争立体路径的研究，需要逐一确定每个鞍点连接的物种。[1, 2]

计算化学智能体已能自动执行其中的若干环节。El Agente Q [3]、Aitomia [4] 与 Gráfico [5] 编排量子化学计算及类型化工作流；Estructural [6] 与 ARCHE [7] 提供分子片段编辑、原子映射及过渡态几何准备工具；Quntur [8] 研究反应动力学与过渡态。将这些能力推进到自主机理探索，还需要可靠的几何操作，以及对计算所得物种和路径的物理解释。

立体取向对齐、反应片段装配与路径端点准备都涉及三维几何关系。语言模型在直接推断这些关系或操作笛卡尔坐标时可能出错。例如，Quntur [8] 报告复杂路径与过渡态准备需要人工协助端点对齐。模型可让程序绕指定化学键旋转一侧原子，再测量相关二面角，据此比较和选择过渡态初猜。

候选中间体必须优化为极小值；候选过渡态必须是一阶鞍点，且其路径连接目标反应物和产物。若 IRC 通向另一产物或立体异构体，该鞍点应归入其实际连接的反应。自主探索系统需要据此重新判断步骤归属，或继续寻找目标鞍点。

1.2 Cloudra：以化学对象组织自主机理探索

以工具调用或计算任务为节点、执行依赖为边的工作流图，规定计算如何组织。Cloudra 是面向有机小分子机理探索的多智能体系统，要求智能体用 Delivery DAG 中的物种对象和基元反应步对象表达交付机理。智能体根据当前的结构和能量提出假设，选择要探索的步骤和下一项计算。

图 1展示 85 个化学 AI Agent 系统的结构化文献样本：材料或表面 39 项，有限分子或配合物 23 项，软物质或生物分子 12 项，另有 11 项展示多个对象类别。图 2和图 3展示有限分子或配合物类已记录的任务，并对比

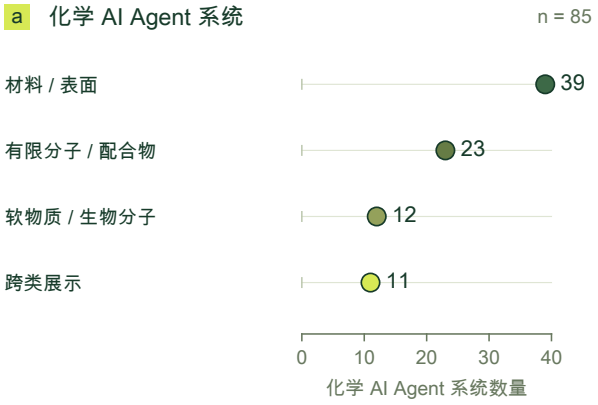


图 1. 85 个化学 AI Agent 系统的结构化文献样本：材料/表面 39 项、有限分子/配合物 23 项、软物质/生物分子 12 项、跨类系统 11 项。

Cloudra 与已有系统的能力覆盖。配套文献材料保留完整矩阵及逐项来源。

按照“智能克制”的原则，Cloudra 将坐标计算交给确定性程序。MCS 匹配用于选择分子片段，原子映射用于匹配反应物与产物中的原子，并标出成键或断键的原子对。程序测量键长、键角、二面角与立体特征，并通过旋转或平移选定原子来构造候选结构。

Delivery DAG 将机理表示为化学对象组成的图。每个物种节点承载分子几何、成键拓扑、立体构型及相应计算结果；每条基元反应步的边承载过渡态和连接相邻物种的反应路径。分子拓扑与立体化学比较确定物种身份，原子映射确定反应物与产物中的原子对应关系。频率计算判定驻点性质，IRC 端点计算确定其反应连接。程序检查频率计算和双向 IRC 是否对应同一一阶鞍点，以及两侧末帧优化后是否得到声明的反应物和产物。Supervisor 对照题目审阅这些对象，并指出还需完成的计算和还需研究的步骤。

1.3 主要贡献

Cloudra 的核心设计是将交付机理的图约束，与建立和操作化学对象的化学信息学算法结合起来。分子拓扑与立体构型标识物种，原子映射确定结构间的原子对应关系；几何操作构造候选结构，频率和 IRC 计算确定所得驻点及其反应连接。智能体围绕这些对象扩展和

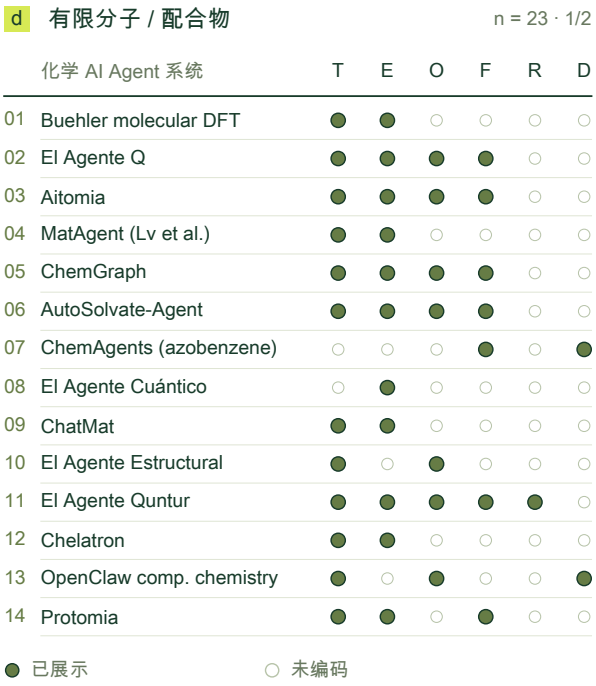


图 2. 有限分子/配合物类已记录的任务（第 1/2 面板，共 23 个化学 AI Agent 系统）。T：结构构建/编辑；E：静态能量/性质；O：几何优化；F：振动/热化学；R：显式路径/过渡态；D：分子/量子动力学。实心表示文献提供正面证据，空白项的能力覆盖保留为未知。

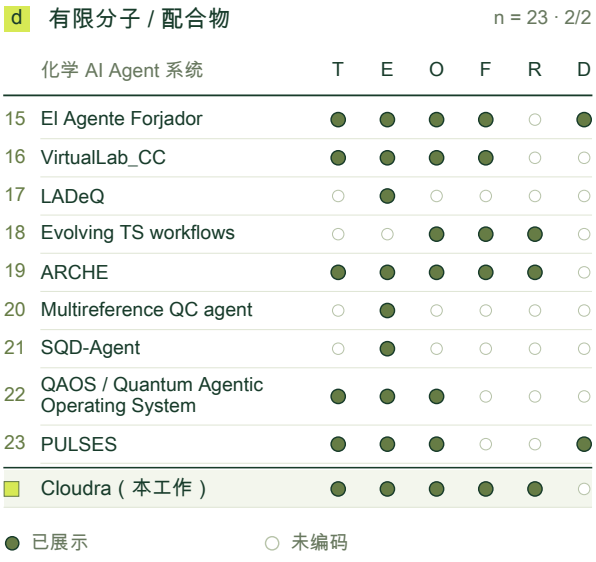


图 3. 有限分子/配合物类化学 AI Agent 系统任务续图（第 2/2 面板），代码同图 2，底端展示 Cloudra（本工作）的能力覆盖。全部 85 个化学 AI Agent 系统的完整矩阵及逐项来源限制见配套材料。

修订机理。

几何程序包括基于 MCS 的片段选择、用于确定移动原子组的图遍历，以及过渡态片段装配。智能体可旋转选定基团、调整片段位置、测量所得结构，并在过渡态搜索失败后准备新的初猜。

CloudraBench 用于衡量这套方法的端到端机理计算能力，依据原生计算产物评价图结构覆盖、物理自洽性和任务规定目标的准确度。50 题涵盖基元与多步反应、立体化学及允许方法的适用边界。实验包括四题三次重复的 48 次运行，以及覆盖 50 题、四种配置的 200 次全基准运行。主要比较采用同一模型主干的 Standard，Record 与 Brief-errors 分析证据组织和诊断反馈的作用。

2 系统设计与方法

2.1 系统全貌与职责划分

Cloudra 根据规定的反应条件与计算要求，通过构造候选分子构型、寻找和表征驻点、追踪基元反应路径及比较竞争通道研究反应机理。工作流图按照执行依赖组织工具调用与计算任务。Cloudra 的 Delivery DAG 表达所交付的反应机理：节点是物种在反应序列中的一次出现，边是基元反应步骤。智能体须在该化学图中表达候选物种及其反应连接，再根据机理假设和返回的计算结果选择后续几何操作、计算与探索分支。

规范拓扑和立体构型比较用于判断结构所表示的物种，原子映射确定反应物与产物构型中哪些原子相互对应。几何算子旋转、平移和组装分子片段。频率计算判断驻点曲率；IRC 及其后的端点优化和频率分析确定鞍点连接哪些物种。

协调智能体提出机理假设和候选基元反应步，并选择要探索的分支。计算智能体调用几何算子构造三维结构，提交所分配反应步的量子化学计算。若出现几何发散、鞍点优化收敛失败或路径分叉，计算智能体检查结构和计算诊断，判断是否继续该步骤。若认为该步骤受阻，则向协调智能体说明诊断结果，由其修改假设或探索另一分支。督导智能体对照任务要求审阅 DAG 中的物种、反应步和计算结果；审阅意见与计算输出中解析出的事实分别保存。

2.1.1 异步计算调度与资源管理

中央计算账本（`ComputeDB`）记录每个作业的状态。独立容量池分别限制本地工作进程、远程 SSH 集群和 Slurm 队列中的并发计算数。提交前，调度器根据 Cartesian 坐标、自旋、电荷及理论级别计算 SHA-256 摘要；若有相同的在运行作业或缓存结果，则直接复用，避免重复提交。操作系统的文件排他锁（`flock`）用于跟踪运行进程和并发数；监控异常期间，持有锁的量子化学进程继续运行。计算结束后，调度器通知计算智能体，由通知触发异步读取输出。

2.2 分子表征与几何算子

分子输入包括属性图 $H = (A, B)$ 和 Cartesian 坐标矩阵 $\mathbf{X} \in \mathbb{R}^{n\times 3}$。其中 A 为原子集合，B 为化学键集合，$\mathbf{X}$ 的每一行给出一个原子的坐标。图中记录原子与化学键属性。几何算子修改坐标并返回所得结构的测量值；替换原子或官能团时也修改 H。

2.2.1 原子对应关系与反应中心感知

原子属性显式保留元素种类、同位素标号、形式电荷、显式氢数、自由基电子数以及声明的手性立体构型；化学键属性保留键级与顺反立体构型。已有坐标予以保留，其余分子组分由 ETKDGv3 算法生成初始三维构象 [9–11]，多组分体系分别构建后执行空间对接。两端均

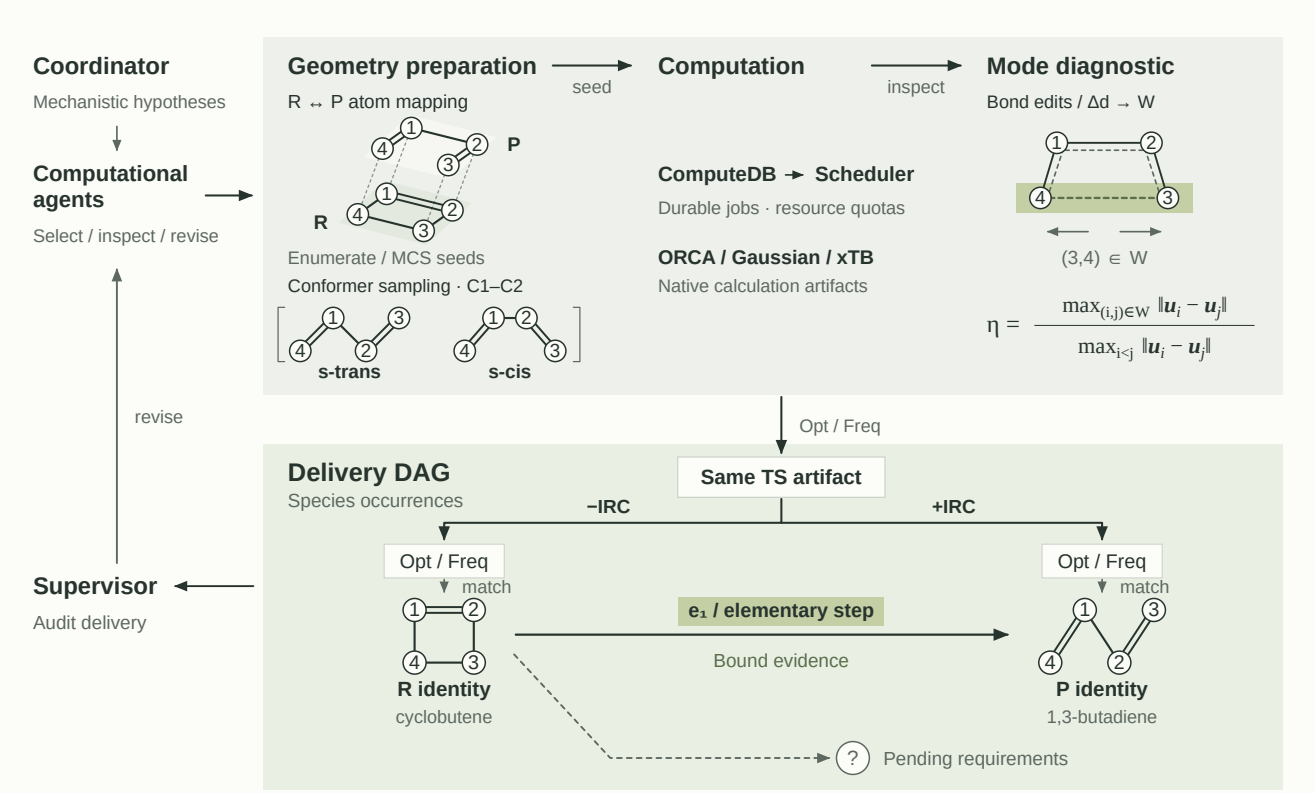


图 4. Cloudra 的机理探索流程。原子映射与构象采样用于准备反应物和产物结构，ComputeDB 与调度器管理计算。振动模式诊断测量监控原子对的运动。双向 IRC 从同一过渡态出发，两侧外帧分别用于端点优化和频率分析，再将所得结构与交付 DAG 中声明的物种比较。督导智能体审阅该图，列出待完成的计算和待确定的结构与路径归属。

具有完整且唯一的原子映射标号时，直接依据标号配对原子，要求两端元素与同位素相同。其余情况下，设产物与反应物的重原子集合分别为 A_{P} 与 A_{R}，搜索保持元素与同位素守恒的双射 $\pi : A_{\mathrm{P}} \to A_{\mathrm{R}}$，满足 $z_i^{\mathrm{P}} = z_{\pi(i)}^{\mathrm{R}}$ 且 $\iota_i^{\mathrm{P}} = \iota_{\pi(i)}^{\mathrm{R}}$，并按下式打分：

$$J(\pi) = 2(N_{\mathrm{f}} + N_{\mathrm{b}}) + N_{\mathrm{o}} + 4\Delta_H + 8\Delta_q + 8\Delta_r + 2N_{\mathrm{s}}. \tag{2.1}$$

令 B_{P}^{π} 表示以反应物原子编号表示的产物化学键集合。成键与断键分别是集合差 $B_{\mathrm{P}}^{\pi} \setminus B_{\mathrm{R}}$ 与 $B_{\mathrm{R}} \setminus B_{\mathrm{P}}^{\pi}$，对应基数分别为 N_{f} 与 N_{b}。N_{o} 统计 $B_{\mathrm{P}}^{\pi} \cap B_{\mathrm{R}}$ 中键级改变的键对数。对于 $a \in \{H, q, r\}$，环境差量定义为 $\Delta_a = \sum_{i \in A_{\mathrm{P}}} |a_i^{\mathrm{P}} - a_{\pi(i)}^{\mathrm{R}}|$，分别度量原子显式氢数、形式电荷与未配对电子数的变化。N_{s} 统计立体化学环境的差异数：仅一端声明四面体标签时增加惩罚 2；当两端对应原子均声明立体标签时，算法要求其具备四个匹配邻居（含必要氢原子），并在比较标签前校正邻居排序的置换奇偶性；两端标签的差异仅在四个邻居可匹配时计分。

对于各元素同位素等价类（大小记为 n_g），全排列空间大小为 $N_{\Pi} = \prod_g n_g!$。当 $N_{\Pi} \le 10^5$ 时，算法遍历全部双射；超过该阈值时，以最大公共子图（MCS）作为种子扩展映射，要求元素严格匹配、放开键级限制并强制保留完整环结构 [11]。MCS 搜索超时时间为 10 秒，每个端点最多贡献 64 个子图匹配。剩余原子按氢数、连接度及输入序号在同类原子中排序配对。算法合并成断键、键级变化及得分相同的映射，保留字典序最小的代表；候选按得分与映射序列升序排序，前 16 个代表构成重原子候选集 C。当 C 包含候选映射时，定义最优得分 $J_{\min} = \min_{\pi \in C} J(\pi)$ 以及容差集合 $\mathcal{N} = \{\pi \in C : J(\pi) \le J_{\min} + 2\}$。当 $|\mathcal{N}| = 1$ 时报告映射唯一；$|\mathcal{N}| > 1$ 时报告存在歧义；$C = \emptyset$ 时将映射结果标记为待定。

每个保留的重原子候选映射按与两端图相容的原子匹配扩展至全原子。系统优先保留相容的显式氢标号，再按同位素配对各对应重原子上的剩余氢原子。剩余氢原子组（大小为 h_g）的置换空间 $N_H = \prod_g h_g!$ 在 $N_H < 257$ 时执行完全枚举；超出该范围时，需要相容的显式氢标签来确定配对；仍有配对歧义时，将结果标记为待定。全原子映射经过去重、排序，并依据相同的 +2 容差规则评估歧义性。选定的全原子双射将产物原子排成反应物的原子顺序。成键与断键原子对用于监控后续路径插值；键级变化随变换后的拓扑图一同记录。

2.2.2 结构测量与刚体变换算子

系统根据坐标计算键长、键角、二面角、环构象和近距离接触。对于坐标 $\mathbf{x}_i$，原子间距为 $d_{ij} = \|\mathbf{x}_j - \mathbf{x}_i\|$；以原子 j 为顶点的键角由两条成键单位向量的内积反余弦求得。将原子间距与参考键长和范德华接触距离比较，标记几何异常。纯坐标输入在进入系统时确定成键拓扑；局部坐标变换保留该键图，并在移动原子前后重复测量。

对于非环单键两侧的分子片段选择，系统通过图连通性自动解析：临时切断指定键 $a - b$，选取包含原子 b 的连通子图 $\mathcal{F}_b$。若切除该键后两端依然连通（处于环体系内部），则要求显式传入移动原子列表。记移动原子集合为 $\mathcal{F}$（由显式指定或切键提取的 $\mathcal{F}_b$ 构成）。将移动片段绕指定空间轴旋转时，对集合内所有原子 $i \in \mathcal{F}$ 应用 Rodrigues 旋转公式：

$$\begin{aligned} \mathbf{x}_i' &= \mathbf{a} + \mathbf{R}(\hat{\mathbf{u}}, \theta)(\mathbf{x}_i - \mathbf{a}), \\ \mathbf{R} &= \cos\theta\, \mathbf{I} + (1 - \cos\theta)\hat{\mathbf{u}}\hat{\mathbf{u}}^{\mathsf{T}} \\ &\quad + \sin\theta\, [\hat{\mathbf{u}}]_{\times}. \end{aligned} \tag{2.2}$$

式中 $\mathbf{a}$ 为旋转轴上基准点，$\hat{\mathbf{u}}$ 为轴的单位方向向量，θ 为旋转角度，$\mathbf{I}$ 为三阶单位矩阵，$[\hat{\mathbf{u}}]_\times \mathbf{v} = \hat{\mathbf{u}} \times \mathbf{v}$ 为反对称叉乘算子。移动片段之外的原子坐标固定。沿指定键 $a-b$ 伸缩距离时，将片段 $\mathcal{F}_b$ 整体平移：

$$\mathbf{x}_i' = \mathbf{x}_i + (L - d_{ab})\frac{\mathbf{x}_b - \mathbf{x}_a}{d_{ab}}, \qquad i \in \mathcal{F}_b. \tag{2.3}$$

式中 L 为目标键长，$\mathcal{F}_b$ 之外的原子坐标固定。手性反转通过绕立体中心旋转两个可分离分支，交换两个分支的方向。基团取代先移除指定侧片段，再沿原连接键的方向放置新基团，并更新拓扑图。比较量子化学优化前后的结构时，系统保持相同元素顺序，分别按距离判断成键，再比较新增或消失的连接属于片段内部还是片段之间。

2.2.3 分支拥挤描述符与反应物预组织

检查杂化状态、环结构和取代基拓扑不等价性后，系统根据各取代基分支中的原子计算候选旋转轴周围的拥挤程度：

$$B_s = \sum_{k \in T_s} c_k r_k \rho^{\ell_k}, \qquad \rho = 0.5, \quad 0 \le \ell_k \le 5. \tag{2.4}$$

式中 r_k 为原子 k 的范德华半径。遍历树 T_s 通过后进先出（LIFO）深度优先遍历生成，以取代基根原子为深度 0 起点，并将旋转轴另一端原子预先标记为已访问。弹出待访问原子时记录其搜索深度 ℓ_k，并在 $\ell_k < 5$ 时将其待访问邻居按拓扑顺序压栈。权重系数 c_k 在根原子图连接度大于等于 3 时取 1.5，其余原子取 1.0。

该描述符采用标准范德华半径标度（Å）：H 1.20, B 1.92, C 1.70, N 1.55, O 1.52, F 1.47, P 1.80, S 1.80, Cl 1.75, Br 1.85, I 1.98（其余元素统一采用 1.70）。将旋转轴两侧四个取代基分支计算得出的 B_s 值四舍五入保留三位小数并求和，其总和记为 B_{axis}；当 $B_{\text{axis}} \ge 9.0$ 时，该键被标记为拥挤轴，供后续构象探查参考。

在多组分反应物预组织中，主反应组分固定于坐标原点，其余反应物分子绕各自质心在三维空间中进行取向采样。在 K 个采样点下，第 s 个采样方向为：

$$\begin{aligned} \hat{\mathbf{u}}_s &= (a_s \cos s\gamma,\ y_s,\ a_s \sin s\gamma), \\ a_s &= \sqrt{1 - y_s^2}, \qquad y_s = 1 - \frac{2s}{K-1}, \\ \gamma &= \pi(3 - \sqrt{5}). \end{aligned} \tag{2.5}$$

其中参数 $\gamma = \pi(3-\sqrt{5}) \approx 2.3999$ rad（约为 137.5°）为黄金角，对应斐波那契球面螺旋分布；绕 $\hat{\mathbf{u}}_s$ 轴的自旋角取 $2\pi s/K$（默认采样 $K = 32$）。沿组分质心向量平移以消除原子重叠冲突。对于显式指定的引导原子对集合 W 及其目标距离窗口 $[l_{ij}, u_{ij}]$，构型 $\mathbf{X}$ 的违背惩罚评分为：

$$\begin{aligned} S(\mathbf{X}) = \max_{(i,j)\in W} \{0,\ & l_{ij} - d_{ij}(\mathbf{X}), \\ & d_{ij}(\mathbf{X}) - u_{ij}\}. \end{aligned} \tag{2.6}$$

低惩罚构型进行带谐性距离约束的 MMFF94 力场优化 [12]，使指定原子对的距离进入目标窗口，同时松弛非键接触。只保留力场优化收敛、距离落入窗口、立体构型得到保留且片段接触满足 $d_{i^*j^*} \le 1.7(r_{i^*} + r_{j^*})$ 的构型。随后按无约束力场单点能排序，并采用 0.5 Å 的重原子 Kabsch RMSD 阈值聚类去重，得到后续计算的初始构型。

2.2.4 端点刚体对齐与 IDPP 路径插值

将产物原子排成反应物的原子顺序后，两端构型分别中心化。令 $\mathbf{P}$ 与 $\mathbf{R}$ 为中心化后的产物与反应物坐标矩阵，Kabsch 最小二乘刚体旋转 [13] 求解：

$$\begin{aligned} &\min_{\mathbf{Q}^{\mathsf{T}}\mathbf{Q}=\mathbf{I},\det\mathbf{Q}=1} \|\mathbf{P}\mathbf{Q} - \mathbf{R}\|_{\mathrm{F}}^2, \\ &\mathbf{P}^{\mathsf{T}}\mathbf{R} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^{\mathsf{T}}, \\ &\mathbf{Q} = \mathbf{U}\,\mathrm{diag}\big(1, 1, \det(\mathbf{U}\mathbf{V}^{\mathsf{T}})\big)\mathbf{V}^{\mathsf{T}}. \end{aligned} \tag{2.7}$$

矩阵 $\mathbf{Q}$ 给出两端构型之间的刚体旋转。行列式因子 $\det(\mathbf{U}\mathbf{V}^{\mathsf{T}})$ 使 $\det\mathbf{Q} = +1$，排除镜像反射，保留原有手性构型。

对于包含端点在内的 M 个路径帧，定义进度参数 $\lambda_k = k/(M-1)$，并初始化坐标 $\mathbf{X}_k = (1-\lambda_k)\mathbf{R} + \lambda_k \mathbf{P}\mathbf{Q}$。IDPP 算法 [14] 在两端之间插值各帧的目标原子对距离，并按下式优化坐标：

$$\begin{aligned} d_{ij,k}^{*} &= (1-\lambda_k) d_{ij}^{\mathrm{R}} + \lambda_k d_{ij}^{\mathrm{P}}, \\ V_k &= \sum_{i<j} \frac{(d_{ij,k} - d_{ij,k}^{*})^2}{d_{ij,k}^{4}}. \end{aligned} \tag{2.8}$$

该泛函的分母引入距离负四次方权重 $d_{ij,k}^{-4}$，使短程成键区域具有较高的刚性恢复力，优先保持化学键尺度，同时允许长程非键相互作用松弛。标准模式将中间镜像帧通过改进切线法弹性带（NEB）弹簧耦合，并利用 MDMin 算法执行能量最小化，以移动原子受力的最大残差评估收敛性 [15, 16]；轻量模式则将分母设定为 $\max(d_{ij,k}^{*}, 0.1\,\text{Å})^4$，使用 Adam 优化器对各个中间镜像帧独立进行几何松弛。[17]

动态监控原子对集合 W 自动提取反应映射中的成断键对、两端成键但键长变化 $|\Delta d| \ge 0.15$ Å 的键对，以及两端距离变化最大的前 5 对原子。在集合 W 中，算法选取距离变化最大的主反应坐标 $p^{*} \in \operatorname{argmax}_{p\in W} |d_p^{\mathrm{P}} - d_p^{\mathrm{R}}|$，计算中点距离 $m = (d_{p^*}^{\mathrm{R}} + d_{p^*}^{\mathrm{P}})/2$。初始过渡态初猜选取首个跨越中点的镜像帧 k（满足 $(d_{p^*,k} - m)(d_{p^*}^{\mathrm{R}} - m) \le 0$），或与中点距离偏差最小的帧。提取出的三维构型直接作为后续一阶鞍点优化的输入种子。

2.3 交付 DAG 中的化学物种与反应步骤

2.3.1 物种节点与基元反应步

交付 DAG 定义为 $G = (V, E)$。每个节点 $v \in V$ 表示物种在反应序列中的一次出现，每条有向边 $e = (v_i, v_j) \in E$ 表示一个基元反应步。映射 $\kappa : V \to \mathcal{S}$ 给出每个节点的规范化学身份。因此，初始催化剂与再生催化剂可使用具有相同化学身份的两个独立节点。

每个物种由分子几何、成键拓扑和立体构型描述，其入边与出边描述它与相邻物种之间的反应连接。系统通过比较规范分子图和立体标签，将结构归于相应物种；原子映射则确定反应物与产物结构中的原子对应关系。物种节点记录驻点几何、振动频率和绝对能量；反应步边记录过渡态几何、虚频位移向量和反应路径。频率与 IRC 计算表征这些驻点和路径，具体物理条件在下文定义。

集合 K 列出每个物种或反应步需要完成的计算阶段。基元反应步默认要求 $K = \{\text{ts_opt}, \text{frequency}, \text{short_irc}\}$ 阶段链，并按任务要求追加热力学校正。计算输出以内容摘要标识，并作为固定记录归档。每项解析结果记为 $f = (c, o, r, d)$：c 为检查项，$o \in \{+, -, ?\}$ 表示支持、矛盾或未定，r 指向该结果的计算输出，d 记录测量值。

对于物种或反应步 t，以 F_t 表示其计算输出中的解

析结果，R 表示必需属性检查，O 表示可选检查。物理检验条件为：

$$\begin{aligned} S_t = \mathbf{1}[R \neq \emptyset] \\ \wedge \bigwedge_{c \in R} \mathbf{1}[\exists f \in F_t : f.c = c,\, f.o = +] \\ \wedge \mathbf{1}[\nexists f \in F_t : f.c \in R \cup O,\, f.o = -]. \end{aligned} \tag{2.9}$$

当 $R \neq \emptyset$ 时，每个必需检查均须有支持结果，且 $R \cup O$ 中各检查当前结果的状态须为支持或未定；当 $R = \emptyset$ 时，只检查所要求的计算阶段。

2.3.2 势能面曲率与简正振动模式对齐诊断

驻点的物理曲率性质由质量加权黑塞矩阵（Hessian）决定：

$$\begin{aligned} \mathbf{H}_{\mathrm{mw}} &= \mathbf{M}^{-1/2} \nabla_{\mathbf{x}}^2 U\, \mathbf{M}^{-1/2}, \\ \mathbf{H}_{\mathrm{mw}} \mathbf{v}_k &= \lambda_k \mathbf{v}_k. \end{aligned} \tag{2.10}$$

在消除平动与转动自由度的振动子空间内，负本征值 $\lambda_k < 0$ 对应虚频 $\nu_k < 0$。虚频总数统计为 $n_{\mathrm{imag}} = \sum_k \mathbf{1}[\nu_k < 0]$。基态反应中间体要求 $n_{\mathrm{imag}} = 0$；一阶鞍点要求 $n_{\mathrm{imag}} = 1$。

系统比较频率计算所用的几何与驻点优化得到的几何。对于中心化后的坐标矩阵 $\mathbf{X}$ 与 $\mathbf{Y}$，几何匹配要求满足 $\delta_\pi(\mathbf{X}, \mathbf{Y}) = \max_i \|\mathbf{Y}_{\pi(i)} \mathbf{Q}_\pi - \mathbf{X}_i\| \leq 3 \times 10^{-6}$ Å，在保持元素种类的原子置换 π 与最佳 Kabsch 旋转 $\mathbf{Q}_\pi$ 下进行比较。

对于满足一阶鞍点且具有唯一虚频位移向量 $\mathbf{u}$ 的过渡态，振动模式对齐诊断比较监控反应中心原子对 W 中最大的相对位移幅度与所有原子对中的最大值：

$$\eta = \frac{\max_{(i,j) \in W} \|\mathbf{u}_i - \mathbf{u}_j\|}{\max_{i<j} \|\mathbf{u}_i - \mathbf{u}_j\|}. \tag{2.11}$$

诊断量 $\eta \in [0, 1]$ 衡量反应中心原子对相对全局最大原子对位移的参与程度，比较比值为 0.5，可提示甲基摇摆或溶剂运动等旁观模式。对齐标记只提供诊断建议；科学检验依据一阶鞍点要求及同一 TS 的双向 IRC 和端点优化/频率证据链。

2.3.3 内禀反应坐标（IRC）方向与端点一致性

内禀反应坐标（IRC）是在质量加权坐标 $\mathbf{q} = \mathbf{M}^{1/2}\mathbf{x}$ 下从过渡态出发的最陡下降路径 [1, 2]：

$$\begin{aligned} \frac{\mathrm{d}\mathbf{q}_\pm}{\mathrm{d}s} &= -\frac{\nabla_{\mathbf{q}} U}{\|\nabla_{\mathbf{q}} U\|}, \\ \mathbf{q}_{\mathrm{init},\pm} &\approx \mathbf{q}_{\mathrm{TS}} \pm \epsilon \mathbf{v}_-. \end{aligned} \tag{2.12}$$

Cloudra 检查两个 IRC 方向是否从已确认的同一鞍点出发，并提取各方向的末端帧。对于两端均为分子极小值的路径，以每侧末端帧启动无约束几何优化。所得驻点必须为零虚频（$n_{\mathrm{imag}} = 0$），其规范异构 SMILES 必须与声明的反应物或产物相同，包括拓扑和立体构型。

对于产物发生解离的多组分反应步，各产物分子分别独立优化至零虚频极小值。在监控原子对集合 W 上，设过渡态、IRC 外侧末端帧及反应物参考构型的距离向量分别为 $\mathbf{q}_{\mathrm{TS}}$、$\mathbf{q}_{\mathrm{E}}$ 与 $\mathbf{q}_{\mathrm{R}}$。取共价截断半径 $c_{ij} = 1.25(r_i + r_j)$ 及容差 $\tau = 0.10$ Å，定义共价集合 $W_{\mathrm{c}} = \{(i,j) \in W : d_{ij}^{\mathrm{R}} \leq c_{ij}\}$ 以及边界区间 $[a_p, b_p] = [\min(d_p^{\mathrm{TS}}, d_p^{\mathrm{R}}) - \tau, \max(d_p^{\mathrm{TS}}, d_p^{\mathrm{R}}) + \tau]$。布尔断言 is_between 要求满足 $\|\mathbf{q}_{\mathrm{E}} - \mathbf{q}_{\mathrm{R}}\|_2 < \|\mathbf{q}_{\mathrm{TS}} - \mathbf{q}_{\mathrm{R}}\|_2$ 且 $a_p \leq d_p^{\mathrm{E}} \leq b_p$ 对所有 $p \in W_{\mathrm{c}}$ 均成立。解离型产物通道需同时满足上述极小值条件和 is_between 判定。

2.3.4 证据汇总与定量能垒

对于基元反应步 e，K_e 列出所要求的计算阶段。当阶段 k 所用的计算结果满足其物理条件时，令 $P_{e,k} = 1$，否则为 $P_{e,k} = 0$。所有必需阶段均须通过：

$$A_e = \bigwedge_{k \in K_e} P_{e,k}. \tag{2.13}$$

当任务显式声明属性检查集合 R 时，反应步还需满足 $A_e \wedge S_e$。各阶段分别记录为支持、待决、跳过或拒绝；方法限制或有记录的豁免与已完成计算分别记录。

电子活化能垒由驻点能量差计算：

$$\Delta E_e^{\ddagger} = E_{\mathrm{TS},e} - E_{\mathrm{ref},e}. \tag{2.14}$$

所用能量来源于相同的量子化学方法与基组级别。对于热力学性质，零点能校正、焓变与 Gibbs 自由能校正在指定温度与压强下基于谐性配分函数提取。

2.4 计算诊断与重试

系统区分执行错误、数值不收敛和物理证据问题。执行错误包括输入语法错误、环境故障和解析失败；数值检查记录 SCF 与几何优化是否收敛；物理证据问题包括 $n_{\mathrm{imag}} \neq 1$ 的鞍点、等待验证的 IRC 端点，以及对应其他物种的分子图。虚频模式参与程度和几何区间测量提示应检查哪些原子运动或距离。

设 T 包含任务要求研究的物种与基元反应步。将 $P_{e,k}$ 推广至各 $t \in T$，待解决的计算阶段要求为：

$$U = \{(t,k) : t \in T,\, k \in K_t,\, P_{t,k} = 0\}. \tag{2.15}$$

对于每个 $(t,k) \in U$，诊断反馈指出涉及的物种或反应步，以及 SCF 不收敛、振动模式失配、IRC 与端点计算缺少衔接，或分子图不符等具体问题。计算失败后，系统保留输出、更新 U，并将几何与收敛信息返回智能体。

依赖失败阶段的计算重新排队，先前尝试及原始输出予以保留。系统重排原子编号，将各项计算结果记录到相应物种或反应步，并更新图中状态。模型为下一次尝试修改化学约束、二面角或电子结构方法。

2.5 实施默认参数

本文描述的系统实现基于 Cloudra 提交版本 70daa5a。[18] 数值数组与线性代数运算使用 NumPy[19]；量子化学数值提取由 cclib 与各引擎的原生日志读取逻辑共同完成 [20]；Benchmark 图表示与匹配使用 NetworkX[21]。反应物预组织中多组分球面采样取 32 个刚体旋转方向，保留至多 8 个引导对接构型，组分间最小初始间距 1.0 Å，分子接触截断乘子 1.7，重原子 RMSD 聚类阈值 0.5 Å。MMFF94 距离约束力场松弛每阶段上限 2000 步，距离谐振子力常数设为 100.0。路径插值中标准 IDPP 默认采用 10 个图像帧，使用 MDMin 算法松弛（上限 100 步，受力容差 $f_{\max} = 0.1$，NEB 弹簧系数 $k = 0.1$）；轻量 IDPP 采用 Adam 优化器（上限 4000 步，步长 0.02，梯度容差 10^{-7}）。路径收敛性由中间镜像帧的最大受力残差判定。

原子映射系数及 $J_{\min} + 2$ 歧义窗口是固定的候选排序启发式。电荷与自由基不匹配的代价高于氢数和键编辑不匹配。支链拥挤度使用衰减 $\rho = 0.5$、遍历至深度五和 $B_{\mathrm{axis}} \geq 9.0$ 标记；模式参与诊断的比较比值为 0.5，仅作诊断提示。

Cloudra 的构象搜索工具提供 RDKit 和外部 CREST 后端。[24] 上述默认预组织使用刚体放置、受限

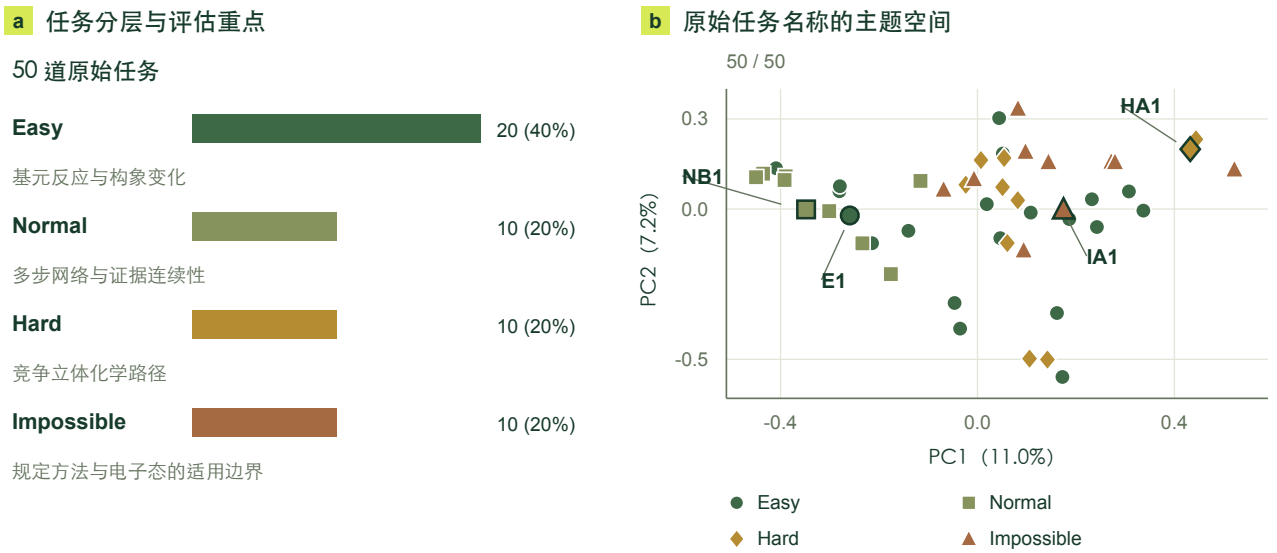


图 5. CloudraBench 的任务组成与研究主题。a，四档任务的数量及评估重点。b，50 道原始任务名称的 BAAI/bge-m3 嵌入 [22] 使用 scikit-learn[23] 进行主成分分析得到的二维投影，E1、NB1、HA1 和 IA1 为重复实验采用的四题。颜色和点形表示预先规定的任务类别。

MMFF94 松弛及聚类；需要时可请求 CREST 进一步搜索构象或非共价复合物，再进行量子化学优化与物理检验。

2.6 CloudraBench 基准构建与实验设计

2.6.1 任务覆盖与分层依据

CloudraBench 用 50 题评估端到端机理计算能力：Easy 20 题检验基元转化、构象变化与基础执行可靠性；Normal 10 题检验中间体识别和多步衔接；Hard 10 题检验竞争通道与立体身份；Impossible 10 题检验允许方法下的适用边界与可信否定（图 5）。同类反应可因要求研究的路径、构型或电子态不同而分入不同层级。选题依据文献和参考计算，同时考虑能否区分工作流表现及计算成本。配套清单列出各题名称、输入条件和允许方法。

2.6.2 参考答案与评价口径

每题固定化学条件、电荷、自旋、交付目标和方法范围。Easy、Normal 和 Hard 任务允许 xTB[25]、PM7[26] 与 B3LYP-D3(BJ)/def2-SVP[27–32]，Impossible 任务限于 xTB 与 PM7；计算证据读取 ORCA、Gaussian 或 MOPAC 原生日志。[33–36] 参考答案包含物种、基元步、立体身份及适用的数值或否定目标。数值参考按同一方法下的纯电子能差登记，稳定极小值参照与真实 IRC 连接分别核验。对要求验证的可达反应步，TS 频率、双向 IRC、末帧来源和端点优化/频率构成证据链；物种性质和电子态问题则按其指定目标核验。

图结构、自洽性与准确度分别评价，综合权重为 0.1、0.3 和 0.6；分级物理支持程度与运行期交付完整性分别报告。正确识别方法限制时，以有依据的否定结论作为答案。

各题参考答案的证据完整性、特别处理和保留项单独记录，参考图是否存在与科学验证是否完整分别判断。

2.6.3 重复实验、主对照与工作流消融

重复任务研究（P1b）比较 E1、NB1、HA1 与 IA1 在 Guided、Standard、Record 和 Brief-errors 四配置下的表现，每种题目与配置组合独立运行三次，共 48 次任务运行。重复实验使用 DeepSeek-v4.1-flash（1017）。[37] 四题分别涉及消除预组织、多步脱羧、立体化学开环及电子结构方法边界，其轨迹用于后续局部诊断。耗时单位为并发二、四题一批的实际批次，每配置三批。全基准研究（P2）保留 50 题、四配置各一次运行，共 200 次任务运行。全部 P2 配置均通过 DeepSeek 官方端点的流式 OpenAI 兼容 chat completions 接口调用 DeepSeek-v4.1-flash（1017），归档 API 别名为 `deepseek-v4-flash`，请求 minimal 推理设置；冻结配置与实际请求/完成记录中的模型标识一致。主比较为使用同一主干的 Guided 与 Standard，后者在图中标记为 Backbone。P1b 与 P2 是重复任务及全基准研究沿用的归档标识。P2 执行版本和请求设置见 SI 第 S1 节。

Standard 隐藏显式 DAG 工具、取消物理检验约束并提供中性计算反馈；Guided 保留研究图、科学检查与详细诊断。Record 保留可用工具和记录，物理检验由运行自行选择；Brief-errors 保留引导而缩短诊断。各配置采用相同题目与方法限制，运行版本、预算、结束原因及产物来源保留在档案中。

评分前，将各次运行已有的研究记录转换为统一机理图。人工整理依据 Agent 在对话、工具记录、报告和计算文件中表达的机理意图与结论，还原物种和反应步、恢复文件引用，并记录每个图字段的来源。评分器在同一次运行的沙箱中搜索原生计算证据，应用统一评分规则。整理仅使用该次运行已有的计算和科学结论，Gold 用于提供评价目标。最终数据包含全部 200 次运行，每项综合分均列出对应的 Graph、自洽性和 Accuracy。逐题配对差及 95% 百分位区间采用 100,000 次任务簇 bootstrap，同一任务的四配置始终一起抽样，随机种子为 20261031。计算投入取四配置均有记录的 15 道选定任务，报告量子化学作业数和累计 job-hours，并与先导实验的批次实际耗时分别呈现。

3 结果与讨论

3.1 端到端基准评估

CloudraBench 衡量端到端机理计算能力：构建候选机理、完成所需量子化学计算，并得出符合任务要求的正结论或负结论，其中包括判断允许方法下目标的物理存在性。下文报告最终整理后的综合分及图结构、自洽性与准确度分量。离线整理从每次运行自身的研究材料组装机理图，并关联该运行已有的评分记录，得到

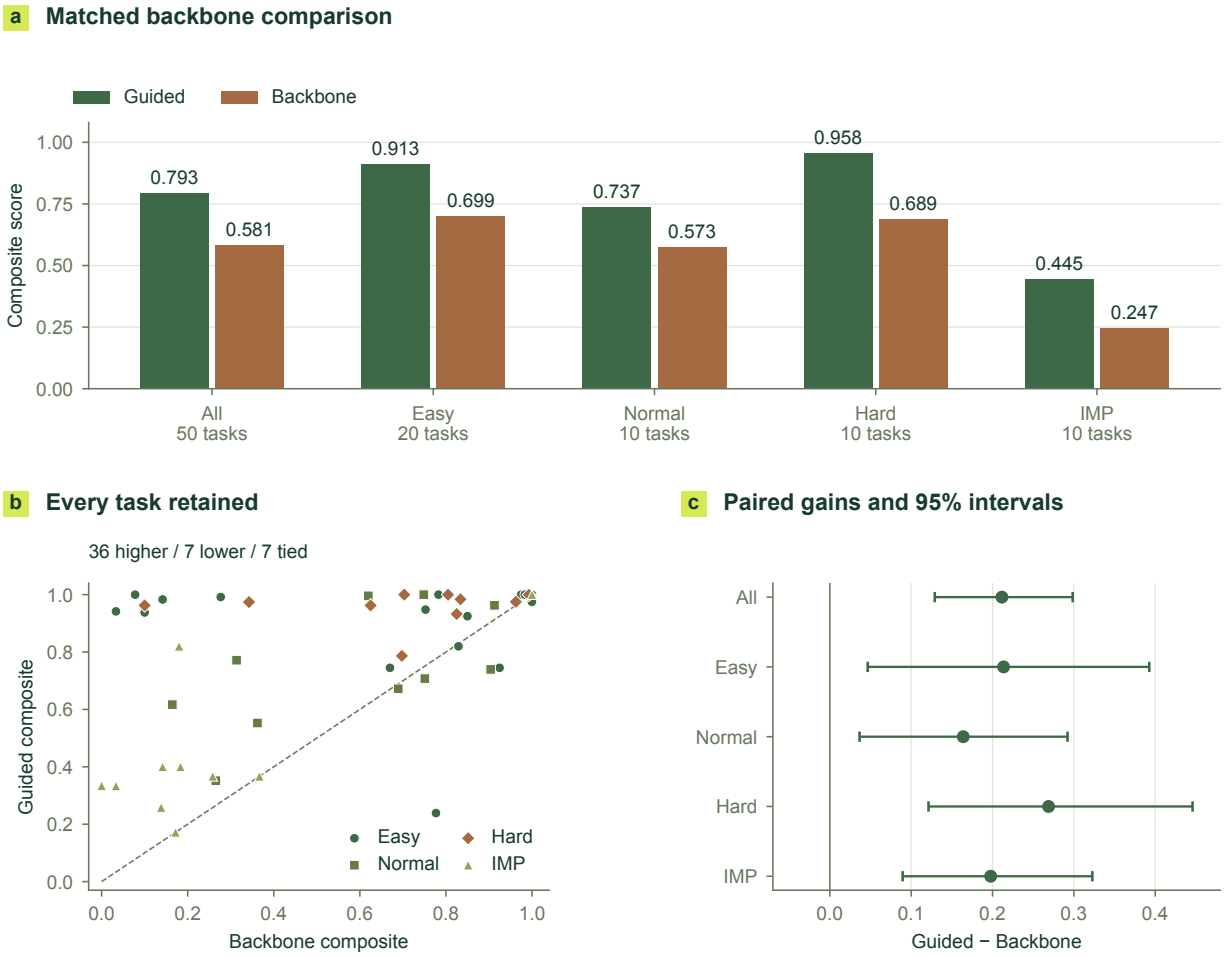


图 6. P2 主比较与逐题差异。a，Cloudra Guided 与同一 backbone 的 Standard 基线在全部 50 题及各难度层的整理后复合分；Easy 为 20 题，其余各 10 题。b，保留全部 50 个同题配对。c，配对均差与 100,000 次按任务整组 bootstrap 的 95% 百分位区间。

200 次运行全部三项分量与综合分，整体均分为 0.7051。图 6至图 10报告运行期根图生成情况、TS—IRC—端点证据，以及结果与任务答案的符合程度。

3.1.1 同一模型下，Cloudra 提高了端到端机理计算得分

Guided 的综合均分为 0.7930，Standard 为 0.5814。50 道题逐题配对的平均增益为 0.2116，95% 任务 bootstrap 区间为 [0.1290, 0.2985]。Guided 在 36 题中更高、7 题中更低、7 题持平，配对差值的中位数为 0.1142（图 6）。

各组最低分十题的均值也有差别：Guided 为 0.3221，Standard 为 0.0930。

最一致的改善出现在 Hard 立体化学任务。Guided 均分为 0.9577，Standard 为 0.6888，配对增益为 0.2689 [0.1213, 0.4459]，十题中 Guided 全部更高。这些任务要求将每个能垒和计算路径归到相应立体异构体或竞争通道。

Normal 任务中，Guided 均分为 0.7370，Standard 为 0.5731，增益 0.1640 [0.0365, 0.2922]，7 题更高、3 题更低。Easy 均分分别为 0.9125 和 0.6989，但配对差值中位数为 0.0500，其分布与 Hard 中广泛为正的改善不同。Impossible 均分分别为 0.4451 和 0.2473；这组分数取决于运行是否回答了题目所要求的方法受限负结论，因而在后文单独分析。

3.1.2 自洽性对综合分增益的贡献最大

三项分数分别评价计算的不同内容（图 7）。Graph 衡量交付物中所要求物种与步骤的覆盖及身份；Self-consistency 衡量鞍点、频率、IRC 起点与端点优化/频率之间的支持关系；Accuracy 衡量结果与任务数值或负目标的符合程度。因此，一次运行可能给出接近参考的数值，而路径仍待补证；也可能完成了回答另一个研究问题的局部自洽计算。

全部 50 个 Guided–Standard 配对中，平均增益的加权图结构贡献为 +0.0108，自洽性贡献为 +0.1179，准确度贡献为 +0.0829，合计对应综合增益 0.2116。Normal 与 Hard 的全部 20 题均差为 0.2164，图结构、自洽性与准确度分别贡献 +0.0080、+0.1247 和 +0.0837。

其中 10 道 Normal 题的三项贡献为 +0.0098、+0.1141 和 +0.0400，10 道 Hard 题为 +0.0063、+0.1353 和 +0.1274。Hard 中准确度与自洽性的加权改善幅度相近。

HH1 给出了直接例子。Guided 与 Standard 均交付联萘消旋能垒 23.48 kcal/mol，接近参考 23.01 kcal/mol；两者图结构均为 1，准确度均约 0.973。自洽性分别为 1.0 和 0.5，对应综合分 0.9838 和 0.8338。归档的 Standard 研究已有候选通道和 IRC 输入；所要求的端点连接仍待证实；Guided 将路径证据关联至相应鞍点及端点。HI1 呈现类似结果：两组准确度均约为 1，自洽性由 0.2333 提高至 1.0，综合分由 0.7032 提高至 0.9999。因此，确定鞍点实际连接哪些极小值，仍需补充 IRC 及端点计

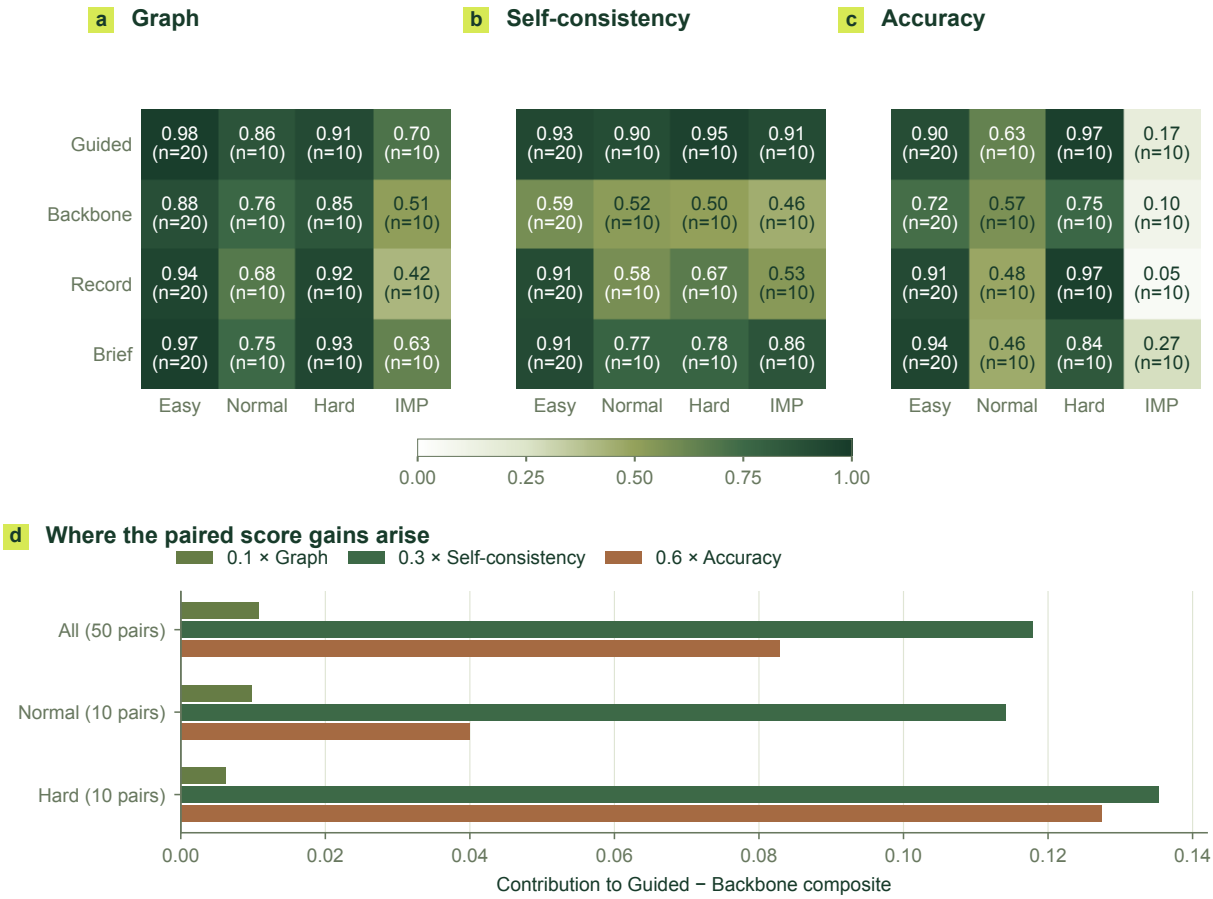


图 7. 全部 200 次整理后运行的三个评分层。a–c，各配置、难度层的 Graph、自洽性与 Accuracy 均值；每配置总体 50 题，Easy 为 20 题，其余各层 10 题。d，按固定 0.1/0.3/0.6 权重分解 Guided 相对 Backbone 的均差，全部、Normal 与 Hard 分别使用完整 50、10 和 10 个配对。各运行分量由其自身研究材料与评分记录对齐至最终整理总分。

算。

3.1.3 交付文件与分级科学支撑分别记录

运行期是否生成根图，与原运行中找到的物理证据分别记录（图 8）。原运行中，Standard 在 50 题中交付 43 份根图，Guided、Record 与 Brief-errors 各交付 50 份。Standard 需离线重建根图的 7 题为 F1、HA1、HF1、IA9、M17、NR1 和 P3。离线整理从对应运行已有研究材料组装其机理图，最终各配置均形成完整 50 题记录。恢复这 7 份 Standard 记录，使基线已完成的研究得到相应评分，避免仅因缺少根交付文件而低估基线，从而使组间比较更保守。

Standard 这 7 题整理后均分为 0.1537，Guided 在相同任务上的均分为 0.8285，贡献了两组总净差的 44.7%；其逐题分数范围为 0.0333 至 0.3425。计算结果和候选描述可能已经留在运行记录中，而所要求的路径或比较结论仍未完成；离线整理将这些已有内容恢复出来，用于评价。

各配置 40 道非 Impossible 任务中，Guided 有 24 题的自洽连续分恰好为 1（60.0%）、16 题获得部分正分；Standard 有 7 题满分（17.5%）、29 题部分正分、4 题零分；Record 为 16 题满分（40.0%）、24 题部分正分；Brief-errors 有 20 题满分（50.0%）及 20 题部分正分。图 8并列展示完整证据分布与单独记录的运行期根图交付数。

3.1.4 工具相同时，Guided 得分仍高于 Record

Record 的全 50 题均分为 0.6918，Brief-errors 为 0.7541。Guided 相对 Record 高 0.1012 [0.0396, 0.1695]，28 题更高、7 题更低、15 题持平。Normal 与 Hard 全部 20 题均差为 0.1468，其中图结构贡献 +0.0083、自洽性 +0.0919、准确度 +0.0466。最大的分量差异来自自洽性，即支持所报告步骤的频率、IRC 及端点计算。

3.1.5 研究批次耗时与量子化学作业时长

图 9并列展示重复实验的耗时和 P2 可获得的计算投入。重复实验的测量单位是一个四题批次，批内并发度为 2，每种配置实际观察 3 个批次。Guided、Standard、Record 和 Brief-errors 的平均批次耗时分别为 4.451、3.958、3.894 和 4.827 小时。Guided 平均比 Standard 长 12.5%，比 Brief-errors 短 7.8%。图中保留 12 个真实批次点及原始运行结果所对应的变异。这一测量包含批次的研究生命周期、计算等待及结果返回后的继续研究。

P2 投入统计覆盖四组共有的 15 道深挖任务。Guided 每题使用 11.08 job-hours，Standard 为 7.55，Record 为 7.88，Brief-errors 为 15.59；对应最终综合均分分别为 0.8124、0.6495、0.7360 和 0.7273。相对 Standard，Guided 累计计算时长多 46.7%，均分高 0.1629；相对 Brief-errors，累计计算时长少 28.9%，均分高 0.0851。在 15 个配对任务中，Guided 有 7 题同时比 Brief-errors 使用更少累计计算时长并得到更高分。

共同任务中，Guided 记录 789 个量子化学作业，Standard 为 419，Record 为 431，Brief-errors 为 883；其中

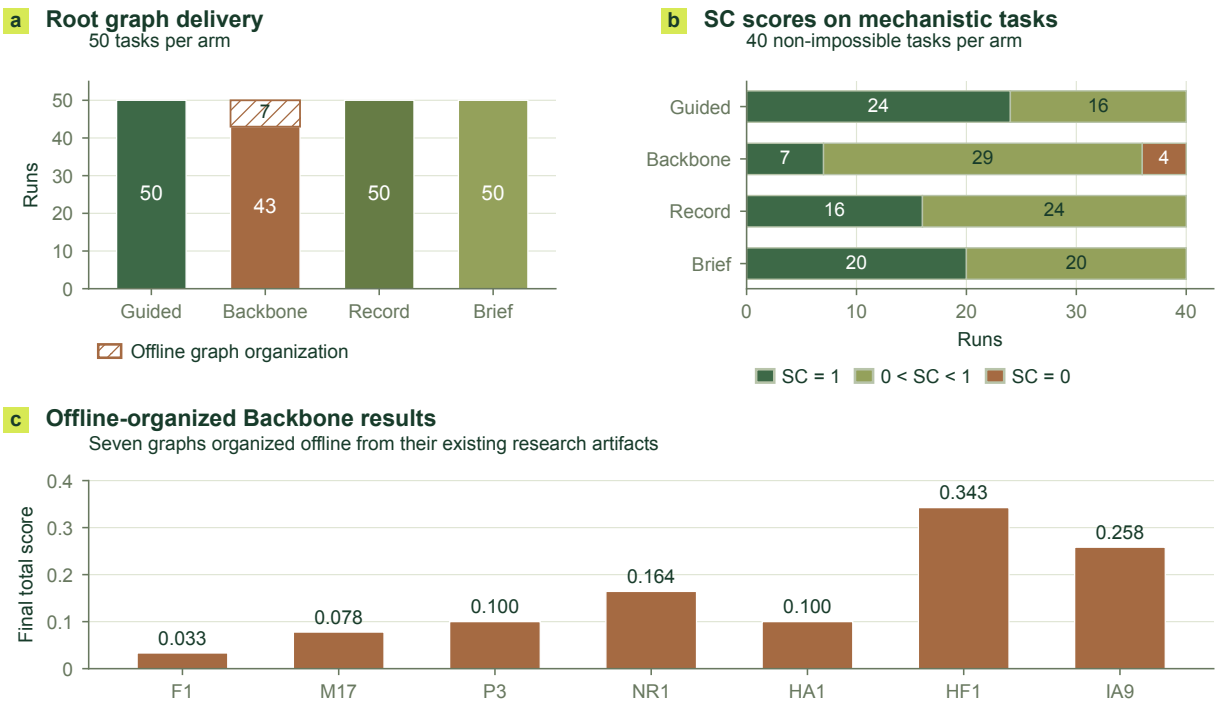


图 8. 运行期交付图与最终科学支持。a，每配置 50 题中的原始根图记录，Guided、Backbone、Record 与 Brief 分别为 50、43、50 和 50；斜线标记从运行自身材料离线组装的 7 份 Backbone 图，整理后每配置均为 50 份。b，每配置全部 40 道非 Impossible 题的自洽分布，区分 SC=1、部分正分及 SC=0；满分数依次为 24、7、16 和 20，Backbone 另有 4 题零分。c，7 个需离线重建根图的 Backbone 任务整理后总分，范围 0.0333 至 0.3425，均值 0.1537。

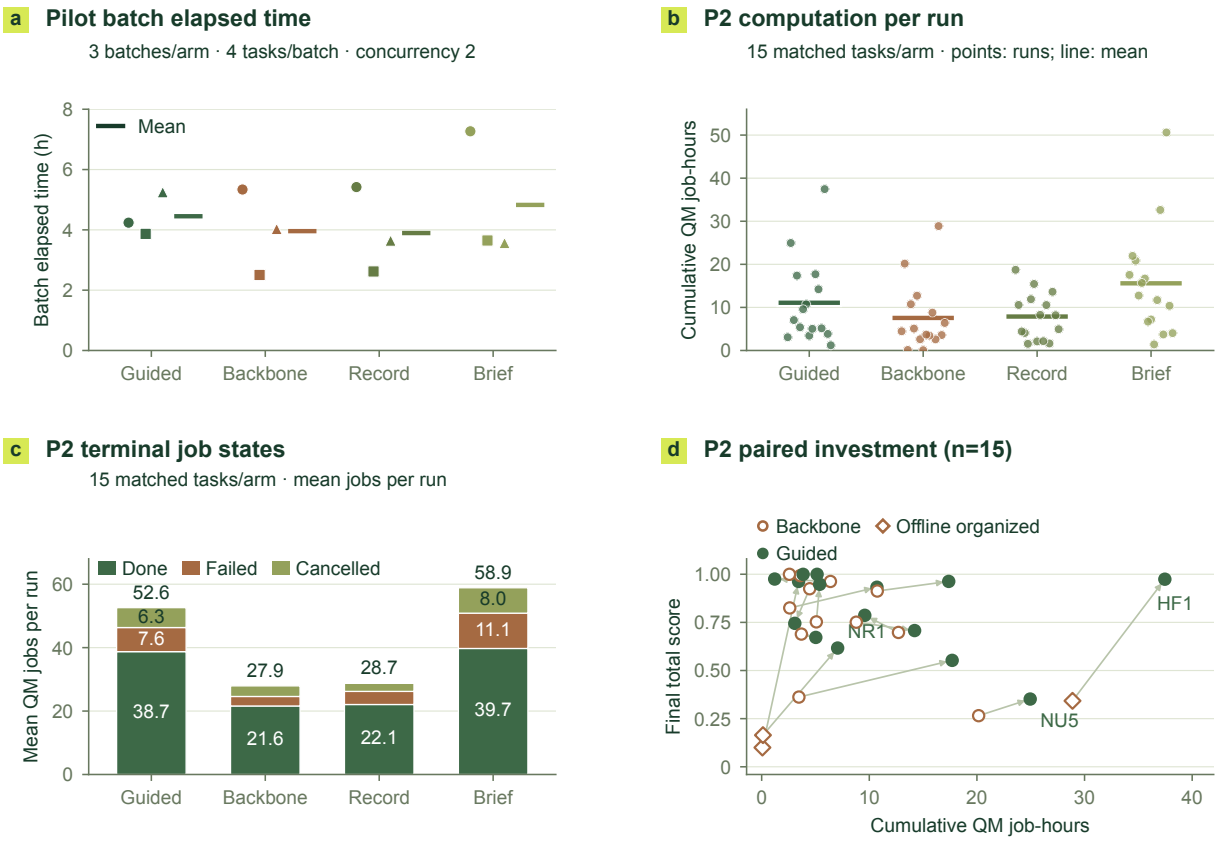


图 9. 运行速度与计算投入。a，P1b 的 12 个真实批次，每配置 3 批，每批 4 题，并发为 2；点为观测批次，短线为均值。b，P2 四配置共同 15 题的逐运行累计 QM job-hours 及均值。c，同一任务集每运行的完成、失败和取消作业数量。d，Standard 与 Guided 同题的计算投入及整理后总分，箭头连接相同任务，菱形标记离线组装机理图的运行。

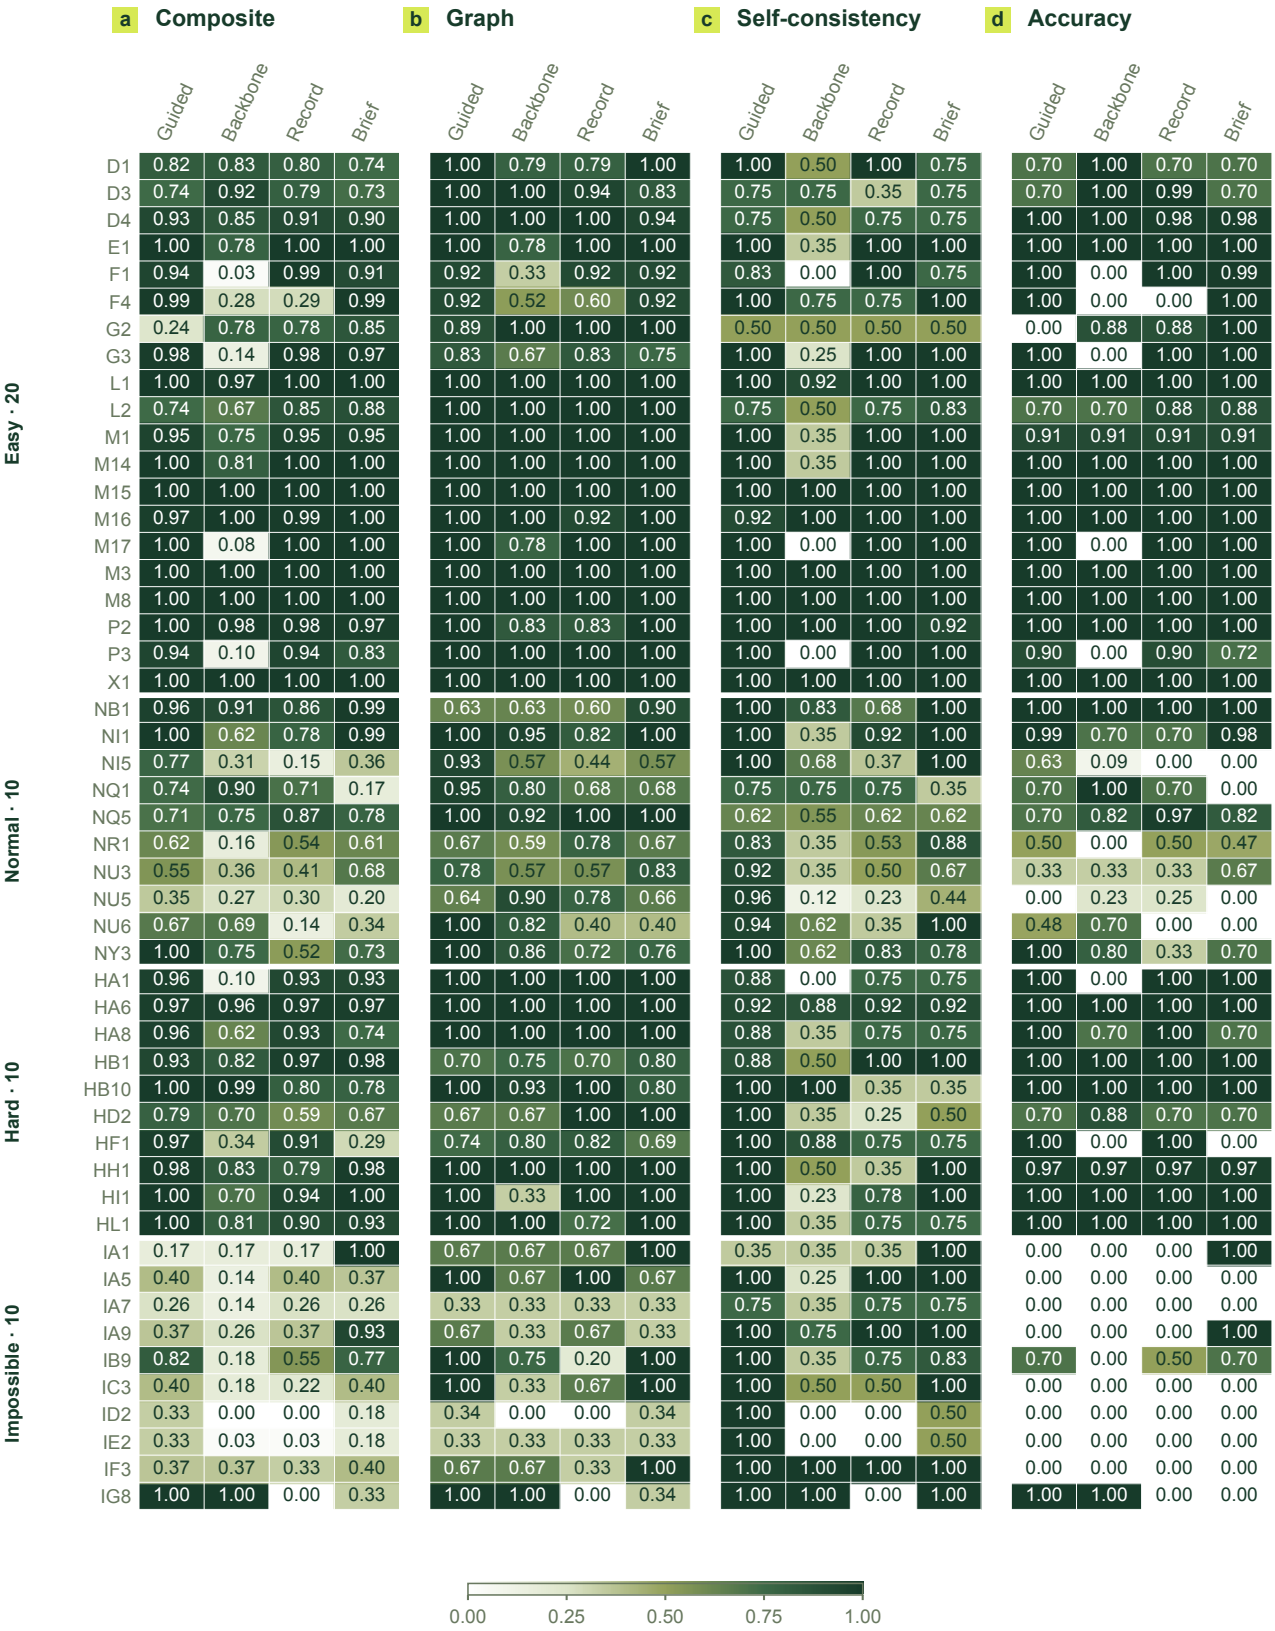


图 10. CloudraBench 全部 50 题、四配置的完整逐题成绩。四个评分块按相同顺序展示综合分、Graph、自洽性与 Accuracy，色标统一为 0–1，800 格全部呈现。数值保留两位小数，来源表保留完整精度。

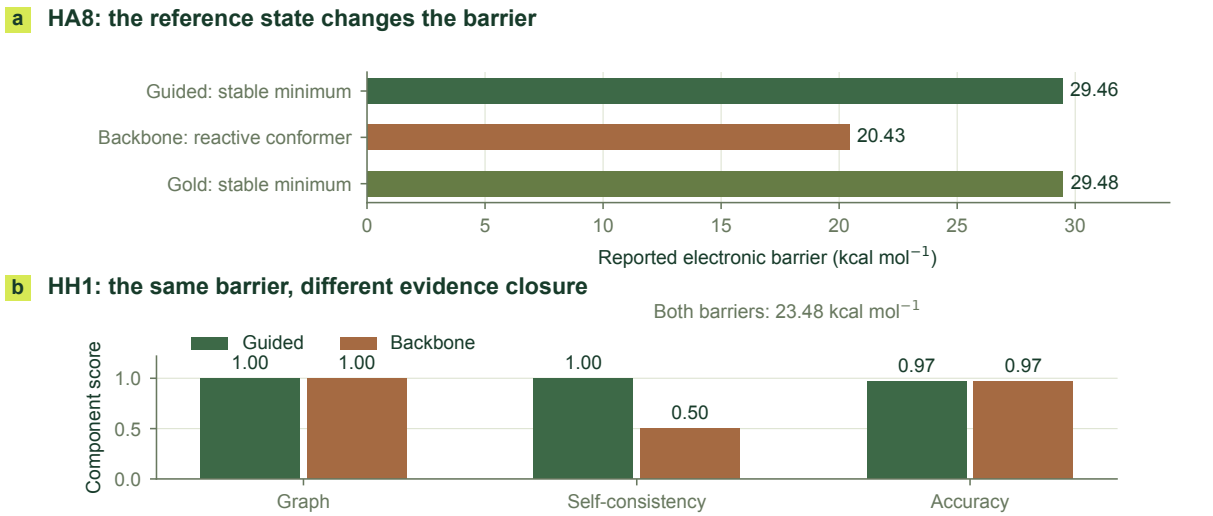


图 11. 能量参照与路径归属。a，HA8 分别采用稳定极小值与反应性构象作参照的声明能垒，与 campaign Gold 并列。b，HH1 两组均给出 23.48 kcal/mol 能垒且准确度接近，自洽证据分不同。c，NU6 两个已记录能量之差为 18.836772 kcal/mol；Guided 将其保留为 concerted 鞍点区域的代价，并将目标闭环鞍点留为待解决，Standard 则将 18.837 声明为第二步闭环能垒。计算细节与路径文字取自归档证据记录。

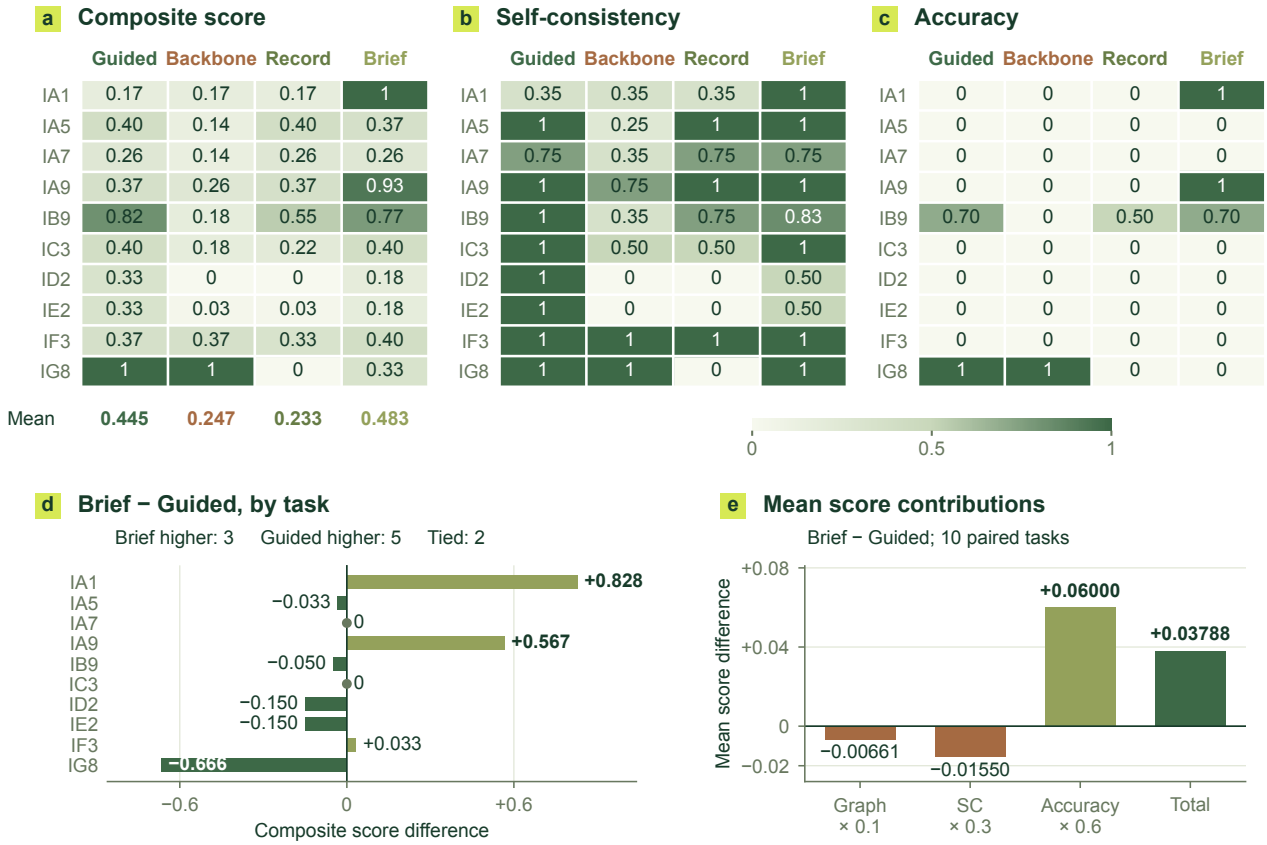


图 12. Impossible 层的逐题对照与 Brief–Guided 差异。a–c，全部 10 题、四配置的完整整理总分、自洽性和 Accuracy，色标统一为 0–1。d，Brief 相对 Guided 的逐题总分差，均差 +0.03788 集中于 IA1 与 IA9，IG8 呈相反结果；Guided 赢 5 题、Brief 赢 3 题、2 题持平。e，按既定权重分解均差，Accuracy 贡献 +0.06000、Graph 贡献 −0.00661、自洽性贡献 −0.01550，细微加总差异来自保存总分的舍入；任务 bootstrap 的 95% 区间为 −0.188 至 +0.284，逐题科学声明见下文分析。

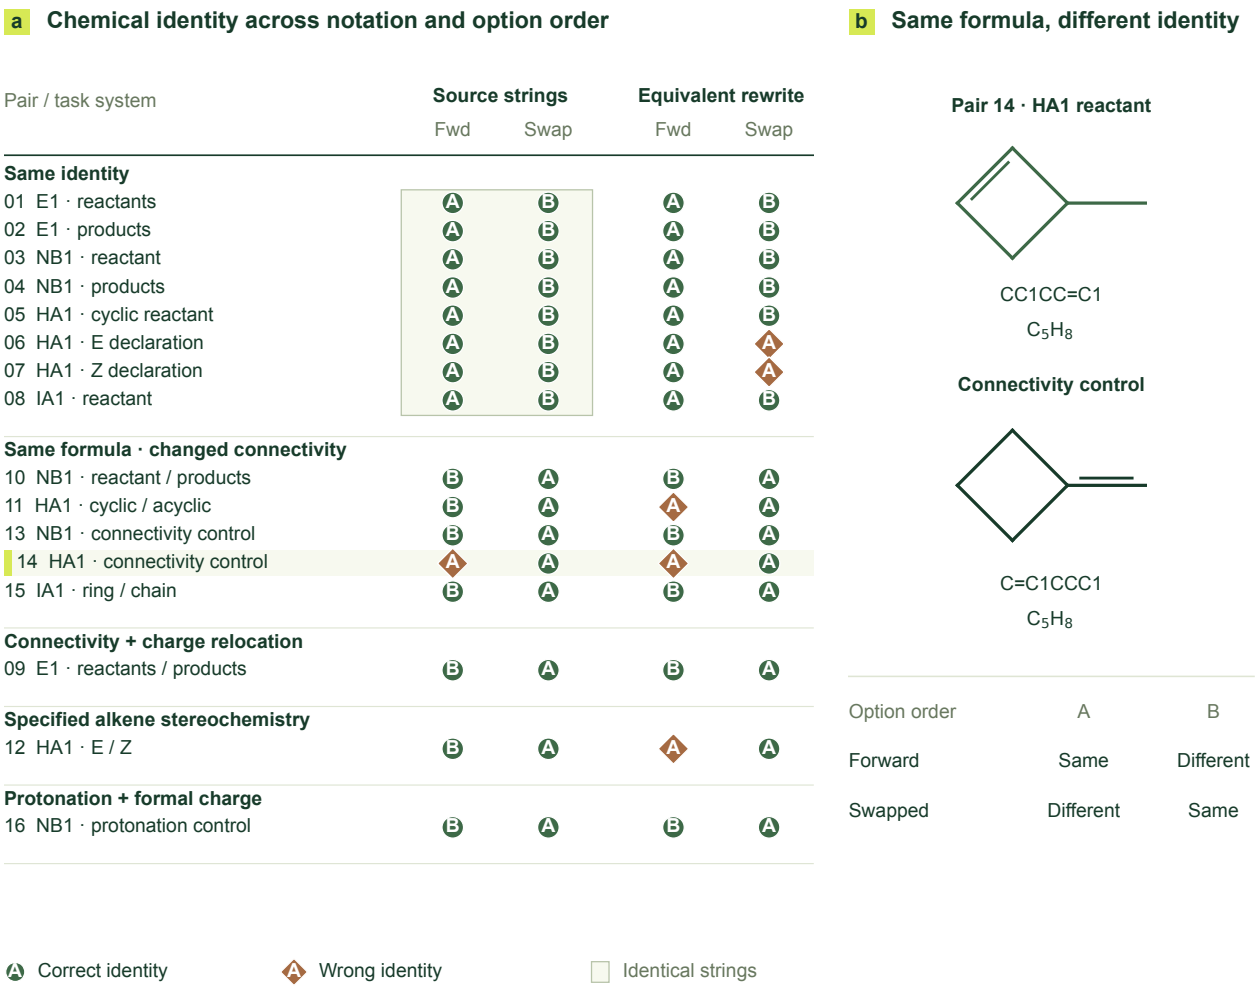


图 13. 分子表示与选项顺序下的化学身份判断。16 对分子各包含四种输入条件；圆形和菱形分别表示正确与错误，内部字母保留模型实际回答。浅色区域为相同字符串条件。右侧显示第 14 对的两种连接结构 `CC1CC=C1` 与 `C=C1CCC1` 及选项含义，两者分子式均为 C_5H_8。

失败作业分别为 114、45、62 和 167，取消作业另行记录。NU3、NU5、NU6 和 NR1 四道困难研究的 16 次运行共使用 163.5 job-hours，占可用 63 条投入档案 673.82 job-hours 的 24.3%。这四项研究追加尝试后，仍有步骤待解决。在归档的 Standard 缺图案例中，计算还可能晚于研究会话结束，后续结果因而留在已经结束的研究会话之外。

Guided 相对 Brief-errors 的总体增益为 0.0388，区间为 $[-0.0317, 0.1076]$，26 题更高、10 题更低、14 题持平。比较随研究要求改变：Guided 在 Normal 中平均高 0.1514，在 Hard 中高 0.1295，而 Brief-errors 的 Impossible 均分更高。

3.1.6 逐题比较能垒、路径与计算证据

图 10展示全部 50 题、四种配置及完整评分分量。NB1 和 NI1 也展示了多步机理计算中的得分情况。NB1 中，Guided、Standard 和 Brief-errors 分别为 0.9628、0.9128 和 0.9900，Guided 与 Brief-errors 的自洽性均为 1；NI1 中，Guided 为 0.9958，Standard 为 0.6196，自洽性分别为 1 和 0.35。与此同时，NQ5 中 Record 高于 Guided，NU3 中 Brief-errors 更高。

归档记录解释了几个具体能垒差异（图 11）。HA8 中，Guided 给出 29.46 kcal/mol，Standard 给出 20.43 kcal/mol，参考为 29.48 kcal/mol。档案将 9.03 kcal/mol 的差别追溯至能量参照：Guided 采用最低 all-s-trans 反应物极小值，Standard 采用反应性 cisoid 构象。

IRC 确定鞍点连接的局部结构；报告活化能时，则采用题目规定的稳定极小值作能量参照。

NU6 显示路径身份也可能在计算后改变。Guided 记录的 concerted 鞍点能量为 −247.030042392 Ha，betaine 极小值为 −247.060060699 Ha，两者差为 18.836772 kcal/mol。Guided 将其描述为经过 concerted 鞍点区域的能量代价，并将目标 betaine 至产物闭环鞍点保留为待解决状态；Standard 则将 18.837 kcal/mol 交付为第二步闭环能垒。两份报告将这一几乎相同的能差归给了不同过程。Guided 从 betaine 插值结构和受约束扫描峰出发的尝试，释放约束后反复回到直接反应物至产物的鞍点区域。因此，需要根据优化后的几何和路径重新判断实际找到哪个鞍点。

G2 中，Guided 得分 0.2389，Standard 为 0.7769。Guided 原生日志支持约 0.845 kcal/mol 的双氢转移能垒。伴随边的数值能垒声明三次被拒绝后，Agent 删除了数值字段；Supervisor 反馈促使其恢复字段，第四次拒绝及随后的鞍点证据检查后，最终图再次删除数值能垒以及鞍点能量、日志绑定。数值仅保留在文字说明中，准确度为 0。Brief-errors 保留了相应数值结果，得分 0.8500。

D1、D3 和 L2 中 0.7 的准确度来自既定数值偏差罚分上限。D1 与 Standard 的能垒差追溯至反应物构象参照，D3 则主要来自鞍点能量差。L2 区分反应性 cZc 与更低的 tZt 参照；Standard 已交付相应的 18.99 与 28.28

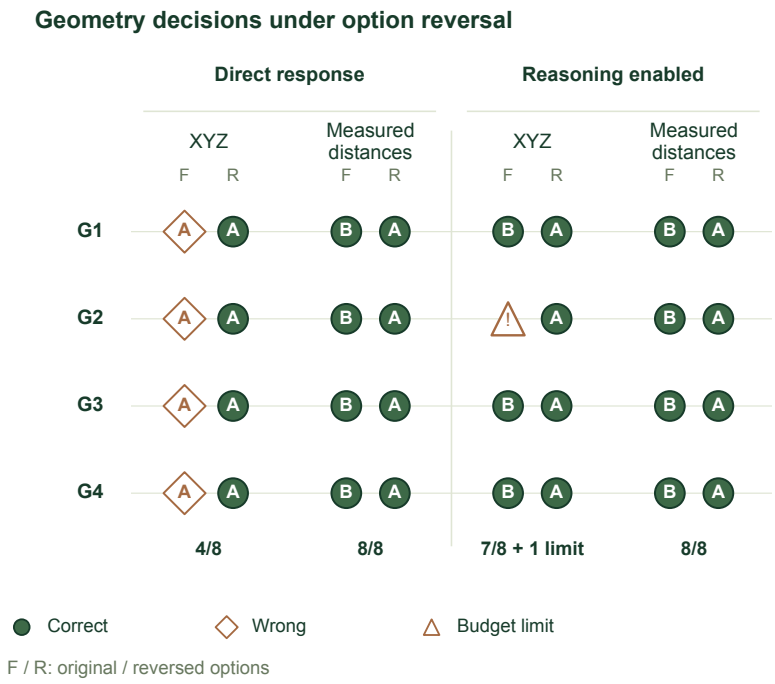


图 14. 使用坐标或测量距离，判断两个指定原子间距中哪一个更短。四个源结构分别在直接回答和开启思考条件下比较，每种条件均包含原始（F）与交换（R）选项顺序。圆形表示正确，菱形表示错误，三角形表示达到输出预算；内部字母保留实际回答。

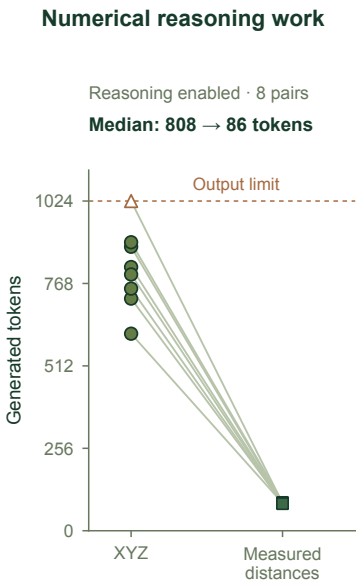


图 15. 开启思考时的生成 token 数。每条线连接同一源结构、同一选项顺序下的笛卡尔坐标输入与测量距离输入，共八组配对比较。虚线表示输出上限。

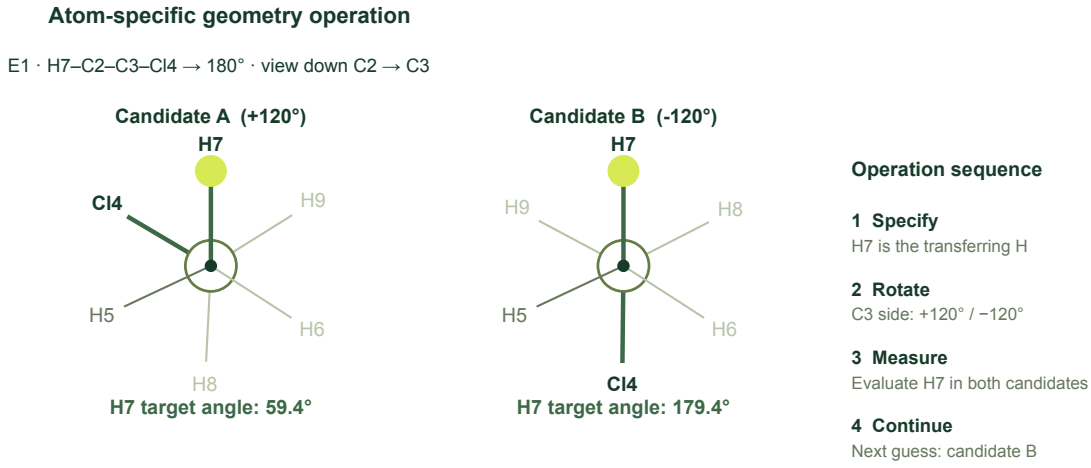


图 16. E1 中面向指定目标的几何操作。Newman 投影保留原候选坐标沿 C2→C3 观察时的方向。H7 为指定的转移原子；候选 A、B 的目标角分别为 59.4° 和 179.4°。投影旁列出相应操作顺序。

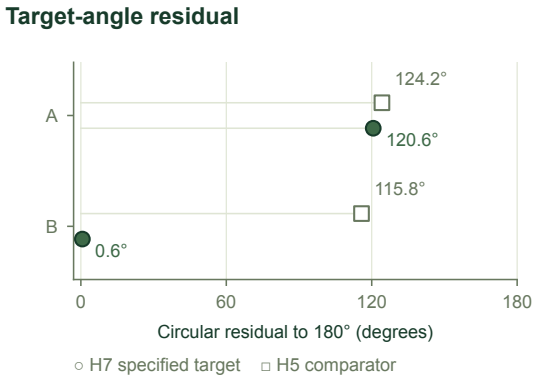


图 17. 候选 A、B 相对指定 180° 目标的圆周角残差。H7 为指定目标原子，H5 为比较原子。



图 18. 三种局部选项排列下的后续动作。仅提供 H5 测量值时，模型请求 H7 测量；补充 H7 后，模型选择候选 B。

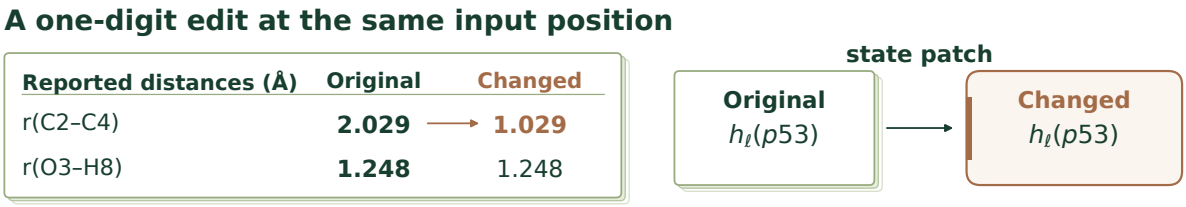


图 19. 对单个报告距离的干预。一次数字修改将 C2–C4 距离从 2.029 改为 1.029 Å，O3–H8 保持 1.248 Å。在指定层，将原始输入中 token 位置 53 的残差状态替换到修改后输入的运行中。token 位置从零计数。

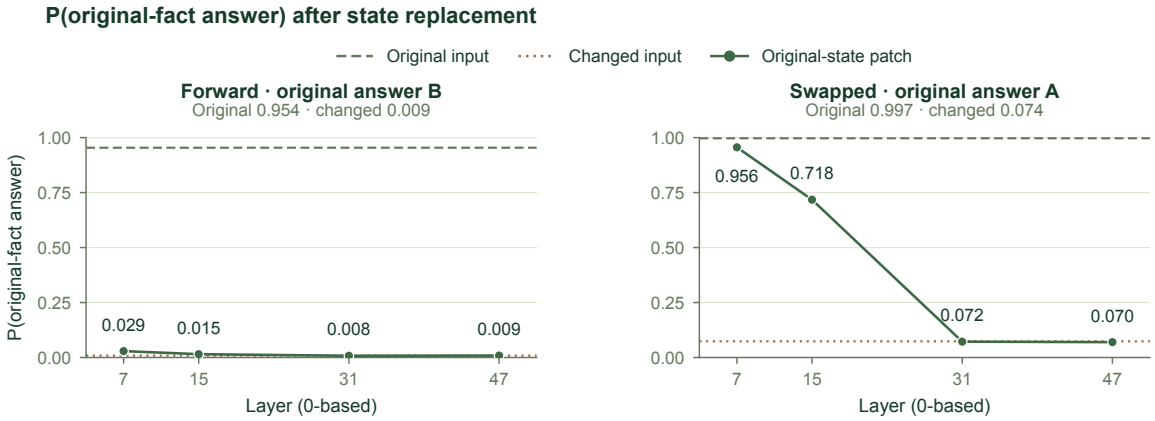


图 20. 状态替换后原始事实答案的概率。曲线显示原始顺序（答案 B）与交换顺序（答案 A）下，原始事实答案在完整词表中的概率质量，包含无前导空格与带前导空格的 token 写法。水平线为原始输入与修改后输入的基线。层号从零计数。

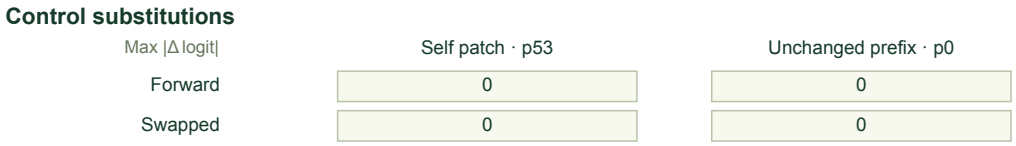


图 21. 状态干预实验的对照替换。在 p53 进行同状态自替换，以及在 p0 替换相同的前缀，两种选项顺序下均保持全部词表 logits 原值。表中报告 logit 差值绝对值的最大值。token 位置从零计数。

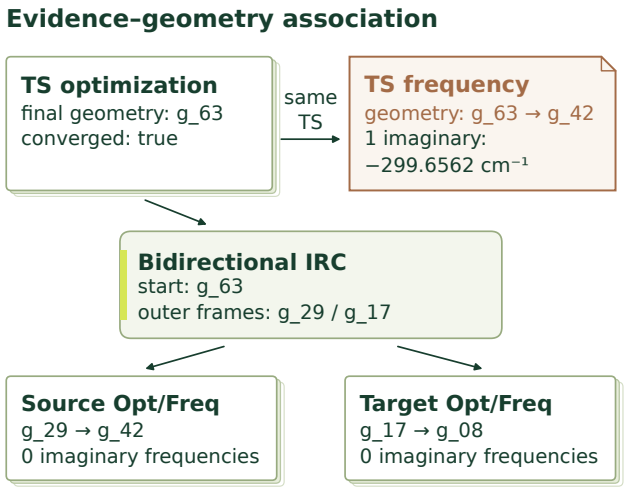


图 22. 改变 E1 频率计算所对应的几何。受控输入将频率计算的几何引用从 g_63 改为 g_42，同时保持局部终止、收敛、能量和频率数值。箭头连接过渡态优化、双向 IRC 与端点优化和频率计算。

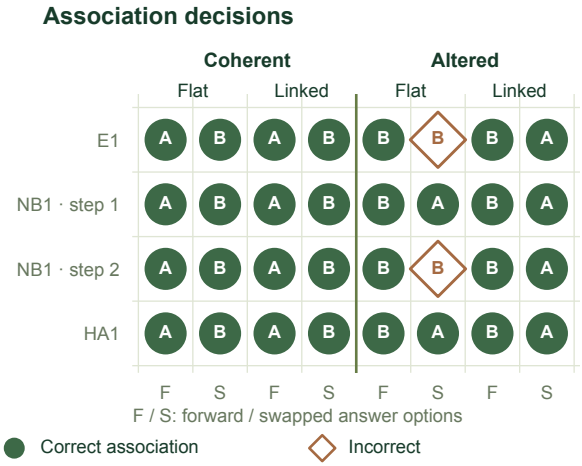


图 23. 判断计算引用是否支持指定步骤。四条源链共 32 个输入，交叉比较一致或修改后的关联、平铺或关联式表示，以及原始（F）或交换（S）答案顺序。字母保留已保存的 A/B 回答；圆形表示正确关联，菱形表示错误关联。

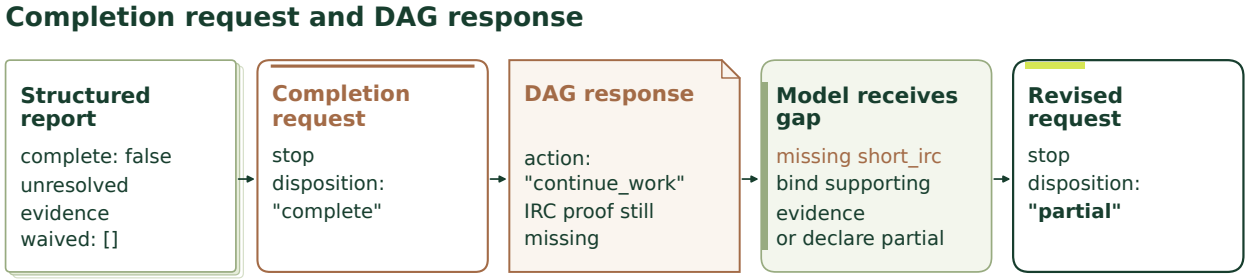


图 24. 原始 IA1 轨迹中的完成请求与 DAG 反馈。报告列有待补充的证据时，模型请求完成；系统指出缺少 short_irc 证明并向模型反馈，随后模型改为请求部分完成。

kcal/mol 两种能垒，参考匹配选中了前者。补充信息给出了这五题各工作流的最终分项得分、原生证据与交付记录。

3.1.7 Impossible 任务区分局部证据与目标负结论

Impossible 组考察在 xTB/PM7 限制下能否得到题目规定的方法受限结论。Brief-errors 均分为 0.4829，Guided 为 0.4451，Standard 为 0.2473，Record 为 0.2325（图 12）。Brief-errors 相对 Guided 赢 3 题、负 5 题、平 2 题。其平均高 0.0379，集中于特定答案：IA1 贡献 +0.8283，IA9 贡献 +0.5666；相反，IG8 中 Guided 的结果在 Brief-errors 减 Guided 方向贡献 −0.6661。

IA1 涉及环丁二烯方形几何的自同分异构目标，Brief-errors 的图结构、自洽性和准确度均为 1，Guided 准确度为 0。IA9 涉及二氧杂环丁烷热分解，两组自洽性均为 1，准确度分别为 1 和 0。铬二聚体目标 IG8 则呈相反的准确度排序。在 Brief-errors 与 Guided 准确度相同的其余 7 题中，Brief-errors 平均低 0.0500。

其 Impossible 总体优势分解为图结构 −0.0066、自洽性 −0.0155、准确度 +0.0600：更高均分来自特定任务的目标结论，而 Guided 在另外一些任务中保留了更充分的局部支持。

全部 40 次 Impossible 运行中，4 次准确度为 1，14 次同时具有自洽性 1 与准确度 0。例如，Guided 与 Brief-errors 在 IA5、IC3 和 IF3 中均得到自洽性 1 和目标负结论准确度 0；在兼含正负步骤的 IB9 中，两者准确度均为 0.7。

保存的 Brief-errors/IC3 图提供了科学报告层面的具体例子。图中将最低开壳层单重态及相应状态转换边标记为不可达，拒绝给出所求单重态—三重态能隙；已经计算的闭壳层单重态仍作为独立表征分支保留，两个方法依赖的相对能量被明确排除在目标能隙之外。该运行保留了有效探索结果，同时将这些结果明确限定于已经计算的闭壳层态；其最终准确度分仍为 0。这一明确拒绝与准确度得分之间的差异将在讨论中分析。

3.2 分子识别、原子间距比较与片段旋转

下文检验模型能否区分分子身份、比较指定原子间距、识别计算记录中错误的几何引用，以及找出尚缺的 IRC 计算。分子结构和计算记录取自归档研究轨迹；采用 Qwen3.8:27b 的局部对照分别改变输入信息、答案顺序及选定的内部状态，观察这些变化对各项判断的影响。

3.2.1 等价 SMILES 与答案顺序影响分子身份判断

一次几何修改首先需要确定它作用于哪个分子、哪个原子和哪个反应中心。相同分子可以有不同的 SMILES 遍历方式；相同分子式也可以对应不同连接关系。为考察模型如何处理这些差别，我们构造了 16 对分子身份问题，覆盖相同身份、同分子式下的连接变化、连接与电荷位置变化、双键立体化学以及质子化变化。每一对交叉设置原字符串或等价改写，以及两种答案顺序，得到 64 次判断。

模型在其中 58 次作出正确判断。等价改写改变了 32 组表示配对中的 4 组语义判断，交换答案顺序改变了 32 组选项配对中的 6 组判断。后六组都重复选择字母 A。图 13 中的一对 C_5H_8 结构尤其直观：环内双键与环外双键对应不同连接方式，模型在四种条件下均回答 A，而 A 在两种顺序中分别代表“相同”与“不同”。因此，仅改变写法或答案顺序，就可能改变模型对两个结构是否为同一分子的判断。

Cloudra 将分子连接关系与坐标分别保存，并通过原子对应关系确定测量、移动或比较哪些原子。产物端点对齐、路径插值和反应中心测量均使用这一对应关系，改变坐标后仍按原来指定的原子识别反应。

3.2.2 几何测量分担反复出现的数值推理

我们选取 NB1 轨迹中的四个实际结构，要求模型判断两个指定原子间距中哪一个更短。每个结构均交换答案顺序，并分别提供完整 XYZ 或程序测得的距离。两种信息条件进一步交叉直接作答与开启思考，形成 32 次原生聊天调用（图 14）。

直接作答时，XYZ 条件的八次响应全部选择 A，其中四次正确；提供测量距离后，八次均正确，并在选项交换后保持相同的语义答案。开启思考后，XYZ 条件得到七个正确答案，另一次在 1,024 个生成 token 时达到输出上限；该输入单独增加预算后，在 1,353 个生成 token 内得到正确答案。

测量距离条件的八次回答均正确。开启思考的八组配对中，XYZ 与测量距离条件的生成 token 中位数分别为 807.5 和 86。

提供距离后，模型直接比较程序测得的两个数值。Cloudra 同样由程序计算键长、键角和二面角，并用确定性算子旋转或平移选定片段。模型选择要移动的原子和目标构型，再比较候选结构测得的距离或角度。这种做法将数值运算交给程序，与程序辅助语言模型的思路一致。[38]

3.2.3 反馈必须对应指定原子与几何目标

在 E1 的一条真实轨迹中，模型希望将转移氢 H7、C2、C3 与离去原子 Cl4 调整为接近 180° 的二面角。它围绕 C2–C3 轴分别旋转 C3 一侧片段 +120° 与 −120°，构建候选 A 和 B，并将 C3–Cl4 距离调整到 2.35 Å。默认结构报告中的代表性二面角涉及 H5，而当前目标涉及 H7。模型随后主动计算两候选的 H7–C2–C3–Cl4，获得约 59.4° 和 179.4°，并在下一次实际提交中采用候选 B。

图 16 给出由保存的候选坐标绘制的 C2→C3 方向 Newman 投影，图 17 汇总对应的目标角残差。

候选 B 的 H7 目标角距 180° 仅 0.6°，A 的相应残差为

120.6°；H5 比较量在两候选中的残差分别为 124.2° 和 115.8°。判断 B 中 H7 与 Cl4 的反式共平面排布，需要测量 H7 所定义的二面角。

局部对照只提供 H5 测量值时，三种循环选项排列均请求补测 H7；加入 H7 后，三种排列均选择 B。另两组充分性配对也随目标量的加入，从需要补测转为信息充分。

3.2.4 激活替换对距离比较答案的影响随选项顺序变化

为检验一个报告距离怎样影响答案，我们在同一本地量化模型中进行了单位置激活替换。[39] 输入中的一个距离由 2.029 Å 改为 1.029 Å，另一距离保持 1.248 Å，对应的比较答案随之反转。随后把原始输入在数字 token 位置的残差状态，分别替换到改动输入的第 7、15、31 和 47 层，并读取原始事实所对应答案的全词表概率。

替换的影响随层和选项顺序变化（图 20）。在交换选项的输入中，原始事实答案 A 的概率由改动后的 0.074，在第 7 和 15 层替换后分别升至 0.956 和 0.718；第 31 和 47 层的值分别为 0.072 和 0.070。在原选项顺序中，答案 B 的概率由 0.009，在前两层替换后分别变为 0.029 和 0.015，后两层仍接近改动输入。

自替换及未改变前缀位置的控制替换中，全词表 logit 差均为零。

交换选项时，替换早期层状态使原始事实的答案重新成为首选；保持原选项顺序时，首选仍是修改后事实的答案。因此，从同一数字位置恢复原答案的效果取决于选项顺序，3.2.1 节的分子身份判断也出现了选项顺序依赖。

3.3 从计算结果判定物种与反应路径

3.3.1 将频率与 IRC 端点对应到同一鞍点

几何对象进入计算之后，研究需要把优化结构、能量、频率与路径逐步组织成对同一反应步骤的支持。每份结果的局部有效性及其归属共同决定这条支持链：频率应对应所声明的鞍点，IRC 应从该鞍点出发，两侧末帧的优化与频率应对应相应端点。DAG 将优化几何、频率计算、IRC 起点和端点计算归到对应物种或步骤，并分别记录作业执行、优化收敛及这些物理检查的结果；优化已经收敛时，频率或端点计算仍可能尚缺。

我们从归档提取四条源证据链，分别构造保持关联与改变单一引用的版本，并交叉平铺表示、关联表示和两种答案顺序，得到 32 个输入。单一引用的变化分别涉及频率几何、IRC 起始几何、端点优化输入或目标物种；局部终止、收敛、能量和频率值均保持原值。图 22 以 E1 为例：将频率的几何引用从鞍点改为一个已有的端点，便改变了这份频率对当前步骤的支持关系。

关联表示的 16 次判断均正确，平铺表示的 16 次中有 14 次正确；两处错误均出现在引用已改变且选项交换的条件，分别来自 E1 与 NB1 第二步。随后选择的两条源链原生跟进中，开启思考使全部 16 次关联判断正确，包括原先两处错误。局部数值保持原值时，模型在关联式表示下仍识别出了所有修改过的引用。这一呈现方式的影响与图编码影响语言模型关系推理的观察一致。[40] Cloudra 为每个物种、步骤和计算尝试记录相应产物引用，明确当前比较的是哪一个鞍点、哪条 IRC 及哪些端点计算。

3.3.2 IRC 连接与过渡态曲率的诊断反馈

诊断反馈把证据问题对应到需要修订的化学对象和计算。Cloudra 的结构化诊断指出具体问题，例如位阻冲突原子对、虚频模式对齐异常及路径端点连接问题，使智能体能够据此调整冲突几何、检查虚频模式或重算相应端点。

两条归档轨迹展示了这一过程。在 Brief-errors 的 HA1 试验中，简短错误代码替代了详细的 IRC 端点关联诊断。计算智能体反复更换源极小值引用，几何连接问题仍待处理。在 Guided 的 NB1 试验中，检查发现零虚频并返回模式诊断；协调智能体要求调整过渡态初猜参数和优化约束，计算智能体将这些改动用于下一次提交。[41]

3.3.3 IA1：IRC 计算尚缺时的结束请求

IA1 的归档轨迹中，一次结束请求与已记录的科学要求发生冲突。反应步骤的必要双向 short_irc 验证仍待完成，豁免清单为空。Supervisor 此前曾肯定中间体优化收敛，模型随后在 IRC 仍待完成时请求结束研究。

系统驳回该请求，并将尚缺的 short_irc 要求返回模型。下一次提交中，模型将状态改为部分完成（图 24）。完成状态改变时，IRC 计算仍处于待完成状态。

我们还检验模型能否依据记录状态辨认 IA1 的未完成要求。在最新摘要与 12 条消息历史两种条件、正反选项顺序组成的 6 对输入中，12 次判断均正确（100%）。

3.4 工作流引导、科学判断与展望

工具图与任务图组织计算执行。Cloudra 的 Delivery DAG 约束智能体提交的机理表达：节点表示物种在机理中的一次出现，边表示基元步骤，承载分子几何、成键关系与反应连接。化学信息学算法确立并比较分子身份与原子对应关系；频率及 IRC/端点计算判断计算支持哪些驻点及连接。50 题对照衡量这些方法在完整机理计算任务中的表现。Guided 的平均自洽性和准确度均高于 Standard；Hard 中，两者对增益的加权贡献分别为 +0.1353 和 +0.1274。HH1 和 HI1 报告了接近参考的能垒；确定这些鞍点连接哪些极小值，仍需补充 IRC 及端点计算。

HA8 和 NU6 展示了几何优化后需要核对的两类归属。HA8 采用稳定反应物极小值作为能垒参照，而 IRC 连接的是鞍点附近的局部活性构象。NU6 中，用于寻找 betaine 至产物闭环鞍点的初猜，反复优化至直接反应物至产物的鞍点区域。因此，需要按优化结构及路径判断实际找到哪个鞍点。DAG 记录反应物构象、鞍点、IRC 端点及相应步骤，使智能体能够在新计算返回后检查每个能量属于哪个结构。这种使用已记录计算结果的做法，与语言模型研究中外部规划、检验和反馈的作用一致。[42]

缺少端点优化时，需要补算该端点；鞍点反复回到另一条路线时，需要调整初猜或修改路径假设。目标电子态超出方法描述能力时，则需要重新判断方法与所求结论。智能体需要对照计算结构和路径检查其反应描述，因为原有解释可能在计算结果改变后仍显得合理。[43] Record 保留了工具，自洽分仍低于 Guided，Normal 和 Hard 任务尤其如此。Brief-errors 对照也随任务而变：Guided 在 Normal 和 Hard 中的均分更高，Brief-errors 则在 Impossible 中更高。因此，需要具体考察反馈是否让智能体处理了相应几何、计算或方法限制，这与工具反馈用于推理修正的研究一致。[41, 44]

Brief-errors/IC3 保留了已表征的闭壳层分支，同时拒绝给出所求最低开壳层单重态及其单重态—三重态能隙。Brief-errors 在 IA1 和 IA9 中也得分更高，Guided 则在 IG8 中更高。这些交叉结果提出了一个依赖任务的假说：详细诊断可能有助于修复 TS 或 IRC 计算；方法或目标本身需要重新审视时，继续局部修补的收益可能有限。本次对照记录的是最终任务结果；诊断长度的因果作用及其内部认知机制仍待专门研究。

G2 中，伴随边的检查阻止了数值声明，随后智能体删除了原生计算已支持的数值。Supervisor 反馈曾恢复这些字段，后续拒绝又先于最终删除。路径仍在检验时，应保留数值观测及其原生日志，并按当前验证状态说明数值可用于哪些机理结论。G2 保留了部分自洽分，数值字段被删除后失去了准确度分。

Record/IA5 与 Brief-errors/IC3 的所求目标和正向替代对象具有相同的端点连接关系：前者是异旋与同旋路径，后者是开壳层与闭壳层电子态。两例运行均明确拒绝了所求目标，归档匹配器却选择了正向替代对象。本文保留最终分数，并同时报告这些科学主张。评价这类任务时，需要先匹配反应通道或电子态，再判断最终结论。

SI 按原有负目标计分规则，对 IA5 与 IC3 的所求对象开展条件性匹配分析，固定两例的图分、自洽分及其余 198 次运行。每次对象归属修正使一例综合分由 0.4 变为 1.0，对应配置的 Impossible 均分增加 0.0600。两项同时修正时，Brief、Guided、Record 和 Standard 的条件均分分别为 0.54294、0.44506、0.29250 和 0.24733。Brief、Guided、Record 保持原有排序，Record 超过 Standard；Guided 与 Standard 的每一对比较均保持原值。正文报告最终评价分数；条件分析只改变原有负目标分应计入哪个图对象。

P2 每题每配置保留一次运行，任务簇 bootstrap 区间反映抽样题目构成的变化；同一任务的随机方差需要独立重复运行来估计。另行开展的 P1b 研究在四题、四配置的每个组合上重复三次，共 48 次运行，覆盖 P2 的 50 题中的四题。完整整理后的 P2 表覆盖 200 次运行及其三项评分分量。部分 Hard 任务的准确度目标是定性通道身份，因此收益包括路径识别、证据闭合和数值能垒。后续对完整题库重复评估，可以进一步刻画运行间变异及不同研究路线的选择频率。

Impossible 组考察在题目允许的当前方法下认为物理不存在的目标，这类判断限定于相应的方法描述。其分量还采用负目标规则，显式负结论的自洽性 1 与正路径的 TS—IRC—端点证明分别解释。14 例自洽性 1、准确度 0，需要结合运行实际表征或拒绝的电子态、路径或性质理解。

12 个先导批次测量并发度 2 的四题真实耗时，包含原始失败与停止结果；P2 投入档案覆盖选定的深挖研究，四配置共有 15 题。累计 job-hours 代表记录的量子化学进程时长，Standard/M1 另有已注明的原生日志重构；它与核时、费用及 P2 端到端研究耗时不同。并发计算共享资源，CPU 排队可能延迟个别结果。进一步区分排队、计算和智能体活跃时间，可以确定一次运行分别花了多少时间等待、计算和选择后续操作。

Standard 缺图时，计算仍在进行，研究已提前结束；Guided/HI1 则在收到完成通知后仍停留于等待状态。两种情况都需要在形成最终报告前，让返回的计算结果重新进入待继续的研究。另一个搜索问题是反复优化到同一驻点区域，NU6 即属此例。候选选择方法可以比较新鞍点与先前尝试，帮助智能体选择下一次初猜或路径假设。

Cloudra 的默认预组织采样 32 个刚体相对放置，进行局部 MMFF94 松弛，再按能量与聚类选择候选。频率检查确定候选的驻点性质，寻找更低构象则需要额外采样。HA8 需要同时保留规定的稳定参照和局部活性构象；全局最低点的主张还需要评估构象覆盖。CREST 通过独立的可选后端提供，其在本次 200 次运行中的覆盖范围仍待逐项确认。高柔性体系可能需要更广的构象采样与更多量子化学计算。后续需要测量找到了哪些低能构象，以及如何在竞争候选之间分配计算。

本基准以纯电子能差计分；零点能、热与熵、标准态及溶剂化贡献属于进一步的自由能处理。NI5 的题设为弱酸性水溶液，NU5 则为高浓度二氯甲烷条件，这一区别对二者尤为重要。其分数评价规定的电子能参照。对于缔合与解离，熵及浓度相关的标准态项进入 $\Delta G^{\ddagger}$；溶剂参与还可能改变描述路径所需的化学模型。推断溶液条件下的控速步骤或立体选择性，需要对相关物种和路径采用一致的自由能处理。当前电子能对照将实际溶剂影响的大小与方向留给单独的溶剂敏感性研究。

原子映射系数与歧义窗口，以及分支拥挤描述符的衰减、深度和拥挤设置，在各工作流对照中保持固定。本研究评价固定设置下的整体表现，各项设置的敏感性与独立贡献仍待测量。虚频模式对齐比值 0.5 仅用于提示，科学有效性由驻点与 IRC 端点证据决定。P2 各配置均使用 DeepSeek-v4.1-flash（1017），归档 API 别名为 `deepseek-v4-flash`，请求设置另行保留。采用更多 backbone 进行比较，可以检验工作流收益在不同模型间的适用范围。

将 Cloudra 从小分子机理计算扩展至其他体系，需要采用适合这些体系的表示、计算方法和物理判据。现有的计算引擎和共享执行基础设施可以支持这些计算。Cloudra 将以 GNU Affero General Public License（AGPL）开源，支持系统的公开检查、复用与社区共同发展。

数据获取。Cloudra 公开研究数据目录提供 P2、48 次 P1b 实验、Gold 参考证据和 SI 复现材料；内容、版本与校验值见 SI 第 S7 节及下载说明。

参考文献

[1] K. Fukui. Formulation of the reaction coordinate. *The Journal of Physical Chemistry*, 74:4161–4163, 1970. doi: 10.1021/j100717a029.

[2] S. Maeda, Y. Harabuchi, Y. Ono, T. Taketsugu, and K. Morokuma. Intrinsic reaction coordinate: Calculation, bifurcation, and automated search. *International Journal of Quantum Chemistry*, 115:258–269, 2015. doi: 10.1002/qua.24757.

[3] Yunheng Zou et al. El Agente: An autonomous agent for quantum chemistry. *Matter*, 8:102263, 2025. doi: 10.1016/j.matt.2025.102263.

[4] Jinming Hu, Hassan Nawaz, Yi-Fan Hou, Lijie Chi, Xin-Yu Tong, Yuting Rui, Yuxinxin Chen, Arif Ullah, and Pavlo O. Dral. Aitomia: An Agentic Framework for AI-Driven Atomistic and Quantum Chemical Simulations. *Journal of Chemical Theory and Computation*, 22(13):6557–6571, 2026. doi: 10.1021/acs.jctc.6c00591. URL `https://doi.org/10.1021/acs.jctc.6c00591`.

[5] Jiaru Bai, Abdulrahman Aldossary, Thomas Swanick, Marcel Müller, Yeonghun Kang, Changhyeok Choi, Naruki Yoshikawa, Zijian Zhang, Jin Won Lee, Tsz Wai Ko, Aiwei Yin, Mohammad Ghazi Vakili, Chris Crebolder, Varinia Bernales, and Alán Aspuru-Guzik. El Agente Gráfico: A Semantic Execution Runtime for Scientific Agents, 2026. URL `https://arxiv.org/abs/2602.17902v2`. Version 2, 7 August 2026.

[6] Changhyeok Choi, Yunheng Zou, Marcel Müller, Han Hao, Yeonghun Kang, Juan B. Pérez-Sánchez, Ignacio Gustin, Hanyong Xu, Andrew Wang, Mohammad Ghazi Vakili, Chris Crebolder, Alán Aspuru-Guzik, and Varinia Bernales. El Agente Estructural: An Artificially Intelligent Molecular Editor, 2026. URL `https://arxiv.org/abs/2602.04849`.

[7] Dong Li, Sixuan Mi, Zihao Ye, Huan Xiong, Tao Xu, Tong Zhu, Aijia Zhang, Junqi Gao, Kaiyan Zhang, Shijie Wang, Bowen Zhou, Yuqiang Li, and Biqing Qi. Autonomous Chemical Mechanistic Discovery through Agentic Reasoning and Validation, 2026. URL `https://arxiv.org/abs/2609.11147`.

[8] Juan B. Pérez-Sánchez, Yunheng Zou, Jorge A. Campos-Gonzalez-Angulo, Marcel Müller, Ignacio Gustin, Andrew Wang, Han Hao, Tsz Wai Ko, Changhyeok Choi, Eric S. Isbrandt, Mohammad Ghazi Vakili, Hanyong Xu, Chris Crebolder, Varinia Bernales, and Alán Aspuru-Guzik. El Agente Quntur: A research collaborator agent for quantum chemistry. *Chem*, page 103259, 2026. doi: 10.1016/j.chem

pr.2026.103259. URL https://doi.org/10.1016/j.chempr.2026.103259.

[9] S. Riniker and G. A. Landrum. Better Informed Distance Geometry: Using What We Know To Improve Conformation Generation. *Journal of Chemical Information and Modeling*, 55:2562–2574, 2015. doi: 10.1021/acs.jcim.5b00654.

[10] Shuzhe Wang, Jagna Witek, Gregory A. Landrum, and Sereina Riniker. Improving conformer generation for small rings and macrocycles based on distance geometry and experimental torsional-angle preferences. *Journal of Chemical Information and Modeling*, 60(4): 2044–2058, 2020. doi: 10.1021/acs.jcim.0c00025.

[11] RDKit. Getting Started in Python: Conformer Generation and Maximum Common Substructure, 2026. URL https://www.rdkit.org/docs/GettingStartedInPython.html. Online documentation; accessed 31 October 2026.

[12] Thomas A. Halgren. Merck molecular force field. I. basis, form, scope, parameterization, and performance of MMFF94. *Journal of Computational Chemistry*, 17(5–6):490–519, 1996. doi: 10.1002/(SICI)1096-987X(199604)17:5/6<490::AID-JCC1>3.0.CO;2-P.

[13] W. Kabsch. A discussion of the solution for the best rotation to relate two sets of vectors. *Acta Crystallographica Section A*, 34:827–828, 1978. doi: 10.1107/S0567739478001680.

[14] Søren Smidstrup, Andreas Pedersen, Kurt Stokbro, and Hannes Jónsson. Improved initial guess for minimum energy path calculations. *The Journal of Chemical Physics*, 140(21):214106, 2014. doi: 10.1063/1.4878664.

[15] Graeme Henkelman and Hannes Jónsson. Improved tangent estimate in the nudged elastic band method for finding minimum energy paths and saddle points. *The Journal of Chemical Physics*, 113(22):9978–9985, 2000. doi: 10.1063/1.1323224.

[16] Ask Hjorth Larsen, Jens Jørgen Mortensen, Jakob Blomqvist, Ivano E. Castelli, Rune Christensen, Marcin Dułak, Jesper Friis, Michael N. Groves, Bjørk Hammer, Cory Hargus, et al. The atomic simulation environment—a Python library for working with atoms. *Journal of Physics: Condensed Matter*, 29(27):273002, 2017. doi: 10.1088/1361-648X/aa680e.

[17] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations*, 2015. URL https://arxiv.org/abs/1412.6980.

[18] Cloudra. Cloudra source code, 2026. URL https://github.com/yyywaa/Cloudra-mechanism-agent/tree/70daa5a. Revision 70daa5a, 26 October 2026.

[19] Charles R. Harris, K. Jarrod Millman, Stéfan J. van der Walt, Ralf Gommers, Pauli Virtanen, David Cournapeau, Eric Wieser, Julian Taylor, Sebastian Berg, Nathaniel J. Smith, Robert Kern, Matti Picus, Stephan Hoyer, Marten H. van Kerkwijk, Matthew Brett, Allan Haldane, Jaime Fernández del Río, Mark Wiebe, Pearu Peterson, Pierre Gérard-Marchant, Kevin Sheppard, Tyler Reddy, Warren Weckesser, Hameer Abbasi, Christoph Gohlke, and Travis E. Oliphant. Array programming with NumPy. *Nature*, 585(7825):357–362, 2020. doi: 10.1038/s41586-020-2649-2.

[20] Noel M. O'Boyle, Adam L. Tenderholt, and Karol M. Langner. cclib: A library for package-independent computational chemistry algorithms. *Journal of Computational Chemistry*, 29(5):839–845, 2008. doi: 10.1002/jcc.20823.

[21] Aric A. Hagberg, Daniel A. Schult, and Pieter J. Swart. Exploring network structure, dynamics, and function using NetworkX. In Gaël Varoquaux, Travis Vaught, and Jarrod Millman, editors, *Proceedings of the 7th Python in Science Conference*, pages 11–15, Pasadena, CA, 2008. URL https://aric.hagberg.org/papers/hagberg-2008-exploring.pdf.

[22] Jianlyu Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-Embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 2318–2335, 2024. doi: 10.18653/v1/2024.findings-acl.137. URL https://aclanthology.org/2024.findings-acl.137/.

[23] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011. URL https://jmlr.org/papers/v12/pedregosa11a.html.

[24] Philipp Pracht, Fabian Bohle, and Stefan Grimme. Automated exploration of the low-energy chemical space with fast quantum chemical methods. *Physical Chemistry Chemical Physics*, 22(14):7169–7192, 2020. doi: 10.1039/C9CP06869D.

[25] Christoph Bannwarth, Sebastian Ehlert, and Stefan Grimme. GFN2-xTB—an accurate and broadly parametrized self-consistent tight-binding quantum chemical method with multipole electrostatics and density-dependent dispersion contributions. *Journal of Chemical Theory and Computation*, 15(3):1652–1671, 2019. doi: 10.1021/acs.jctc.8b01176.

[26] James J. P. Stewart. Optimization of parameters for semiempirical methods VI: more modifications to the NDDO approximations and re-optimization of parameters. *Journal of Molecular Modeling*, 19(1):1–32, 2013. doi: 10.1007/s00894-012-1667-x.

[27] Axel D. Becke. Density-functional thermochemistry. III. the role of exact exchange. *The Journal of Chemical Physics*, 98(7):5648–5652, 1993. doi: 10.1063/1.464913.

[28] Chengteh Lee, Weitao Yang, and Robert G. Parr. Development of the Colle–Salvetti correlation-energy formula into a functional of the electron density. *Physical Review B*, 37(2):785–789, 1988. doi: 10.1103/PhysRevB.37.785.

[29] P. J. Stephens, F. J. Devlin, C. F. Chabalowski, and M. J. Frisch. Ab initio calculation of vibrational absorption and circular dichroism spectra using density functional force fields. *The Journal of Physical Chemistry*, 98(45):11623–11627, 1994. doi: 10.1021/j100096a001.

[30] Stefan Grimme, Jens Antony, Stephan Ehrlich, and Helge Krieg. A consistent and accurate ab initio parametrization of density functional dispersion correction (DFT-D) for the 94 elements H–Pu. *The Journal of Chemical Physics*, 132(15):154104, 2010. doi: 10.1063/1.3382344.

[31] Stefan Grimme, Stephan Ehrlich, and Lars Goerigk. Effect of the damping function in dispersion corrected density functional theory. *Journal of Computational Chemistry*, 32(7):1456–1465, 2011. doi: 10.1002/jcc.21759.

[32] Florian Weigend and Reinhart Ahlrichs. Balanced basis sets of split valence, triple zeta valence and quadruple zeta valence quality for H to Rn: Design and assessment of accuracy. *Physical Chemistry Chemical Physics*, 7:3297–3305, 2005. doi: 10.1039/B508541A.

[33] Frank Neese. Software update: The ORCA program system—version 6.0. *WIREs Computational Molecular Science*, 15(2):e70019, 2025. doi: 10.1002/wcms.70019.

[34] M. J. Frisch, G. W. Trucks, H. B. Schlegel, G. E. Scuseria, M. A. Robb, J. R. Cheeseman, G. Scalmani, V. Barone, G. A. Petersson, H. Nakatsuji, et al. Gaussian 16. Gaussian, Inc., Wallingford, CT, 2016. URL https://gaussian.com/citation/.

[35] Jonathan E. Moussa and James J. P. Stewart. MOPAC: An open-source semiempirical molecular orbital program. *Journal of Open Source Software*, 11(119):8025, 2026. doi: 10.21105/joss.08025.

[36] FACCTs. ORCA 6.1 Manual, 2025. URL https://www.faccts.de/docs/orca/6.1/manual/. Online documentation; accessed 31 October 2026.

[37] DeepSeek-AI. DeepSeek V4 Model Card, 2026. URL https://fe-static.deepseek.com/chat/transparency/deepseek-V4-model-card-EN.pdf.

[38] Luyu Gao, Aman Madaan, Shuyan Zhou, Uri Alon, Pengfei Liu, Yiming Yang, Jamie Callan, and Graham Neubig. PAL: Program-aided language models. In *Proceedings of the 40th International Conference on Machine Learning*, volume 202, pages 10764–10799, 2023. URL https://proceedings.mlr.press/v202/gao23f.html.

[39] Fred Zhang and Neel Nanda. Towards Best Practices of Activation Patching in Language Models: Metrics and Methods. In *International Conference on Learning Representations*, 2024. URL https://proceedings.iclr.cc/paper_files/paper/2024/hash/06a52a54c8ee03cd86771136bc91eb1f-Abstract-Conference.html.

[40] Bahar Fatemi, Bryan Perozzi, and Jonathan Halcrow. Talk like a Graph: Encoding Graphs for Large Language Models. In *International Conference on Learning Representations*, 2024. URL https://research.google/pubs/talk-like-a-graph-encoding-graphs-for-large-language-models/.

[41] Zhibin Gou, Zhihong Shao, Yeyun Gong, Yelong Shen, Yujiu Yang, Nan Duan, and Weizhu Chen. CRITIC: Large language models can self-correct with tool-interactive critiquing. In *International Conference on Learning Representations*, 2024. URL https://arxiv.org/abs/2305.11738.

[42] Karthik Valmeekam, Matthew Marquez, Sarath Sreedharan, and Subbarao Kambhampati. On the planning abilities of large language models: A critical investigation. In *Advances in Neural Information Processing Systems*, 2023. URL https://arxiv.org/abs/2305.15771.

[43] Miles Turpin, Julian Michael, Ethan Perez, and Samuel R. Bowman. Language models don't always say what they think: Unfaithful explanations in chain-of-thought prompting. In *Advances in Neural Information Processing Systems*, 2023. URL https://arxiv.org/abs/2305.04388.

[44] Jie Huang, Xinyun Chen, Swaroop Mishra, Huaixiu Steven Zheng, Adams Wei Yu, Xinying Song, and Denny Zhou. Large language models cannot self-correct reasoning yet. In *International Conference on Learning Representations*, 2024. URL https://arxiv.org/abs/2310.01798.