Cloudra：面向自主反应机理探索的几何推理与科学有效性检验

杨程驿[1,*]、Qianxin Zhou[2]、李洋[1]

[1] 长沙理工大学化学与医药工程学院，长沙 410114，中国

[2] 福州大学化学学院，能源与环境光催化国家重点实验室，福州 350002，中国

[*] 通讯作者：杨程驿（Chengyi Yang）。电子邮箱：202509240114@csust.edu.cn。

工作审阅稿 — 2026 年 10 月 31 日

摘要

自主反应机理探索涉及提出化学假设、构造分子构型，以及判断计算实际确证了哪些物种和反应路径。将大语言模型（LLM）智能体从计算执行推进到这一科学研究过程，需要解决几何推理与机理判断的方法问题。

本文提出 Cloudra，一个以化学对象为核心开展反应机理探索的多智能体框架。按照“智能克制”的设计原则，具有拓扑感知能力的确定性算法建立分子身份与原子对应关系、构造分子构型，并将化学意图转化为几何操作。Delivery DAG 表示研究中的物种与基元反应步骤，将这些操作和量子化学计算组织为路径构建、比较与修订，并通过物理检验判断哪些机理归属得到支持。CloudraBench 用于衡量这套框架的端到端机理计算能力，包含 50 题，覆盖基元反应、多步机理、立体化学竞争及计算方法局限。四种工作流配置共完成 200 次运行，Cloudra 的平均综合得分为 0.793，同一模型的 Standard 基线为 0.581。在 Hard 任务中，平均得分由 0.689 提高至 0.958。40 道非 Impossible 任务中，Cloudra 的自洽性评分分量在 24 题达到满分，Standard 为 7 题。行为分析进一步考察显式几何测量与结构化结果关联怎样影响局部科学判断。

Cloudra 围绕机理问题结合几何推理、量子化学计算与物理检验，在自主研究过程中构建、比较和修订候选机理。

1 引言

1.1 自主反应机理研究的物理要求

有机反应机理的科学有效性检验，需要核对每个物种和基元步骤所对应的分子几何、反应路径与量子化学结果。几何优化正常终止（exit 0）并不能证明产物是稳定中间体；只有一个虚频，也不能单独确证结构是目标反应的一阶鞍点。IRC 若到达另一个解离产物或立体异构体，相应能量计算的机理归属也随之改变。包含多个基元步骤或竞争立体路径的研究，需要持续检查这些对应关系。[1, 2]

计算化学智能体已能自动执行其中的若干环节。El Agente Q [3]、Aitomia [4] 与 Gráfico [5] 编排量子化学计算及类型化工作流；Estructural [6] 与 ARCHE [7] 提供分子片段编辑、原子映射及过渡态几何准备工具；Quntur [8] 研究反应动力学与过渡态。将这些能力推进到自主机理探索，还需要可靠的几何操作，以及对计算所得物种和路径的物理解释。

立体取向对齐、反应片段装配与路径端点准备都涉及三维几何关系。语言模型在直接推断这些关系或操作笛卡尔坐标时可能出错。例如，Quntur [8] 报告复杂路径与过渡态准备需要人工协助端点对齐。因此，模型需要通过接口指定化学目标，并检查执行后的几何变化。

判断所提出的机理，需要确定计算所得物种与基元步骤的物理性质及连接关系。中间体应对应极小值，候选过渡态应为一阶鞍点，且其反应路径连接目标物种。这些科学判断决定计算实际说明了什么。自主探索方法需要在构型和候选路径变化时，持续将这些判断与机理问题联系起来。

1.2 Cloudra：以化学对象组织自主机理探索

Cloudra 是面向有机小分子反应机理探索的多智能体系统。语言模型提出机理假设、选择探索路径并分析计算问题；确定性程序维持原子与拓扑对应并执行局部几何操作；物理有效性检验则判断返回的结构、路径与机理结论是否满足任务的科学要求。

图 1展示 85 个化学 AI Agent 系统的结构化文献样本：材料或表面 39 项，有限分子或配合物 23 项，软物质或生物分子 12 项，另有 11 项展示多个对象类别。图 2和图 3展示有限分子或配合物类已记录的任务，并对比 Cloudra 与已有系统的能力覆盖。配套文献材料保留完整矩阵及逐项来源。

Cloudra 按照“智能克制”的设计原则，将几何计算和坐标变换交给确定性算子。最大公共子图（MCS）算法检索分子片段，原子映射与反应中心识别将拓扑连接到后续操作的坐标。测量算子返回键长、键角、二面角与立体特征；操作算子执行片段旋转、平移与过渡态装配。模型指定结构变换目标，检查测量变化，再选择下一构型，从而减少人工对齐端点的需要。

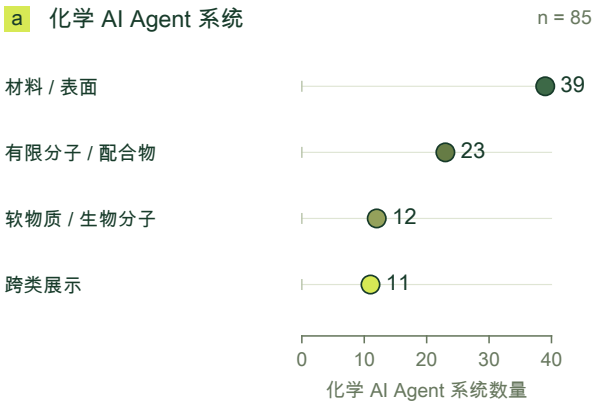


图 1. 85 个化学 AI Agent 系统的结构化文献样本：材料/表面 39 项、有限分子/配合物 23 项、软物质/生物分子 12 项、跨类系统 11 项。

Cloudra 通过以化学实体为中心的有向无环图（Delivery DAG）组织科学检验。物种与基元步骤为相应计算产物提供归属，步骤记录一阶鞍点和双向 IRC 等检验要求。图将机理主张绑定到用于判断的原始量子化学日志，Supervisor 对照任务契约审核结果，与程序化物理检验共同工作。即使模型提出结束请求，仍缺频率或路径支撑的步骤也保留为未确证。

1.3 主要贡献

Cloudra 围绕化学对象组织自主机理探索。Delivery DAG 将物种实例与基元反应步骤表示为研究对象。原子对应与拓扑感知几何算法将机理假设落实为分子构型，驻点和路径检验则判断计算实际支持哪些物种与反应步骤。这些具有明确化学含义的对象贯穿假设修订、竞争路径比较与研究完成判断。

确定性程序将分子身份与原子对应关系连接到几何操作和针对目标的测量。这些程序包括 MCS 拓扑映射、位阻图遍历及过渡态片段装配。语言模型调用它们探

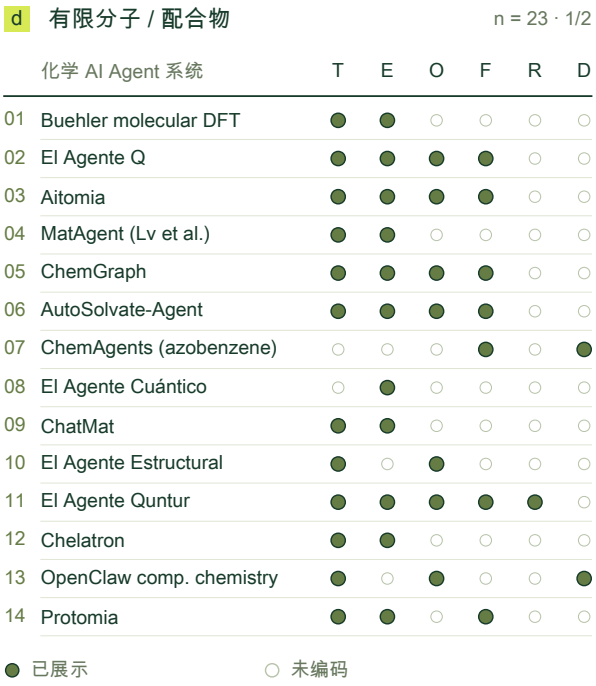


图 2. 有限分子/配合物类已记录的任务（第 1/2 面板，共 23 个化学 AI Agent 系统）。T：结构构建/编辑；E：静态能量/性质；O：几何优化；F：振动/热化学；R：显式路径/过渡态；D：分子/量子动力学。实心表示正面证据，空白表示未编码，不代表缺少能力。

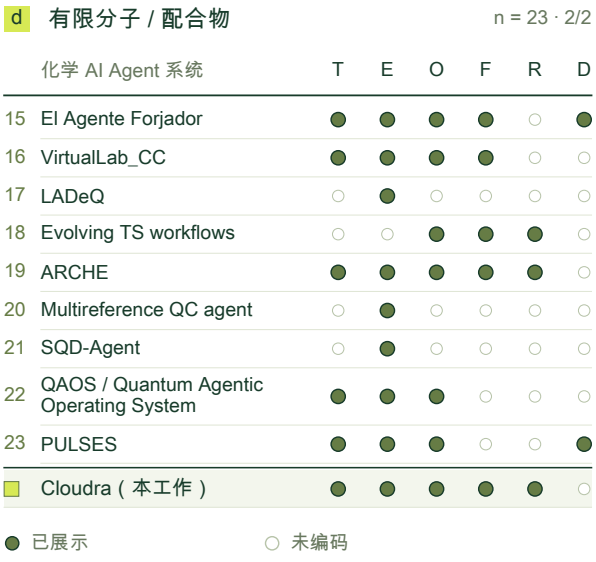


图 3. 有限分子/配合物类化学 AI Agent 系统任务续图（第 2/2 面板），代码同图 2，底端展示 Cloudra（本工作）的能力覆盖。全部 85 个化学 AI Agent 系统的完整矩阵及逐项来源限制见配套材料。

索化学假设、比较竞争通道并在自主过渡态搜索中修订失败的计算尝试。

CloudraBench 用于衡量这套方法的端到端机理计算能力，依据原生计算产物评价图结构覆盖、物理自洽性和任务规定目标的准确度。50 题涵盖基元与多步反应、立体化学及允许方法的适用边界。实验包括四题三次重复的 48 次运行，以及覆盖 50 题、四种配置的 200 次全基准运行。主要比较采用同一模型主干的 Standard，Record 与 Brief-errors 分析证据组织和诊断反馈的作用。

2 系统设计与方法

2.1 系统全貌与职责划分

Cloudra 根据规定的反应条件与计算要求，通过构造候选分子构型、寻找和表征驻点、追踪基元反应路径及比较竞争通道研究反应机理。Delivery DAG 表示研究中的化学物种与基元反应步骤；原子映射、几何算子和量子化学检验共同保证这些对象在构型变化与机理假设修订过程中保持一致。

系统的多智能体角色按职责划分协作。协调智能体负责构思机理假说、提出候选基元反应步，并维护探索分支。计算智能体负责执行具体的基元反应步，调用几何算子构建三维构型并调度底层量子化学计算。当底层计算遭遇几何发散、鞍点优化失败或产物漂移等阻碍时，计算智能体结合结构化诊断反馈，评估当前反应步是否合理；若认为当前步骤难以走通，则向协调智能体反馈诊断信息，交由协调智能体调整机理假设或切换分支。督导智能体独立对照任务要求审阅交付图及提交的证据，其审阅意见与计算产物解析出的事实分别保存。

2.1.1 异步计算调度与资源管理

计算调度底座通过中央计算账本数据库（`ComputeDB`）对作业全生命周期实施状态化管理。系统在本地多进程、远程 SSH 集群及 Slurm 超算节点之间建立独立的容量池，依据预设的硬件并发配额实施排队，防止跨节点溢出。在分发作业前，调度器基于分子的三维坐标、自旋电荷以及量化方法指令生成不可变的 SHA-256 内容哈希；对于已完成或处于运行态的相同作业复用其计算产物，实现任务提交的去重。底层进程的状态通过操作系统的文件排他锁（`flock`）进行跟踪，在监控与异常处理链路中不终止持有排他锁的底层量子化学进程。计算智能体与调度底座之间采用事件驱动方式交互，作业结束时由调度器派发通知，智能体异步读取计算产物，避免同步轮询。

2.2 分子表征与几何算子

系统中的三维分子输入由属性图 $H = (A, B)$ 以及 Cartesian 坐标矩阵 $\mathbf{X} \in \mathbb{R}^{n\times 3}$ 共同表征。其中 A 为原子集合，B 为化学键集合，$\mathbf{X}$ 的每一行对应一个原子的空间三维坐标。原子与化学键的属性编码其固有化学身份；坐标算子更新 $\mathbf{X}$ 并返回测得的几何变化量；涉及原子替换或官能团修饰的算子同步更新拓扑图 H。

2.2.1 原子对应关系与反应中心感知

原子属性显式保留元素种类、同位素标号、形式电荷、显式氢数、自由基电子数以及声明的手性立体构型；化学键属性保留键级与顺反立体构型。缺失三维坐标的分子组分由 ETKDGv3 算法生成初始三维构象 [9–11]，多组分体系分别构建后执行空间对接，已有坐标予以保留。两端均具有完整且唯一的原子映射标号时，直接依据标号确定对应关系（要求两端元素与同位素严格一致）。未提供标号时，设产物与反应物的重原子集合

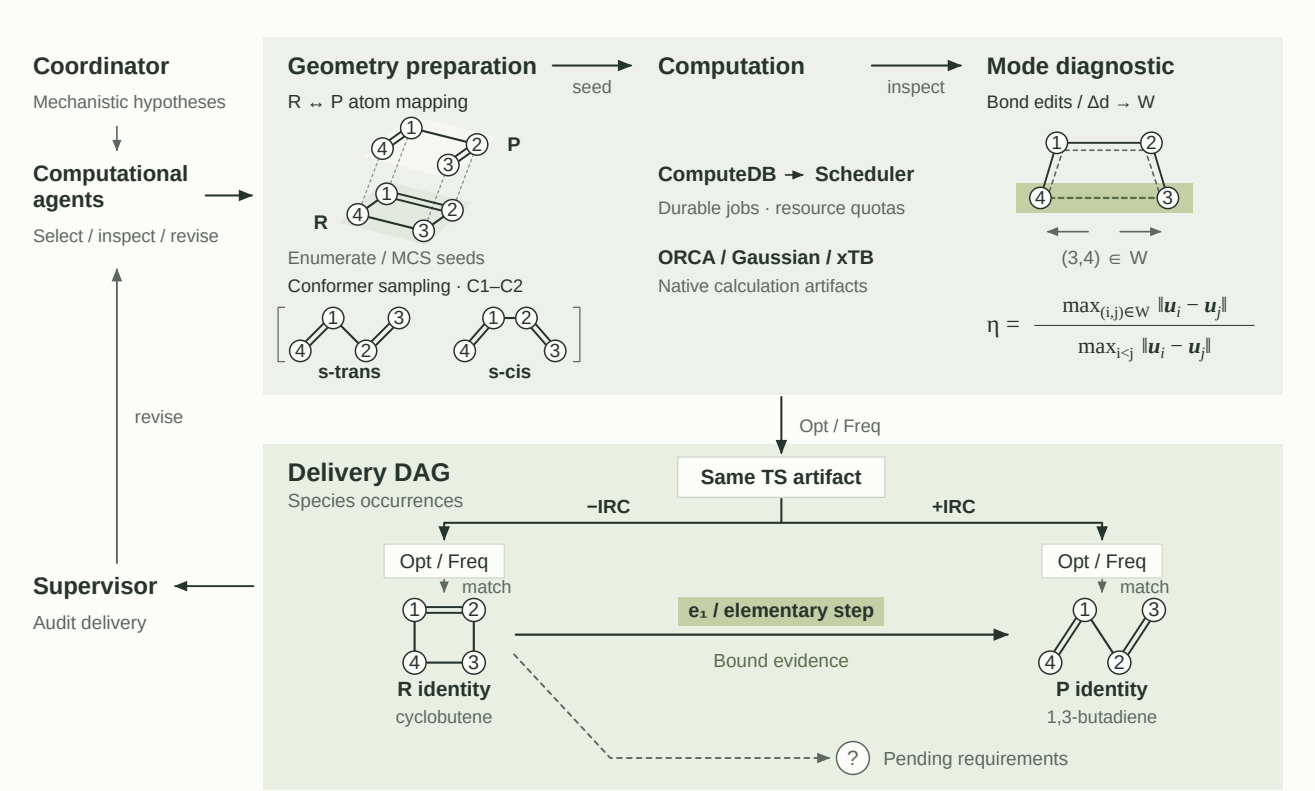


图 4. Cloudra 的机理探索与证据组织流程。几何准备建立反应物与产物的原子映射并采样构象，ComputeDB 与调度器管理计算。振动模式诊断辅助检查监测原子对的运动。同一过渡态计算产物的双向 IRC、端点优化与频率分析以及身份匹配，为交付 DAG 提供证据。监督智能体审查图并反馈未满足的要求以供修订。

分别为 A_{P} 与 A_{R}，在保持元素与同位素守恒的候选双射 $\pi : A_{\mathrm{P}} \to A_{\mathrm{R}}$（满足 $z_i^{\mathrm{P}} = z_{\pi(i)}^{\mathrm{R}}$ 且 $\iota_i^{\mathrm{P}} = \iota_{\pi(i)}^{\mathrm{R}}$）中进行搜索，并依据如下目标函数对候选映射进行打分：

$$J(\pi) = 2(N_{\mathrm{f}} + N_{\mathrm{b}}) + N_{\mathrm{o}} + 4\Delta_H + 8\Delta_q + 8\Delta_r + 2N_{\mathrm{s}}. \tag{2.1}$$

令 B_{P}^{π} 表示以反应物原子编号表示的产物化学键集合。成键与断键分别是集合差 $B_{\mathrm{P}}^{\pi} \setminus B_{\mathrm{R}}$ 与 $B_{\mathrm{R}} \setminus B_{\mathrm{P}}^{\pi}$，对应基数分别为 N_{f} 与 N_{b}。N_{o} 统计 $B_{\mathrm{P}}^{\pi} \cap B_{\mathrm{R}}$ 中键级改变的键对数。对于 $a \in \{H, q, r\}$，环境差量定义为 $\Delta_a = \sum_{i \in A_{\mathrm{P}}} |a_i^{\mathrm{P}} - a_{\pi(i)}^{\mathrm{R}}|$，分别度量原子显式氢数、形式电荷与未配对电子数的变化。N_{s} 统计立体化学环境的不一致数：单一声明的四面体中心不匹配增加惩罚 2；当两端对应原子均声明立体标签时，算法要求其具备四个匹配邻居（含必要氢原子），并在比较标签前校正邻居排序的置换奇偶性；非可比的立体环境不计入惩罚。

对于各元素同位素等价类（大小记为 n_g），全排列空间大小为 $N_{\Pi} = \prod_g n_g!$。当 $N_{\Pi} \le 10^5$ 时，算法遍历全部双射；超过该阈值时，以最大公共子图（MCS）作为种子扩展映射，要求元素严格匹配、放开键级限制并强制保留完整环结构 [11]。MCS 搜索超时时间为 10 秒，每个端点最多贡献 64 个子图匹配。未匹配原子按氢数、连接度及输入序号在同类原子中排序配对。算法合并具有相同编辑事实和得分的映射，保留字典序最小的代表；候选按得分与映射序列升序排序，前 16 个代表构成重原子候选集 C。对于非空集合 C，定义最优得分 $J_{\min} = \min_{\pi \in C} J(\pi)$ 以及容差集合 $\mathcal{N} = \{\pi \in C : J(\pi) \le J_{\min} + 2\}$。当 $|\mathcal{N}| = 1$ 时映射确定为唯一最优；$|\mathcal{N}| > 1$ 时标记为歧义候选；$C = \emptyset$ 时判定为无解。

保留的重原子候选映射进一步扩展至全原子对应关系。系统优先保留端点已有的显式氢标号，剩余同位素氢原子在对应的重原子上进行同位素分组配对。未匹配氢原子组（大小为 h_g）的置换空间 $N_H = \prod_g h_g!$ 在 $N_H < 257$ 时执行完全枚举；超出该范围时若缺乏相容的显式氢标签则判定为排列爆炸。全原子映射经过去重、排序，并依据相同的 $+2$ 容差规则评估歧义性。选定的全原子双射将产物原子重新排列至与反应物严格对齐的原子序号顺序。反应映射输出的成键与断键原子对构成反应中心监控集合，用于后续内禀坐标与路径插值监测；键级改变记录于变换后的拓扑图中。

2.2.2 结构测量与刚体变换算子

空间几何感知将三维坐标转换为键长、键角、二面角、环构象以及空间近邻接触。对于坐标 $\mathbf{x}_i$，原子间距为 $d_{ij} = \|\mathbf{x}_j - \mathbf{x}_i\|$；以原子 j 为顶点的键角由两条成键单位向量的内积反余弦求得。测量所得键长与参考标准共价半径及范德华接触距离的对比构成几何畸变诊断，同时分子拓扑图维持既定化学身份。纯坐标输入在系统入口处完成成键拓扑感知；后续局部坐标变换沿用该拓扑骨架，并在变换前后测量几何异常。

对于非环单键两侧的分子片段选择，系统通过图连通性自动解析：临时切断指定键 $a - b$，选取包含原子 b 的连通子图 $\mathcal{F}_b$。若切除该键后两端依然连通（处于环体系内部），则要求显式传入移动原子列表。记移动原子集合为 $\mathcal{F}$（由显式指定或切键提取的 $\mathcal{F}_b$ 构成）。将移动片段绕指定空间轴旋转时，对集合内所有原子 $i \in \mathcal{F}$ 应用 Rodrigues 旋转公式：

$$\begin{aligned} \mathbf{x}_i' &= \mathbf{a} + \mathbf{R}(\hat{\mathbf{u}}, \theta)(\mathbf{x}_i - \mathbf{a}), \\ \mathbf{R} &= \cos\theta\, \mathbf{I} + (1 - \cos\theta)\hat{\mathbf{u}}\hat{\mathbf{u}}^{\mathsf{T}} \\ &\quad + \sin\theta\, [\hat{\mathbf{u}}]_{\times}. \end{aligned} \tag{2.2}$$

式中 $\mathbf{a}$ 为旋转轴上基准点，$\hat{\mathbf{u}}$ 为轴的单位方向向量，θ 为旋转角度，$\mathbf{I}$ 为三阶单位矩阵，$[\hat{\mathbf{u}}]_\times \mathbf{v} = \hat{\mathbf{u}} \times \mathbf{v}$ 为反对称叉乘算子。移动片段之外的原子坐标保持不变。沿指定键 $a-b$ 伸缩距离时，将片段 $\mathcal{F}_b$ 整体平移：

$$\mathbf{x}_i' = \mathbf{x}_i + (L - d_{ab})\frac{\mathbf{x}_b - \mathbf{x}_a}{d_{ab}}, \qquad i \in \mathcal{F}_b. \tag{2.3}$$

式中 L 为目标平衡键长。手性反转算子通过围绕立体中心协同旋转两个可分离分支以调换空间取向。基团取代算子切除指定侧片段，将携带对接位点的新官能团沿原始成键方向组装，并同步更新拓扑图。在量子化学优化前后对比结构时，系统在一致的元素序列下对基于截断半径感知的连接集合进行差分，解析内部键联与片段间接触的产生与断裂。

2.2.3 分支拥挤描述符与反应物预组织

对于通过了杂化轨道、非环结构及取代基拓扑不等价性筛查的候选旋转轴，系统采用基于图深度指数衰减的分支拥挤描述符提取局部空间位阻特征：

$$B_s = \sum_{k \in T_s} c_k r_k \rho^{\ell_k}, \qquad \rho = 0.5, \quad 0 \le \ell_k \le 5. \tag{2.4}$$

式中 r_k 为原子 k 的范德华半径，用于衡量各原子的固有空间占位。遍历树 T_s 通过后进先出（LIFO）深度优先遍历生成，以取代基根原子为深度 0 起点，并将旋转轴另一端原子预先标记为已访问。弹出未访问原子时记录其搜索深度 ℓ_k，并在 $\ell_k < 5$ 时将其未访问邻居按拓扑顺序压栈。权重系数 c_k 在根原子图连接度大于等于 3 时取 1.5，其余原子取 1.0。

该描述符采用标准范德华半径标度（Å）：H 1.20, B 1.92, C 1.70, N 1.55, O 1.52, F 1.47, P 1.80, S 1.80, Cl 1.75, Br 1.85, I 1.98（未列出元素统一采用 1.70）。将旋转轴两侧四个取代基分支计算得出的 B_s 值四舍五入保留三位小数并求和，其总和记为 B_{axis}；当 $B_{\text{axis}} \ge 9.0$ 时，该键被标记为拥挤轴，供后续构象探查参考。

在多组分反应物预组织中，主反应组分固定于坐标原点，其余反应物分子绕各自质心在三维空间中进行取向采样。在 K 个采样点下，第 s 个采样方向为：

$$\begin{aligned} \hat{\mathbf{u}}_s &= (a_s \cos s\gamma,\, y_s,\, a_s \sin s\gamma), \\ a_s &= \sqrt{1 - y_s^2}, \qquad y_s = 1 - \frac{2s}{K-1}, \\ \gamma &= \pi(3 - \sqrt{5}). \end{aligned} \tag{2.5}$$

其中参数 $\gamma = \pi(3-\sqrt{5}) \approx 2.3999$ rad（约为 137.5°）为黄金角，对应斐波那契球面螺旋分布；绕 $\hat{\mathbf{u}}_s$ 轴的自旋角取 $2\pi s/K$（默认采样 $K = 32$）。沿组分质心向量平移以消除原子重叠冲突。对于显式指定的引导原子对集合 W 及其目标距离窗口 $[l_{ij}, u_{ij}]$，构型 $\mathbf{X}$ 的违背惩罚评分为：

$$\begin{aligned} S(\mathbf{X}) = \max_{(i,j)\in W} \{0,\, l_{ij} - d_{ij}(\mathbf{X}), \\ d_{ij}(\mathbf{X}) - u_{ij}\}. \end{aligned} \tag{2.6}$$

选出的低惩罚构型作为初始种子，在距离谐振子势能约束下进行受限 MMFF94 力场优化 [12]，引导分子片段松弛至目标距离窗口内。合格构型需满足力场收敛、距离落入窗口、立体构型守恒以及多组分接触连通性条件 $d_{i^*j^*} \le 1.7(r_{i^*} + r_{j^*})$。合格构型按无约束力场单点能排序，并采用 0.5 Å 的重原子 Kabsch RMSD 阈值聚类去重，生成预组织初始构型集合。

2.2.4 端点刚体对齐与 IDPP 路径插值

在全原子拓扑对应确立后，两端构型平移至各自坐标原点。令 $\mathbf{P}$ 与 $\mathbf{R}$ 分别为中心化后的产物与反应物坐标矩阵，Kabsch 最小二乘刚体旋转 [13] 求解如下正交变换：

$$\begin{aligned} \min_{\mathbf{Q}^{\mathsf{T}}\mathbf{Q}=\mathbf{I},\det\mathbf{Q}=1} \|\mathbf{P}\mathbf{Q} - \mathbf{R}\|_{\mathrm{F}}^2, \\ \mathbf{P}^{\mathsf{T}}\mathbf{R} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^{\mathsf{T}}, \\ \mathbf{Q} = \mathbf{U}\,\mathrm{diag}\big(1, 1, \det(\mathbf{U}\mathbf{V}^{\mathsf{T}})\big)\mathbf{V}^{\mathsf{T}}. \end{aligned} \tag{2.7}$$

求得的 $\mathbf{Q}$ 即为消除整体平动与转动后的纯刚体旋转矩阵。公式中对角项引入行列式因子 $\det(\mathbf{U}\mathbf{V}^{\mathsf{T}})$，使 $\det\mathbf{Q} = +1$，排除镜像反射并保持手性构型一致。

对于包含端点在内的 M 个路径插值镜像帧，定义进度参数 $\lambda_k = k/(M-1)$，并初始化线性内插坐标 $\mathbf{X}_k = (1-\lambda_k)\mathbf{R} + \lambda_k \mathbf{P}\mathbf{Q}$。基于图像的双原子势能（IDPP）算法 [14] 在内坐标距离空间中对原子对距离进行线性插值（$d^*_{ij,k} = (1-\lambda_k)d^{\mathrm{R}}_{ij} + \lambda_k d^{\mathrm{P}}_{ij}$），其目标泛函定义为：

$$\begin{aligned} d^*_{ij,k} &= (1-\lambda_k)d^{\mathrm{R}}_{ij} + \lambda_k d^{\mathrm{P}}_{ij}, \\ V_k &= \sum_{i<j} \frac{(d_{ij,k} - d^*_{ij,k})^2}{d^4_{ij,k}}. \end{aligned} \tag{2.8}$$

该泛函的分母引入距离负四次方权重 $d_{ij,k}^{-4}$，使短程成键区域具有较高的刚性恢复力，优先保持化学键尺度，同时允许长程非键相互作用松弛。标准模式将中间镜像帧通过改进切线法弹性带（NEB）弹簧耦合，并利用 MDMin 算法执行能量最小化，以移动原子受力的最大残差评估收敛性 [15, 16]；轻量模式则将分母设定为 $\max(d^*_{ij,k}, 0.1\,\text{Å})^4$，使用 Adam 优化器对各个中间镜像帧独立进行几何松弛。[17]

动态监控原子对集合 W 自动提取反应映射中的成断键对、两端成键但键长变化 $|\Delta d| \ge 0.15$ Å 的键对，以及两端距离变化最大的前 5 对原子。在集合 W 中，算法选取距离变化最大的主反应坐标 $p^* \in \mathrm{argmax}_{p\in W} |d^{\mathrm{P}}_p - d^{\mathrm{R}}_p|$，计算中点距离 $m = (d^{\mathrm{R}}_{p^*} + d^{\mathrm{P}}_{p^*})/2$。初始过渡态初猜选取首个跨越中点的镜像帧 k（满足 $(d_{p^*,k} - m)(d^{\mathrm{R}}_{p^*} - m) \le 0$），或与中点距离偏差最小的帧。提取出的三维构型直接作为后续一阶鞍点优化的输入种子。

2.3 证据图谱与科学校验门禁

2.3.1 物种实体与阶段证据契约

交付证据图定义为有向无环图 $G = (V, E)$，其中节点 $v \in V$ 代表化学物种的具体发生实体（Species Occurrence），有向边 $e = (v_i, v_j) \in E$ 代表基元反应转化步骤。映射函数 $\kappa : V \to \mathcal{S}$ 将每个发生实体映射至其规范化学身份，允许催化循环中初始催化剂与再生催化剂作为共享同一化学身份的独立拓扑节点存在。稳定点几何、振动频率与绝对能量绑定至物种节点；过渡态构型、虚频振动向量与反应路径绑定至反应步骤边。

每个图元素承载声明式的阶段契约集合 K。基元反应步默认要求 $K = \{\text{ts_opt}, \text{frequency}, \text{short_irc}\}$ 阶段链，并可依据任务要求追加热力学校正。底层计算日志以内容哈希摘要的形式归档。解析事实表示为四元组 $f = (c, o, r, d)$，其中 c 为检查项，$o \in \{+, -, ?\}$ 分别代表支持、矛盾或未定，r 为溯源引用索引，d 记录提取出的数值度量。

对于声明了显式必需事实检查 R 和可选检查 O 的任务，针对目标实体 t 关联事实集合 F_t 的科学证据通过判据定义为：

$$
\begin{aligned}
S_t = \mathbf{1}[R \neq \emptyset] \\
\wedge \bigwedge_{c \in R} \mathbf{1}[\exists f \in F_t : f.c = c,\, f.o = +] \\
\wedge \mathbf{1}[\nexists f \in F_t : f.c \in R \cup O,\, f.o = -].
\end{aligned} \tag{2.9}
$$

当 $R \neq \emptyset$ 时，任何必需项缺失或存在矛盾项均使 S_t 判定为假；当 $R = \emptyset$ 时，事实层检查跳过，证据审查由阶段链检验完成。

2.3.2 势能面曲率与简正振动模式对齐诊断

驻点的物理曲率性质由质量加权黑塞矩阵（Hessian）决定：

$$
\begin{aligned}
\mathbf{H}_{\mathrm{mw}} &= \mathbf{M}^{-1/2} \nabla_{\mathbf{x}}^2 U\, \mathbf{M}^{-1/2}, \\
\mathbf{H}_{\mathrm{mw}} \mathbf{v}_k &= \lambda_k \mathbf{v}_k .
\end{aligned} \tag{2.10}
$$

在消除平动与转动自由度的振动子空间内，负本征值 $\lambda_k < 0$ 对应虚频 $\nu_k < 0$。虚频总数统计为 $n_{\mathrm{imag}} = \sum_k \mathbf{1}[\nu_k < 0]$。基态反应中间体要求 $n_{\mathrm{imag}} = 0$；一阶鞍点要求 $n_{\mathrm{imag}} = 1$。

溯源校验机制核验振动频率计算的初始几何构型与鞍点优化收敛构型是否一致。对于中心化后的坐标矩阵 $\mathbf{X}$ 与 $\mathbf{Y}$，几何匹配要求满足 $\delta_\pi(\mathbf{X}, \mathbf{Y}) = \max_i \|\mathbf{Y}_{\pi(i)} \mathbf{Q}_\pi - \mathbf{X}_i\| \leq 3 \times 10^{-6}$ Å，该式遍历所有元素守恒的原子置换映射 π 与最佳 Kabsch 旋转矩阵 $\mathbf{Q}_\pi$ 进行判定。

对于满足一阶鞍点且具有唯一虚频位移向量 $\mathbf{u}$ 的过渡态，振动模式对齐诊断比较监控反应中心原子对 W 中最大的相对位移幅度与所有原子对中的最大值：

$$
\eta = \frac{\max_{(i,j) \in W} \|\mathbf{u}_i - \mathbf{u}_j\|}{\max_{i<j} \|\mathbf{u}_i - \mathbf{u}_j\|}. \tag{2.11}
$$

诊断量 $\eta \in [0, 1]$ 衡量反应中心原子对相对全局最大原子对位移的参与程度，比较比值为 0.5，可提示甲基摇摆或溶剂运动等旁观模式。对齐标记只提供诊断建议；科学检验依据一阶鞍点要求及同一 TS 的双向 IRC 和端点优化/频率证据链。

2.3.3 内禀反应坐标（IRC）方向与端点一致性

内禀反应坐标（IRC）是在质量加权坐标 $\mathbf{q} = \mathbf{M}^{1/2}\mathbf{x}$ 下从过渡态出发的最陡下降路径 [1, 2]：

$$
\begin{aligned}
\frac{\mathrm{d}\mathbf{q}_\pm}{\mathrm{d}s} &= -\frac{\nabla_{\mathbf{q}} U}{\|\nabla_{\mathbf{q}} U\|}, \\
\mathbf{q}_{\mathrm{init},\pm} &\approx \mathbf{q}_{\mathrm{TS}} \pm \epsilon \mathbf{v}_- .
\end{aligned} \tag{2.12}
$$

系统检查 IRC 积分起始帧与过渡态几何的一致性，并分别提取正反两个积分方向上的最外侧末端帧。对于闭环反应基元步，以两侧最外侧末端帧作为初始坐标分别进行无约束几何优化，核验优化收敛构型具备零虚频（$n_{\mathrm{imag}} = 0$），且化学结构与声明的反应物和产物在分子拓扑与立体构型上一致（通过规范异构 SMILES 比对）。

对于产物发生解离的多组分反应步，解离生成的产物分子分别独立优化收敛至零虚频稳定极小值。路径方向性通过反应物侧的距离区间断言进行裁定。在监控原子对集合 W 上，设过渡态、IRC 外侧末端帧及反应物参考构型的距离向量分别为 $\mathbf{q}_{\mathrm{TS}}$、$\mathbf{q}_{\mathrm{E}}$ 与 $\mathbf{q}_{\mathrm{R}}$。取共价截断半径 $c_{ij} = 1.25(r_i + r_j)$ 及容差 $\tau = 0.10$ Å，定义共价集合 $W_{\mathrm{c}} = \{(i,j) \in W : d_{ij}^{\mathrm{R}} \leq c_{ij}\}$ 以及边界区间 $[a_p, b_p] = [\min(d_p^{\mathrm{TS}}, d_p^{\mathrm{R}}) - \tau, \max(d_p^{\mathrm{TS}}, d_p^{\mathrm{R}}) + \tau]$。布尔断言 is_between 要求满足 $\|\mathbf{q}_{\mathrm{E}} - \mathbf{q}_{\mathrm{R}}\|_2 < \|\mathbf{q}_{\mathrm{TS}} - \mathbf{q}_{\mathrm{R}}\|_2$ 且 $a_p \leq d_p^{\mathrm{E}} \leq b_p$ 对所有 $p \in W_{\mathrm{c}}$ 均成立。解离型产物通道需同时满足产物极小值确证与 is_between 判定。

2.3.4 证据汇总与定量能垒

对于基元反应步 e，设 K_e 为该步骤声明的法定强制科学阶段集合。阶段验证指示变量 $P_{e,k} = 1$ 表示阶段 k 绑定的原生计算证据已通过该阶段的核验（未通过则为 0）。该步骤的阶段链完备性条件定义为：

$$
A_e = \bigwedge_{k \in K_e} P_{e,k}. \tag{2.13}
$$

当任务显式声明属性检查集合 R 时，该步骤的完全交付要求 $A_e \wedge S_e$ 成立。阶段状态通过显式状态枚举（支持、待决、跳过、拒绝）记录，使方法学不可达声明或豁免与实际完成的物理证据在账本中区分开来。

电子活化能垒由驻点能量差计算：

$$
\Delta E_e^{\ddagger} = E_{\mathrm{TS},e} - E_{\mathrm{ref},e}. \tag{2.14}
$$

所用能量来源于相同的量子化学方法与基组级别。对于热力学性质，零点能校正、焓变与 Gibbs 自由能校正在指定温度与压强下基于谐性配分函数提取。

2.4 引导式诊断与自愈恢复

系统将计算问题区分为执行错误、数值不收敛和物理证据问题。执行错误包括输入语法、环境或解析问题；数值状态记录 SCF 与几何优化收敛；物理检查核对驻点曲率、IRC 端点和化学身份。虚频模式参与程度及几何区间检查作为诊断建议，帮助选择需要检查或修订的对象。

设 T 为任务声明的目标物种与反应步集合。将 $P_{e,k}$ 推广至任意目标对象 $t \in T$，未满足的科学证据契约集合形式化为：

$$
U = \{(t,k) : t \in T,\, k \in K_t,\, P_{t,k} = 0\}. \tag{2.15}
$$

集合 U 记录智能体在当前探索轮次中的待决目标。结构化诊断反馈将 U 中未满足的项对应至底层的 SCF 发散、虚频模式失配、IRC 证据链断裂或产物拓扑不符等具体原因。计算受阻时，系统保留历史计算产物，并在状态机中更新 U，向智能体提供关于几何与计算状态的信息以供调整。

恢复时保留历史尝试与原始计算日志，受影响的下游依赖阶段重新排队。原子编号重排、证据挂载与图状态迁移由底层状态机处理，智能体可据此调整二面角约束、修改反应构型假设或切换电子结构方法。

2.5 实施默认参数

本文描述的系统实现基于 Cloudra 提交版本 70daa5a。[18] 数值数组与线性代数运算使用 NumPy[19]；量子化学数值提取由 cclib 与各引擎的原生日志读取逻辑共同完成 [20]；Benchmark 图表示与匹配使用 NetworkX[21]。反应物预组织中多组分球面采样取 32 个刚体旋转方向，保留至多 8 个引导对接构型，组分间最小初始间距 1.0 Å，分子接触截断乘子 1.7，重原子 RMSD 聚类阈值 0.5 Å。MMFF94 距离约束力场松弛每阶段上限 2000 步，距离谐振子力常数设为 100.0。路径插值中标准 IDPP 默认采用 10 个图像帧，使用 MDMin 算法松弛（上限 100 步，受力容差 $f_{\max} = 0.1$，NEB 弹簧系数 $k = 0.1$）；轻量 IDPP 采用 Adam 优化器（上限 4000 步，步长 0.02，

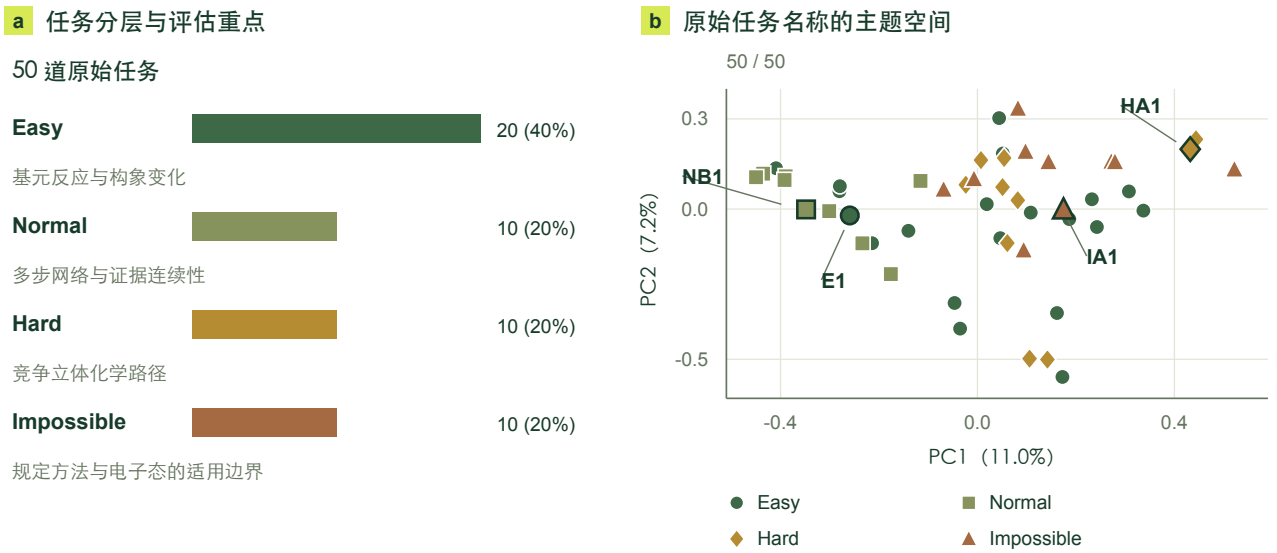


图 5. CloudraBench 的任务组成与研究主题。a，四档任务的数量及评估重点。b，50 道原始任务名称的 BAAI/bge-m3 嵌入 [22] 使用 scikit-learn[23] 进行主成分分析得到的二维投影，E1、NB1、HA1 和 IA1 为重复实验采用的四题。颜色和点形表示预先规定的任务类别。

梯度容差 10^{-7}）。路径收敛性由中间镜像帧的最大受力残差判定。

原子映射系数及 $J_{\min}+2$ 歧义窗口是固定的候选排序启发式。电荷与自由基不匹配的代价高于氢数和键编辑不匹配。支链拥挤度使用衰减 $\rho = 0.5$、遍历至深度五和 $B_{\text{axis}} \geq 9.0$ 标记；模式参与诊断的比较比值为 0.5。这些参数用于候选排序或诊断，驻点及路径证据决定科学检验。

Cloudra 的构象搜索工具提供 RDKit 和外部 CREST 后端。[24] 上述默认预组织使用刚体放置、受限 MMFF94 松弛及聚类；需要时可请求 CREST 进一步搜索构象或非共价复合物，再进行量子化学优化与物理检验。

2.6 CloudraBench 基准构建与实验设计

2.6.1 任务覆盖与分层依据

CloudraBench 包含 50 题：Easy 20 题检验基元转化、构象变化与基础执行可靠性；Normal 10 题检验中间体识别和多步衔接；Hard 10 题检验竞争通道与立体身份；Impossible 10 题检验允许方法下的适用边界与可信否定（图 5）。Easy 的较大样本用于展开基础化学覆盖，其余三类各自保留独立检验。化学类别与研究要求交叉设置，同类反应可因通道、构型或电子态要求而跨层出现。选题兼顾判别价值与可计算性，结合文献依据和参考计算筛选，不以反应名称直接替代难度定义。逐题任务名称、输入条件和允许方法列于配套任务清单。

2.6.2 参考答案与评价口径

每题固定化学条件、电荷、自旋、交付目标和方法范围。Easy、Normal 和 Hard 任务允许 xTB[25]、PM7[26] 与 B3LYP-D3(BJ)/def2-SVP[27–32]，Impossible 任务限于 xTB 与 PM7；计算证据读取 ORCA、Gaussian 或 MOPAC 原生日志。[33–36] 参考答案包含物种、基元步、立体身份及适用的数值或否定目标。数值参考按同一方法下的纯电子能差登记，稳定极小值参照与真实 IRC 连接分别核验。对要求验证的可达反应步，TS 频率、双向 IRC、末帧来源和端点优化/频率构成证据链；物种性质和电子态问题则按其指定目标核验。

图结构、自洽性与准确度分别评价，综合权重为 0.1、0.3 和 0.6；分级物理支持程度与运行期交付完整性分别报告。正确识别方法限制的负例不要求虚构能垒。

各题参考答案的证据完整性、特别处理和保留项单独记录，参考图是否存在与科学验证是否完整分别判断。

2.6.3 重复实验、主对照与工作流消融

重复任务研究（P1b）比较 E1、NB1、HA1 与 IA1 在 Guided、Standard、Record 和 Brief-errors 四配置下的表现，每种题目与配置组合独立运行三次，共 48 次任务运行。重复实验使用 DeepSeek-v4.1-flash（1017）。[37] 四题分别涉及消除预组织、多步脱羧、立体化学开环及电子结构方法边界，其轨迹用于后续局部诊断。耗时单位为并发二、四题一批的实际批次，每配置三批。全基准研究（P2）保留 50 题、四配置各一次运行，共 200 次任务运行。全部 P2 配置均通过 DeepSeek 官方端点的流式 OpenAI 兼容 chat completions 接口调用 DeepSeek-v4.1-flash（1017），归档 API 别名为 `deepseek-v4-flash`，请求 minimal 推理设置；冻结配置与实际请求/完成记录中的模型标识一致。主比较为使用同一主干的 Guided 与 Standard，后者在图中标记为 Backbone。P1b 与 P2 是重复任务及全基准研究沿用的归档标识。P2 执行版本和请求设置见 SI 第 S1 节。

Standard 隐藏显式 DAG 工具、取消物理检验约束并提供中性计算反馈；Guided 保留研究图、科学检查与详细诊断。Record 保留可用工具和记录而不再要求物理检验；Brief-errors 保留引导而缩短诊断。各配置采用相同题目与方法限制，运行版本、预算、结束原因及产物来源保留在档案中。

正式评价先将各次运行已有的研究记录标准化为统一机理图。人工整理依据该次对话、工具记录、报告及计算产物，忠实编码 Agent 已表达的机理意图和结论，恢复图对象与文件引用，并保留逐字段来源。评分器在同一次运行的沙箱中搜索原生计算证据，应用统一评分规则。整理不新增计算或科学结论，Gold 用于提供评价目标。最终数据包含全部 200 次运行，每项综合分均列出对应的 Graph、自洽性和 Accuracy。逐题配对差及 95% 百分位区间采用 100,000 次任务簇 bootstrap，同一任务的四配置始终一起抽样，随机种子为 20261031。计算投入取深挖档案中四组共同的 15 道选定任务，报告量子化学作业数和累计 job-hours，并与先导实验的批次实际耗时分别呈现。

3 结果与讨论

3.1 端到端基准评估

CloudraBench 衡量端到端机理计算能力：构建候选机理、完成所需量子化学计算，并得出符合任务要求的正结论或负结论，其中包括判断允许方法下目标的物理存在性。下文报告最终整理后的综合分及图结构、自洽性与准确度分量。离线整理从每次运行自身的研究材料组装机理图，并关联该运行已有的评分记录，得到 200 次运行全部三项分量与综合分，整体均分为 0.7051。图 6至图 10据此区分最终交付、单项计算获得的科学支撑，以及结果与任务答案之间的对应关系。

3.1.1 相对同一 backbone，Cloudra 提高了研究交付质量

Guided 的综合均分为 0.7930，Standard 为 0.5814。50 道题逐题配对的平均增益为 0.2116，95% 任务 bootstrap 区间为 [0.1290, 0.2985]。Guided 在 36 题中更高、7 题中更低、7 题持平，配对差值的中位数为 0.1142（图 6）。差异因此出现在多个研究问题中，而非仅由最高分运行的少量提升形成。

各组最低分十题的均值也有差别：Guided 为 0.3221，Standard 为 0.0930。

最一致的改善出现在 Hard 立体化学任务。Guided 均分为 0.9577，Standard 为 0.6888，配对增益为 0.2689 [0.1213, 0.4459]，十题中 Guided 全部更高。这些任务要求系统持续区分相互竞争的构型或通道，比较相应能垒，并将支持证据关联至对应结论。观察到的改善因此体现为一项比较性化学研究的完成质量，包括支撑立体化学判断的计算证据组织。

Normal 任务中，Guided 均分为 0.7370，Standard 为 0.5731，增益 0.1640 [0.0365, 0.2922]，7 题更高、3 题更低。Easy 均分分别为 0.9125 和 0.6989，但配对差值中位数为 0.0500，其分布与 Hard 中广泛为正的改善不同。Impossible 均分分别为 0.4451 和 0.2473；这组分数取决于运行是否回答了题目所要求的方法受限负结论，因而在后文单独分析。

3.1.2 分量增益主要体现为计算证据的闭合

拆开三项分数，可以定位工作流在哪一层出现差异（图 7）。Graph 衡量交付物中所要求物种与步骤的覆盖及身份；Self-consistency 衡量鞍点、频率、IRC 起点与端点优化/频率之间的支持关系；Accuracy 衡量结果与任务数值或负目标的符合程度。因此，一次运行可能给出接近参考的数值，而其路径证据仍未完整；也可能完成自洽的局部计算，却没有回答指定的研究问题。

全部 50 个 Guided–Standard 配对中，平均增益的加权图结构贡献为 +0.0108，自洽性贡献为 +0.1179，准确度贡献为 +0.0829，合计对应综合增益 0.2116。Normal 与 Hard 的全部 20 题均差为 0.2164，图结构、自洽性与准确度分别贡献 +0.0080、+0.1247 和 +0.0837。

其中 10 道 Normal 题的三项贡献为 +0.0098、+0.1141 和 +0.0400，10 道 Hard 题为 +0.0063、+0.1353 和 +0.1274。完整题库分解因此将收益同时定位到科学证据闭合与目标答案；Hard 中准确度与自洽性的改善幅度相近。

HH1 给出了直接例子。Guided 与 Standard 均交付联萘消旋能垒 23.48 kcal/mol，接近参考 23.01 kcal/mol；两者图结构均为 1，准确度均约 0.973。自洽性分别为 1.0 和 0.5，对应综合分 0.9838 和 0.8338。归档的 Standard 研究已有候选通道和 IRC 输入，但被接受的证据尚未形成所要求的端点连接；Guided 将路径证据关联至相应鞍点及端点。HI1 呈现类似结果：两组准确度均约为 1，自洽性由 0.2333 提高至 1.0，综合分由 0.7032 提高至 0.9999。这些对照定位到一个有价值的完成层次：得到有希望的数值答案之后，研究仍需把相关计算组织成可核对的证明。

3.1.3 交付文件与分级科学支撑分别记录

根目录交付图是否在运行中形成，与图中携带了多少科学证据，描述研究过程的不同部分（图 8）。原运行中，Standard 在 50 题中交付 43 份根图，Guided、Record 与 Brief-errors 各交付 50 份。Standard 未在运行中形成根图的 7 题为 F1、HA1、HF1、IA9、M17、NR1 和 P3。离线整理从对应运行已有研究材料组装其机理图，最终各配置均形成完整 50 题记录。恢复这 7 份 Standard 记录，使基线已完成的研究得到相应评分，避免仅因缺少根交付文件而低估基线，从而使组间比较更保守。

Standard 这 7 题整理后均分为 0.1537，Guided 在相同任务上的均分为 0.8285，贡献了两组总净差的 44.7%；其逐题分数范围为 0.0333 至 0.3425。这个对照将运行期结束判断与最终可交付的研究量联系起来：计算结果和候选描述可能已经留在运行记录中，而所要求的路径或比较结论尚未完成。整理后的机理图保留这一研究状态，并用于统一评价。

自洽分的分布进一步显示完整任务记录内部的差异。

各配置 40 道非 Impossible 任务中，Guided 有 24 题的自洽连续分恰好为 1（60.0%）、16 题获得部分正分；Standard 有 7 题满分（17.5%）、29 题部分正分、4 题零分；Record 为 16 题满分（40.0%）、24 题部分正分；Brief-errors 有 20 题满分（50.0%）及 20 题部分正分。图 8并列展示完整证据分布与单独记录的运行期根图交付数，保留每项研究已建立的科学支持程度。

3.1.4 消融区分能力可用与引导持续生效

Record 的全 50 题均分为 0.6918，Brief-errors 为 0.7541。Guided 相对 Record 高 0.1012 [0.0396, 0.1695]，28 题更高、7 题更低、15 题持平。Normal 与 Hard 全部 20 题均差为 0.1468，其中图结构贡献 +0.0083、自洽性 +0.0919、准确度 +0.0466。保留工具及记录位置，与让未满足的科学要求在研究中持续参与后续动作选择，产生了不同结果。

3.1.5 研究耗时与计算投入揭示不同的工作流收益

图 9并列展示重复实验的耗时和 P2 可获得的计算投入。重复实验的测量单位是一个四题批次，批内并发度为 2，每种配置实际观察 3 个批次。Guided、Standard、Record 和 Brief-errors 的平均批次耗时分别为 4.451、3.958、3.894 和 4.827 小时。Guided 平均比 Standard 长 12.5%，比 Brief-errors 短 7.8%。图中保留 12 个真实批次点及原始运行结果所对应的变异。这一测量包含批次的研究生命周期、计算等待及结果返回后的继续研究。

P2 投入统计覆盖四组共有的 15 道深挖任务。Guided 每题使用 11.08 job-hours，Standard 为 7.55，Record 为 7.88，Brief-errors 为 15.59；对应最终综合均分分别为 0.8124、0.6495、0.7360 和 0.7273。相对 Standard，Guided 累计计算时长多 46.7%，均分高 0.1629；相对 Brief-errors，累计计算时长少 28.9%，均分高 0.0851。在 15 个配对任务中，Guided 有 7 题同时比 Brief-errors 使用更少累计计算时长并得到更高分。

作业数量补充了这些投入的具体形式。共同任务中，Guided 记录 789 个量子化学作业，Standard 为 419，Record 为 431，Brief-errors 为 883；其中失败作业分别为 114、45、62 和 167，取消作业另行记录。NU3、NU5、NU6 和 NR1 四道困难研究的 16 次运行共使用 163.5 job-hours，占可用 63 条投入档案 673.82 job-hours 的

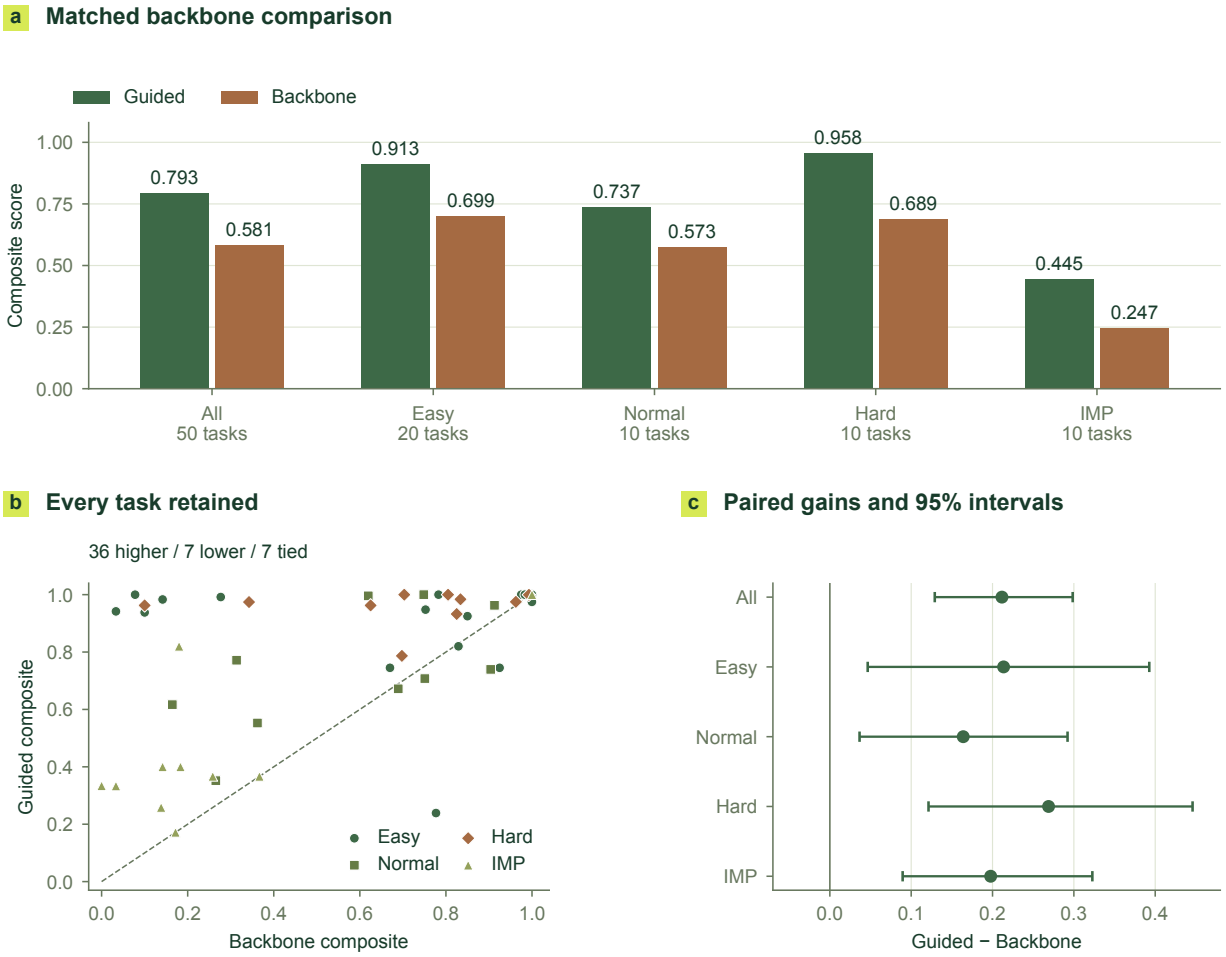


图 6. P2 主比较与逐题差异。a，Cloudra Guided 与同一 backbone 的 Standard 基线在全部 50 题及各难度层的整理后复合分；Easy 为 20 题，其余各 10 题。b，保留全部 50 个同题配对。c，配对均差与 100,000 次按任务整组 bootstrap 的 95% 百分位区间。

24.3%。相当一部分计算投入集中于这些追加尝试未能一致补齐网络缺口的研究。在归档的 Standard 缺图案例中，计算还可能晚于研究会话结束，使后续结果没有重新进入活跃研究。因此，结果返回后能否继续推进研究，也是这里所衡量的交付工作流的一部分。

Guided 相对 Brief-errors 的总体增益为 0.0388，区间为 $[-0.0317, 0.1076]$，26 题更高、10 题更低、14 题持平。比较随研究要求改变：Guided 在 Normal 中平均高 0.1514，在 Hard 中高 0.1295，而 Brief-errors 的 Impossible 均分更高。结合共同任务的投入结果，这些观察支持进一步考察诊断究竟帮助系统修复什么：某个鞍点归属、路径端点、能量参照，或允许方法能否支持所要求的结论。更多诊断文字并未在所有这些决定上形成同一种排序。

3.1.6 逐题差异定位需要持续维护的化学关系

图 10展示全部 50 题、四种配置及完整评分分量，既呈现稳定收益，也保留具体反例。Guided 在 Hard 比较性研究中表现强，NB1 和 NI1 也显示多步研究能够保持高分及充分证据。NB1 中，Guided、Standard 和 Brief-errors 分别为 0.9628、0.9128 和 0.9900，Guided 与 Brief-errors 的自洽性均为 1；NI1 中，Guided 为 0.9958，Standard 为 0.6196，自洽性分别为 1 和 0.35。与此同时，NQ5 中 Record 高于 Guided，NU3 中 Brief-errors 更高。这些差异使具体目标步骤与证据关系比按网络长度作单一排序更有解释力。

三个归档对照进一步说明哪些化学关系影响研究结论（图 11）。HA8 中，Guided 给出 29.46 kcal/mol，Standard 给出 20.43 kcal/mol，参考为 29.48 kcal/mol。档案将 9.03 kcal/mol 的差别追溯至能量参照：Guided 采用最低 all-s-trans 反应物极小值，Standard 采用反应性 cisoid 构象。

局部 IRC 连接和活化能所采用的稳定物种参照需要持续关联，同时分别记录：前者确定一条具体路径连接了哪些结构，后者确定研究问题要求的能量起点。

NU6 显示路径身份也可能在计算后改变。Guided 记录的 concerted 鞍点能量为 −247.030042392 Ha，betaine 极小值为 −247.060060699 Ha，两者差为 18.836772 kcal/mol。Guided 将其描述为经过 concerted 鞍点区域的能量代价，并保留目标 betaine 至产物闭环鞍点尚未找到的状态；Standard 则将 18.837 kcal/mol 交付为第二步闭环能垒。这个数值指纹将分歧定位到能差被解释为哪一个科学步骤。Guided 从 betaine 插值结构和受约束扫描峰出发的尝试，释放约束后反复回到直接反应物至产物的鞍点区域。因此，所要求的路径身份需要在优化后重新核对，不能直接从初猜名称继承。

这些例子与 HH1 的证据对照相互补充：同一个研究状态需要持续保留哪个构象定义能量参照、实际找到哪个驻点、它连接哪些端点，以及这些结果支撑哪个结论。Easy 逐题对照进一步区分了最终机理图中声明的化学身份，与运行保留的物理计算及数值量。

G2 中，Guided 得分 0.2389，Standard 为 0.7769。Guided 原生日志支持约 0.845 kcal/mol 的双氢转移能垒。伴随边的数值能垒声明三次被拒绝后，Agent 删除了数值字

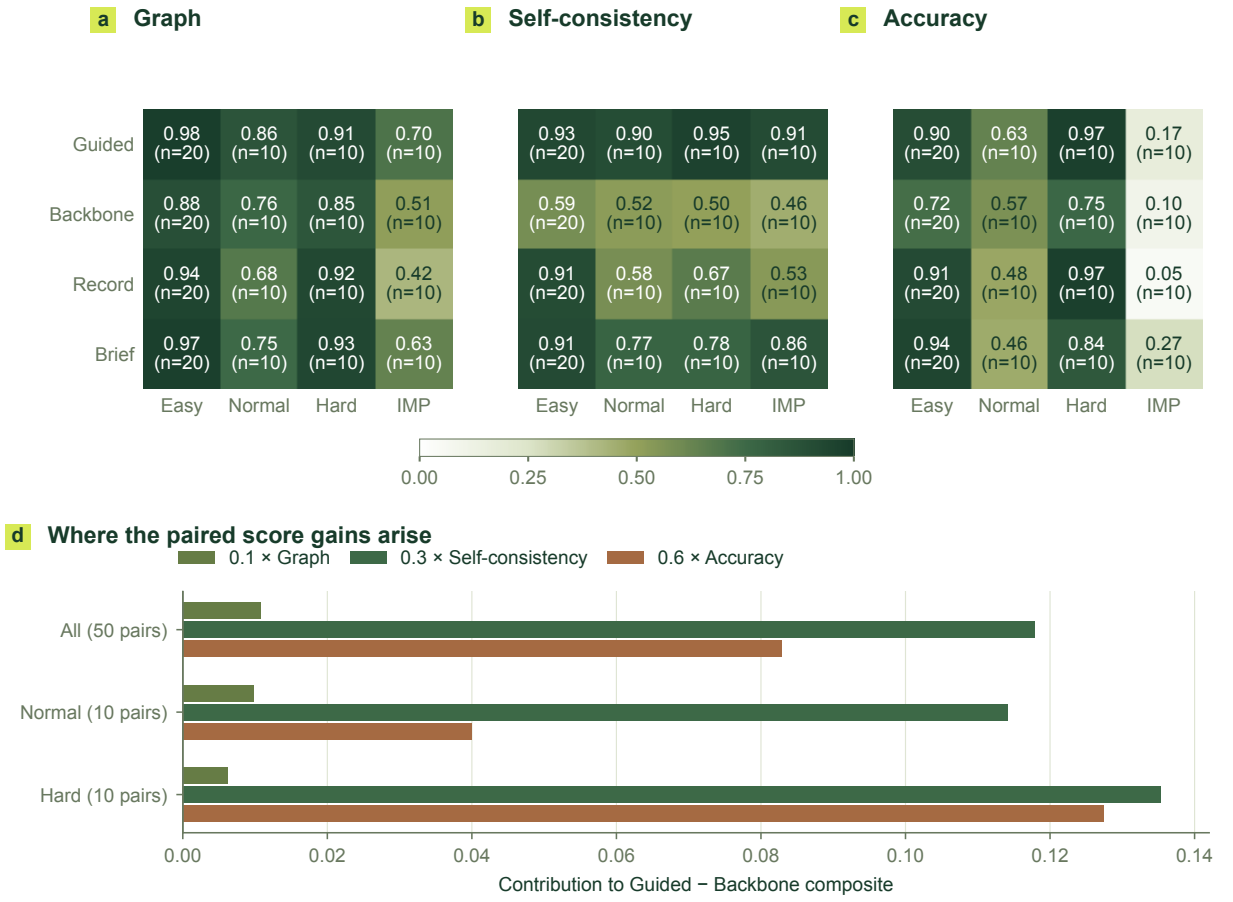


图 7. 全部 200 次整理后运行的三个评分层。a–c，各配置、难度层的 Graph、自洽性与 Accuracy 均值；每配置总体 50 题，Easy 为 20 题，其余各层 10 题。d，按固定 0.1/0.3/0.6 权重分解 Guided 相对 Backbone 的均差，全部、Normal 与 Hard 分别使用完整 50、10 和 10 个配对。各运行分量由其自身研究材料与评分记录对齐至最终整理总分。

段；Supervisor 反馈促使其恢复字段，但第四次拒绝及随后的鞍点证据检查后，最终图再次删除数值能垒以及鞍点能量、日志绑定。数值仅保留在文字说明中，准确度为 0。Brief-errors 保留了相应数值结果，得分 0.8500。

D1、D3 和 L2 中 0.7 的准确度来自既定数值偏差罚分上限。D1 与 Standard 的能垒差追溯至反应物构象参照，D3 则主要来自鞍点能量差。L2 区分反应性 cZc 与更低的 tZt 参照；Standard 已交付相应的 18.99 与 28.28 kcal/mol 两种能垒，但参考匹配选中了前者。补充信息给出了这五题各工作流的最终分项得分、原生证据与交付记录。

3.1.7 Impossible 任务区分局部证据与目标负结论

Impossible 组考察在 xTB/PM7 限制下能否得到题目规定的方法受限结论。Brief-errors 均分为 0.4829，Guided 为 0.4451，Standard 为 0.2473，Record 为 0.2325（图 12）。Brief-errors 相对 Guided 赢 3 题、负 5 题、平 2 题。其平均高 0.0379，集中于特定答案：IA1 贡献 +0.8283，IA9 贡献 +0.5666；相反，IG8 中 Guided 的结果在 Brief-errors 减 Guided 方向贡献 −0.6661。

IA1 涉及环丁二烯方形几何的自同分异构目标，Brief-errors 的图结构、自洽性和准确度均为 1，Guided 准确度为 0。IA9 涉及二氧杂环丁烷热分解，两组自洽性均为 1，准确度分别为 1 和 0。铬二聚体目标 IG8 则呈相反的准确度排序。在 Brief-errors 与 Guided 准确度相同的其余 7 题中，Brief-errors 平均低 0.0500。

其 Impossible 总体优势分解为图结构 −0.0066、自洽性 −0.0155、准确度 +0.0600：更高均分来自特定任务的目标结论，而 Guided 在另外一些任务中保留了更充分的局部支持。

全部 40 次 Impossible 运行中，4 次准确度为 1，14 次同时具有自洽性 1 与准确度 0。这一区别在分量矩阵中直接可见。例如，Guided 与 Brief-errors 在 IA5、IC3 和 IF3 中均得到自洽性 1，却未获得目标负结论的准确度分；在兼含正负步骤的 IB9 中，两者准确度均为 0.7。这些结果持续区分局部计算支撑与任务所要求的科学主张。

保存的 Brief-errors/IC3 图提供了科学报告层面的具体例子。图中将最低开壳层单重态及相应状态转换边标记为不可达，拒绝给出所求单重态—三重态能隙；已经计算的闭壳层单重态仍作为独立表征分支保留，两个方法依赖的相对能量被明确排除在目标能隙之外。该运行保留了有效探索结果，同时没有把它们提升为关于另一个电子态的答案；其最终准确度分仍为 0。这里同时保留科学声明与对应分数，目标对象归属放在讨论中处理。这个行为与 IA1、IA9 和 IG8 的得分逆转相互补充，明确指出了哪些结果可计算、哪些目标主张仍未获支持。

3.2 从化学意图到可靠空间操作

端到端基准考察完整任务中的研究能力。后续小节研究化学身份、针对目标的几何操作、证据关联与结束判断中的语义对应关系。归档研究轨迹定位具体问题；采用 Qwen3.8:27b 的受控局部实验通过配对输入与内部状态干预，考察特定信息怎样改变局部判断和动作。

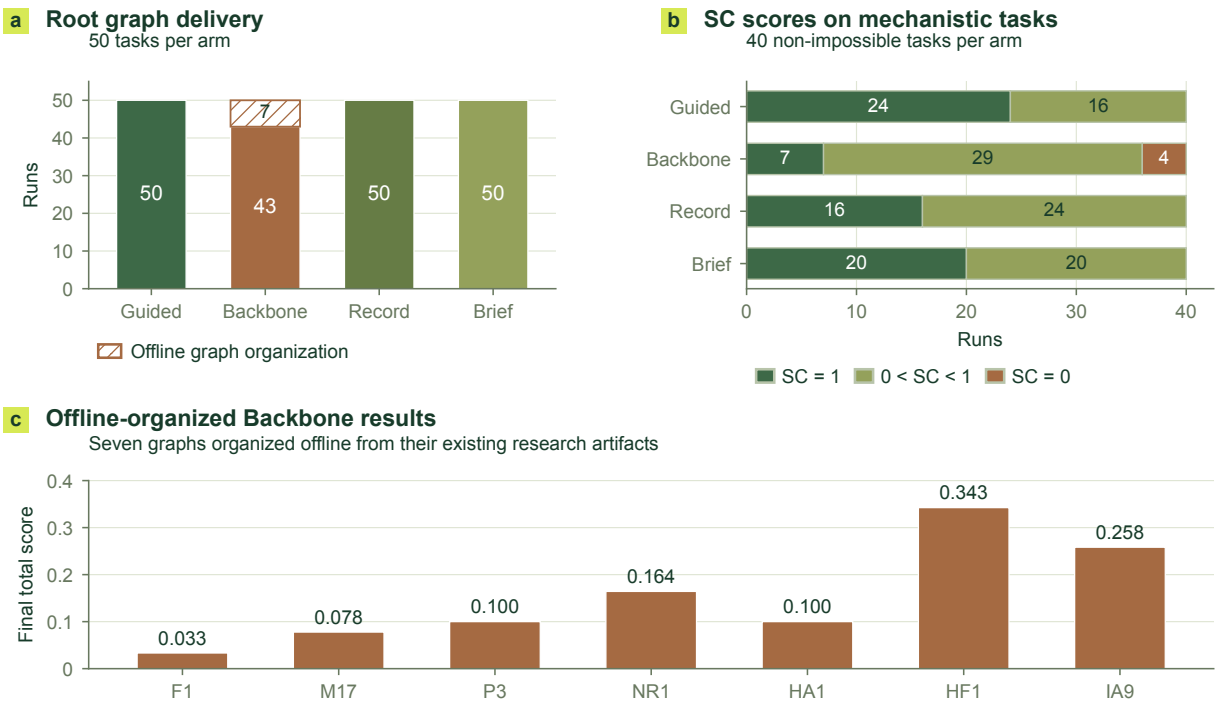


图 8. 运行期交付图与最终科学支持。a，每配置 50 题中的原始根图记录，Guided、Backbone、Record 与 Brief 分别为 50、43、50 和 50；斜线标记从运行自身材料离线组装的 7 份 Backbone 图，整理后每配置均为 50 份。b，每配置全部 40 道非 Impossible 题的自洽分布，区分 SC=1、部分正分及 SC=0；满分数依次为 24、7、16 和 20，Backbone 另有 4 题零分。c，7 个未在运行中形成根图的 Backbone 任务整理后总分，范围 0.0333 至 0.3425，均值 0.1537。

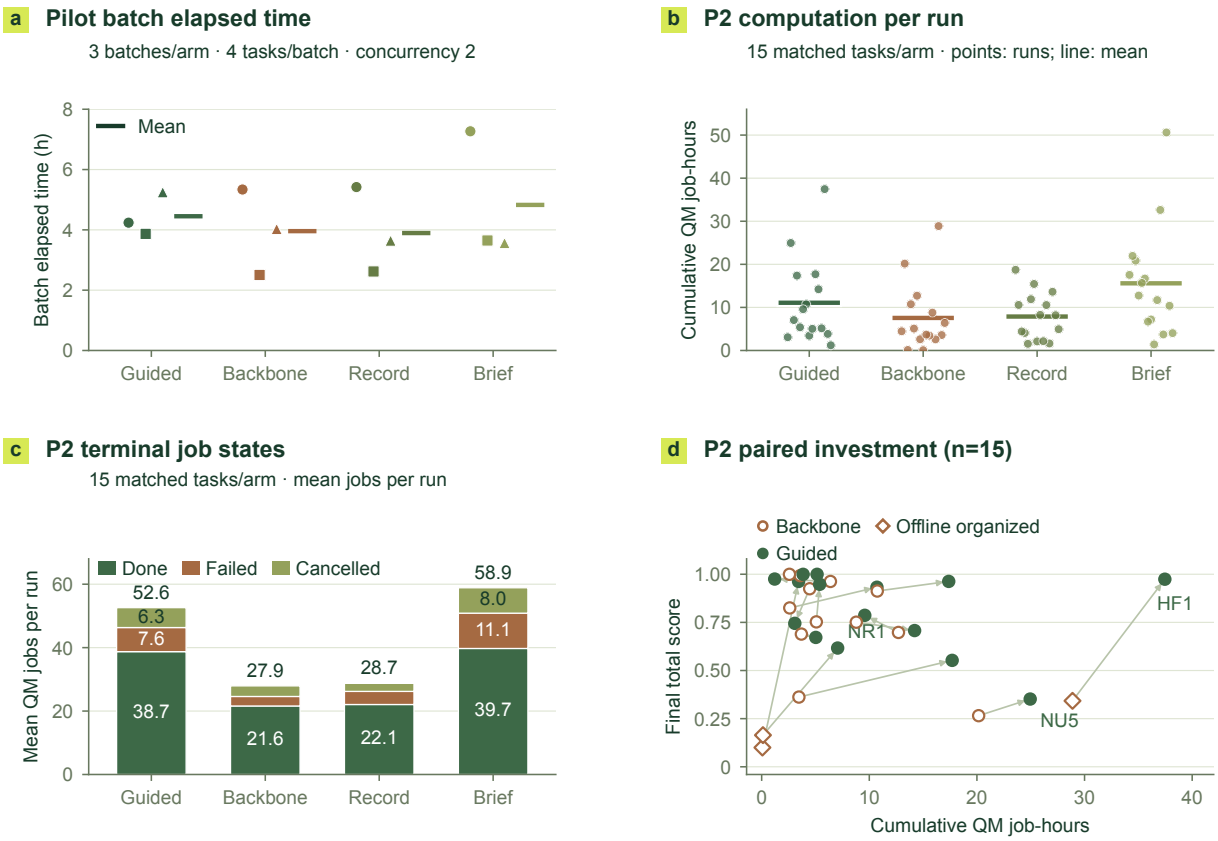


图 9. 运行速度与计算投入。a，P1b 的 12 个真实批次，每配置 3 批，每批 4 题，并发为 2；点为观测批次，短线为均值。b，P2 四配置共同 15 题的逐运行累计 QM job-hours 及均值。c，同一任务集每运行的完成、失败和取消作业数量。d，Standard 与 Guided 同题的计算投入及整理后总分，箭头连接相同任务，菱形标记离线组装机理图的运行。

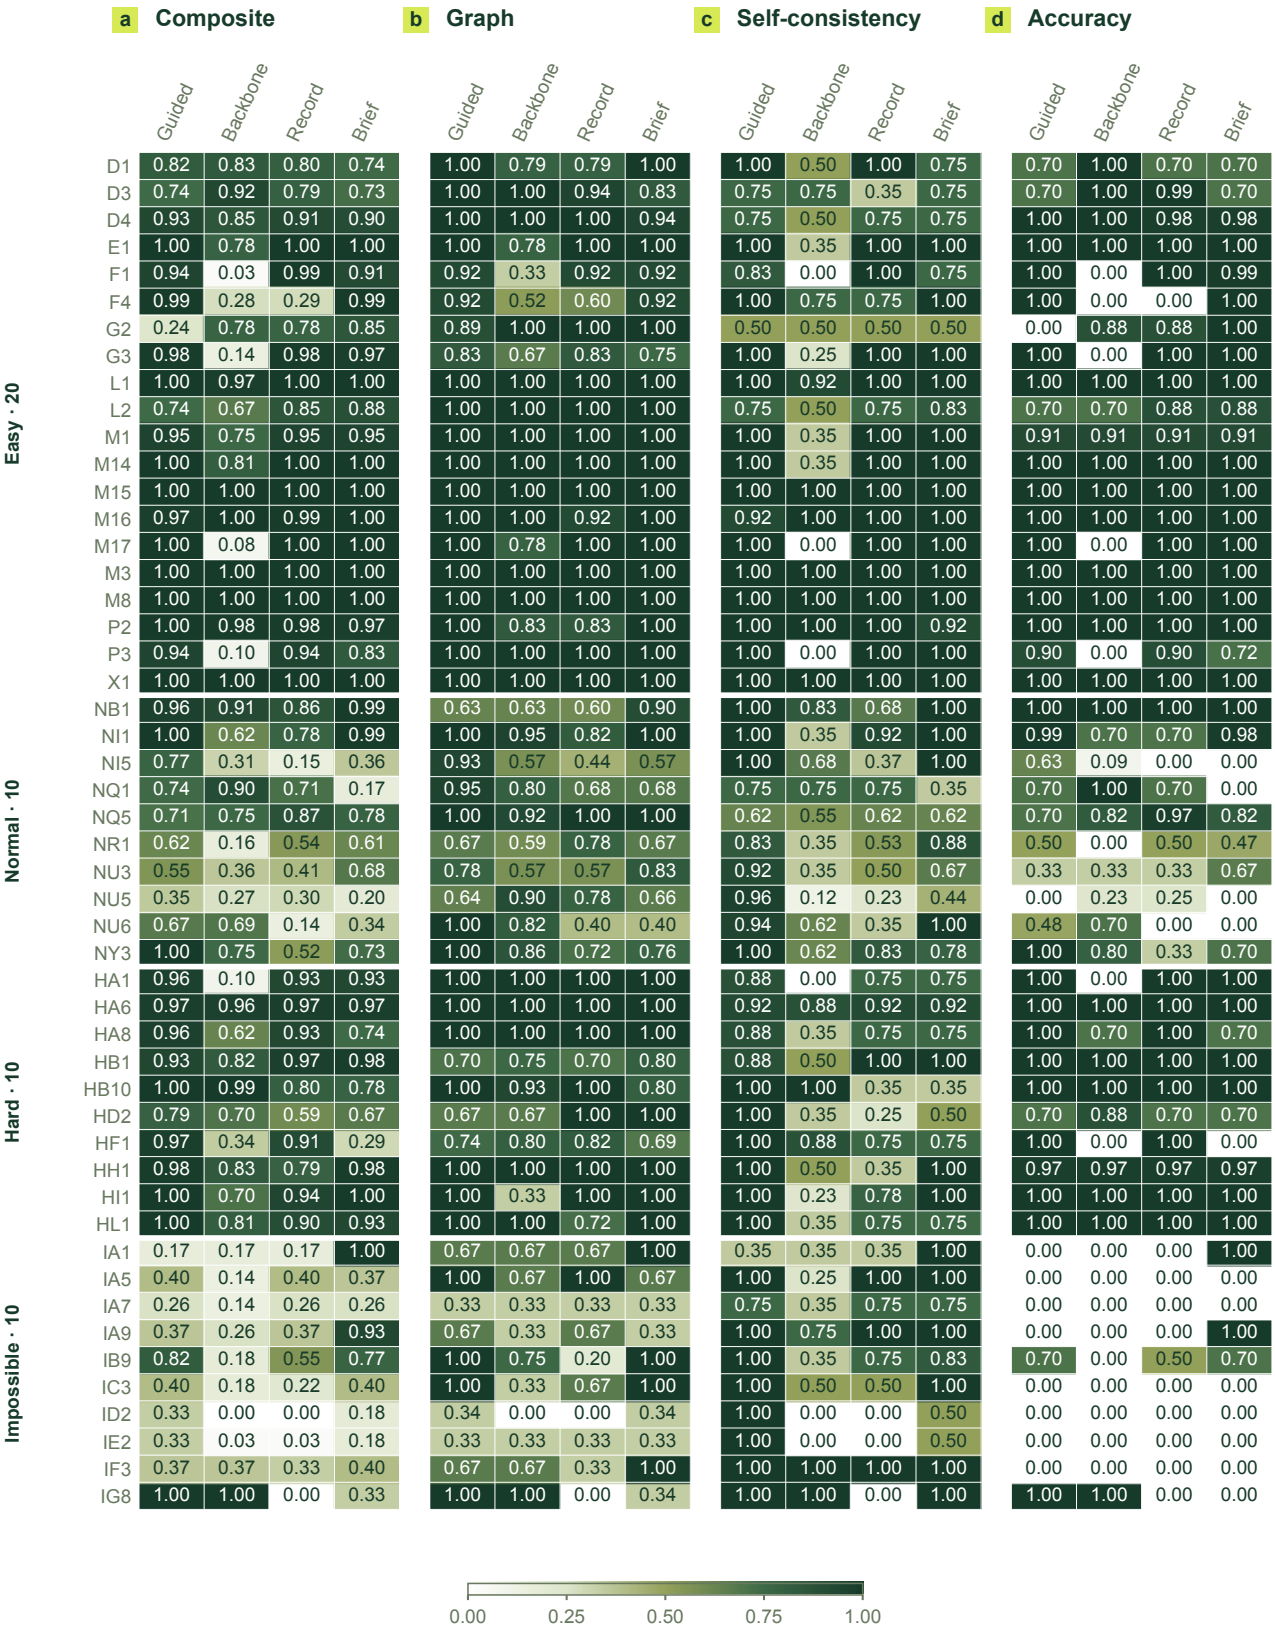


图 10. CloudraBench 全部 50 题、四配置的完整逐题成绩。四个评分块按相同顺序展示综合分、Graph、自洽性与 Accuracy，色标统一为 0–1，800 格全部呈现。数值保留两位小数，来源表保留完整精度。

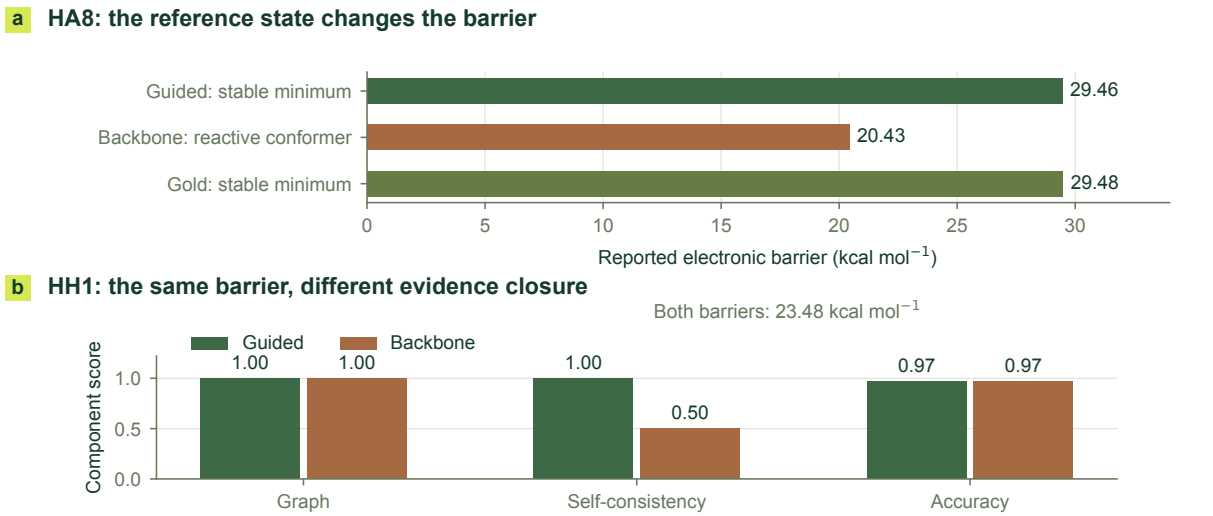


图 11. 计算结果的科学归属。a，HA8 分别采用稳定极小值与反应性构象作参照的声明能垒，与 campaign Gold 并列。b，HH1 两组均给出 23.48 kcal/mol 能垒且准确度接近，自洽证据分不同。c，NU6 两个已记录能量之差为 18.836772 kcal/mol；Guided 将其保留为 concerted 鞍点区域的代价，并将目标闭环鞍点留为未解决，Standard 则将 18.837 声明为第二步闭环能垒。计算细节与路径文字取自归档证据记录。

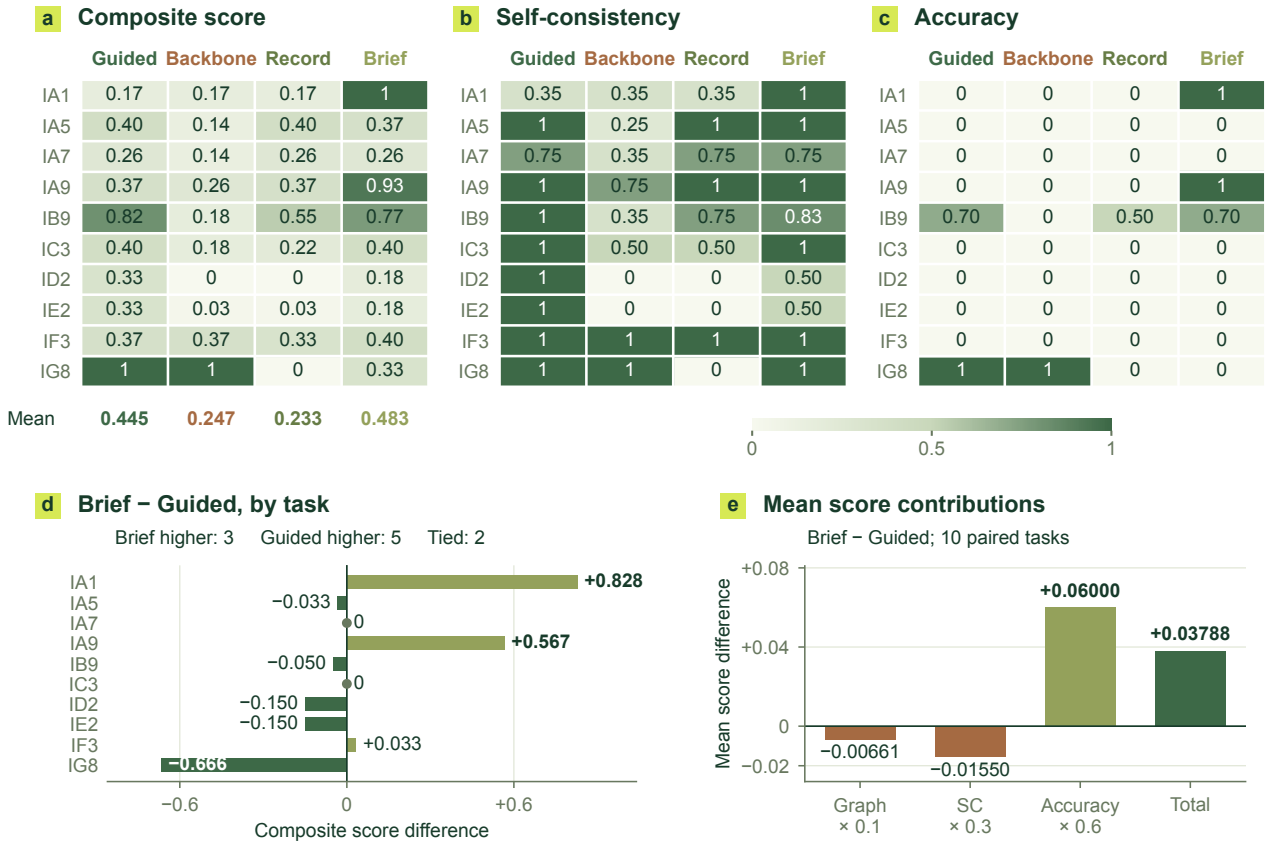


图 12. Impossible 层的逐题对照与 Brief–Guided 差异。a–c，全部 10 题、四配置的完整整理总分、自洽性和 Accuracy，色标统一为 0–1。d，Brief 相对 Guided 的逐题总分差，均差 +0.03788 集中于 IA1 与 IA9，IG8 呈相反结果；Guided 赢 5 题、Brief 赢 3 题、2 题持平。e，按既定权重分解均差，Accuracy 贡献 +0.06000、Graph 贡献 −0.00661、自洽性贡献 −0.01550，细微加总差异来自保存总分的舍入；任务 bootstrap 的 95% 区间为 −0.188 至 +0.284，逐题科学声明见下文分析。

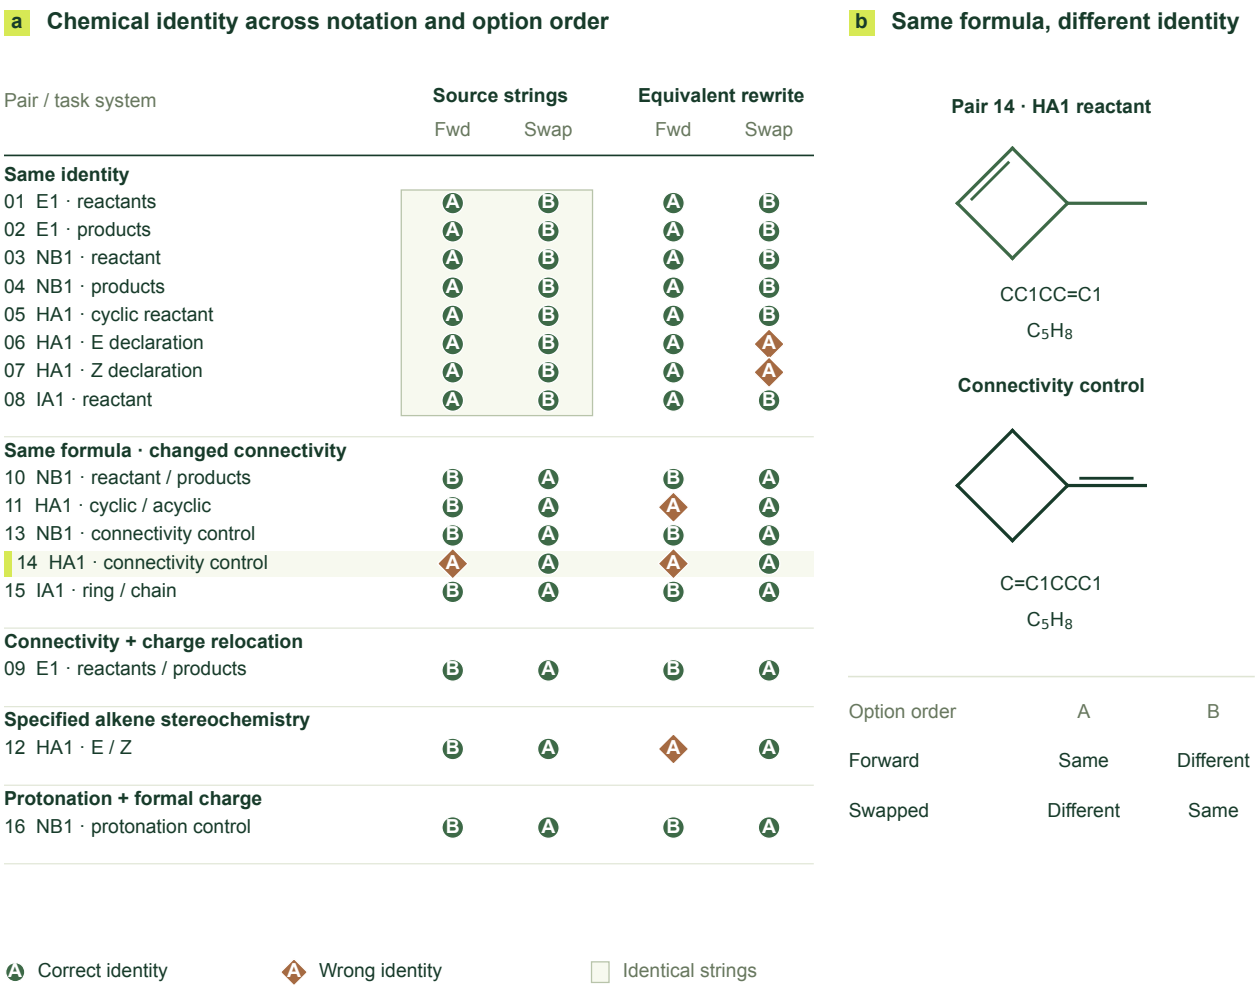


图 13. 分子表示与选项顺序下的化学身份判断。16 对分子各包含四种输入条件；圆形和菱形分别表示正确与错误，内部字母保留模型实际回答。浅色区域为相同字符串条件。右侧显示第 14 对的两种 C_5H_8 连接结构及选项含义。两种连接分别为 `CC1CC=C1` 与 `C=C1CCC1`，分子式均为 C_5H_8。

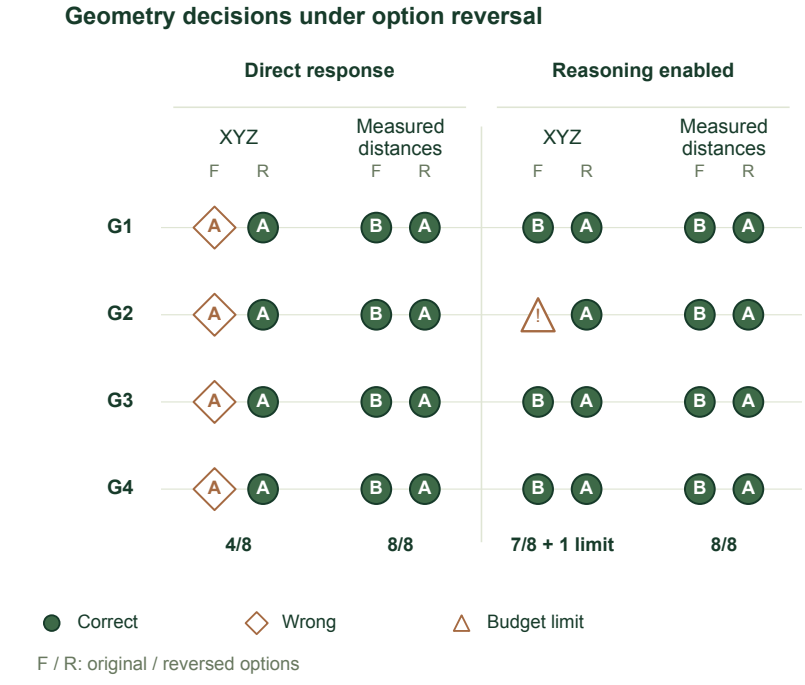


图 14. 坐标输入与测量距离输入下的几何判断。四个源结构分别在直接回答和开启思考条件下比较，每种条件均包含原始（F）与交换（R）选项顺序。圆形表示正确，菱形表示错误，三角形表示达到输出预算；内部字母保留实际回答。

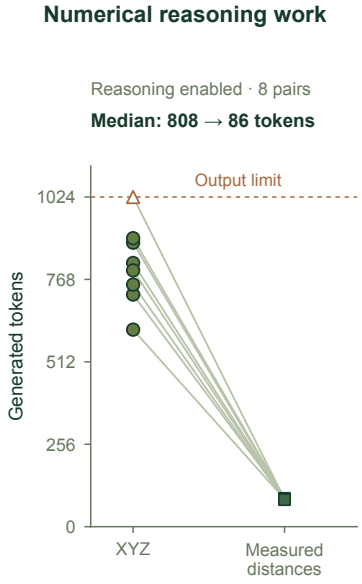


图 15. 开启思考时的生成 token 数。每条线连接同一源结构、同一选项顺序下的笛卡尔坐标输入与测量距离输入，共八组配对比较。虚线表示输出上限。

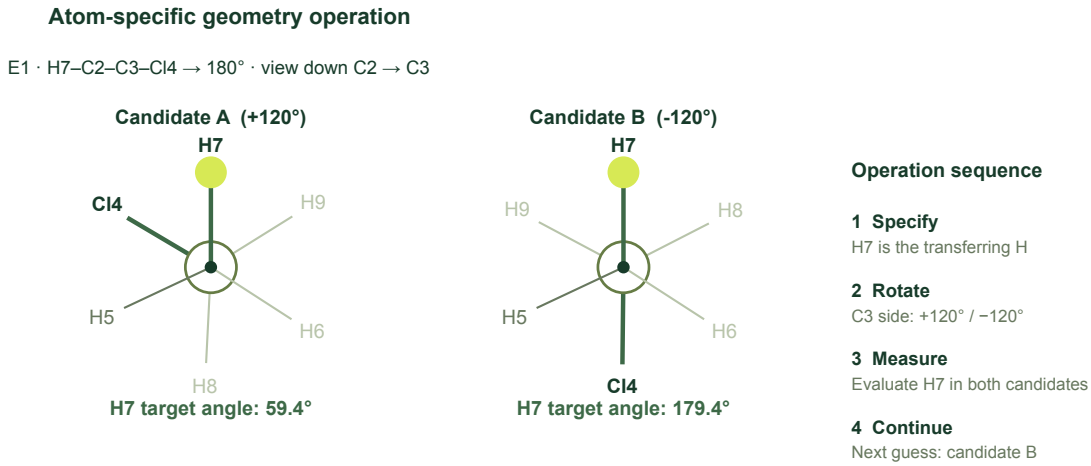


图 16. E1 中面向指定目标的几何操作。Newman 投影保留原候选坐标沿 C2→C3 观察时的方向。H7 为指定的转移原子；候选 A、B 的目标角分别为 59.4° 和 179.4°。投影旁列出相应操作顺序。

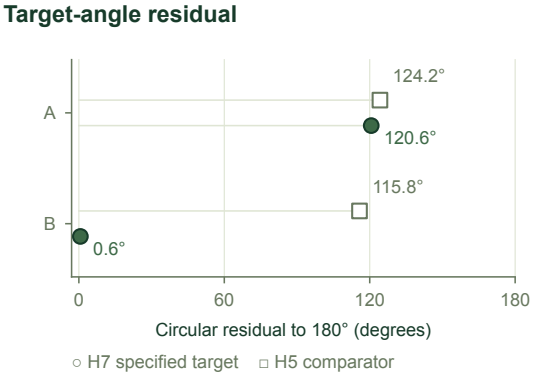


图 17. 候选 A、B 相对指定 180° 目标的圆周角残差。H7 为指定目标原子，H5 为比较原子。

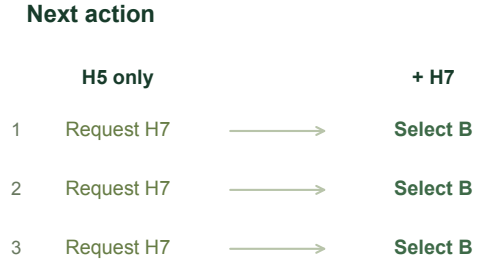


图 18. 三种局部选项排列下的后续动作。仅提供 H5 测量值时，模型请求 H7 测量；补充 H7 后，模型选择候选 B。

3.2.1 化学身份为操作提供持续参照

一次几何修改首先需要确定它作用于哪个分子、哪个原子和哪个反应中心。相同分子可以有不同的 SMILES 遍历方式；相同分子式也可以对应不同连接关系。为考察模型如何处理这些差别，我们构造了 16 对分子身份问题，覆盖相同身份、同分子式下的连接变化、连接与电荷位置变化、双键立体化学以及质子化变化。每一对交叉设置原字符串或等价改写，以及两种答案顺序，得到 64 次判断。

模型在其中 58 次作出正确判断。等价改写改变了 32 组表示配对中的 4 组语义判断，交换答案顺序改变了 32 组选项配对中的 6 组判断。后六组都重复选择字母 A。图 13 中的一对 C_5H_8 结构尤其直观：环内双键与环外双键对应不同连接方式，模型在四种条件下均回答 A，而 A 在两种顺序中分别代表“相同”与“不同”。这一结果将表示敏感性定位到实际的化学对象判断上，也说明持续研究需要保留稳定的身份参照。

Cloudra 的分子拓扑、原子映射与反应中心承担了这项职责。它们使模型在不同表述和不同构型间切换时，后续测量、片段移动及端点比较仍能指向原来声明的对象。原子对应关系还将产物端点对齐、路径插值与反应中心监测连接起来，使局部几何操作能够沿同一套化学身份继续进行。

3.2.2 几何测量分担反复出现的数值推理

识别研究对象之后，模型还需从坐标获得与操作有关的空间关系。我们选取 NB1 轨迹中的四个实际结构，要求比较两个指定原子间距。每个结构均交换答案顺序，并分别提供完整 XYZ 或程序测得的距离。两种信息条件进一步交叉直接作答与开启思考，形成 32 次原生聊天调用（图 14）。

直接作答时，XYZ 条件的八次响应全部选择 A，其中四次正确；提供测量距离后，八次均正确，并在选项交换后保持相同的语义答案。开启思考后，XYZ 条件得到七个正确答案，另一次在 1,024 个生成 token 时达到输出上限；该输入单独增加预算后，在 1,353 个生成 token 内得到正确答案。

测量距离条件的八次回答均正确。开启思考的八组配对中，XYZ 与测量距离条件的生成 token 中位数分别为 807.5 和 86。

这些结果提示，几何判断的负担包含原子定位、数值运算和关系比较。增加推理可以完成这些局部计算，程序测量则直接提供后续判断所需的关系量。Cloudra 因而让模型以键长、键角、二面角与片段关系表达目标，由确定性算子执行坐标变化。这种分工将重复的数值工作交给程序，并使操作后的变化能够直接检查，与程序辅助语言模型的职责划分相呼应。[38] 分支拥挤描述、反应物预组织与局部片段旋转在此基础上，进一步把空间关系用于候选构型的选择和构建。

3.2.3 反馈必须对应指定原子与几何目标

确定性执行还需要与化学意图保持对应。E1 的一条真实轨迹提供了完整例子：模型希望将转移氢 H7、C2、C3 与离去原子 Cl4 调整为接近 180° 的二面角。它围

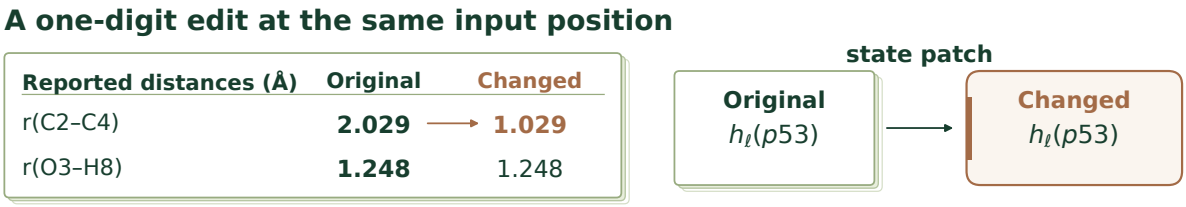


图 19. 对单个报告距离的干预。一次数字修改将 C2–C4 距离从 2.029 改为 1.029 Å，O3–H8 保持 1.248 Å。在指定层，将原始输入中 token 位置 53 的残差状态替换到修改后输入的运行中。token 位置从零计数。

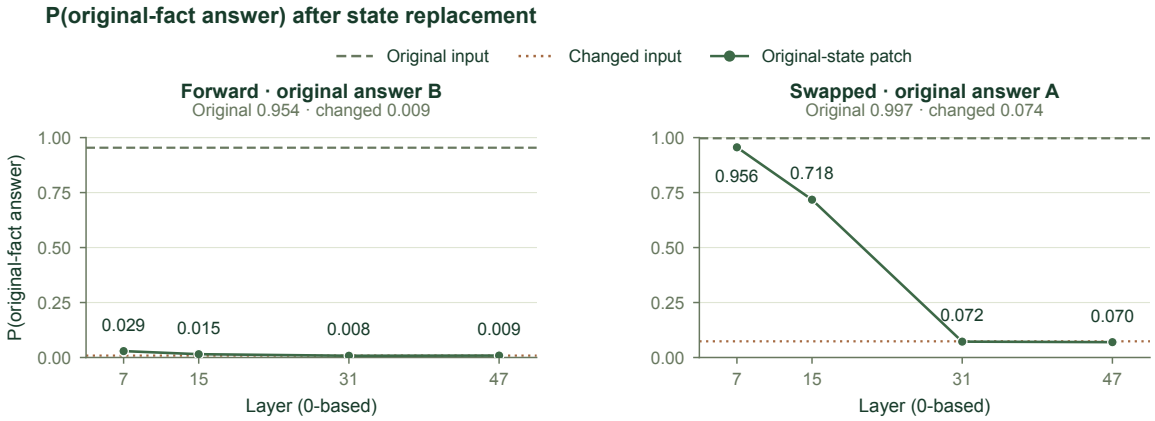


图 20. 状态替换后原始事实答案的概率。曲线显示原始顺序（答案 B）与交换顺序（答案 A）下，原始事实答案在完整词表中的概率质量，包含无前导空格与带前导空格的 token 写法。水平线为原始输入与修改后输入的基线。层号从零计数。

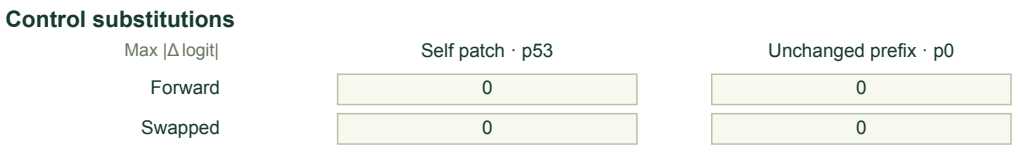


图 21. 状态干预实验的对照替换。在 p53 进行同状态自替换，以及在 p0 替换未改变的前缀，两种选项顺序下均保持全部词表 logits 不变。表中报告 logit 差值绝对值的最大值。token 位置从零计数。

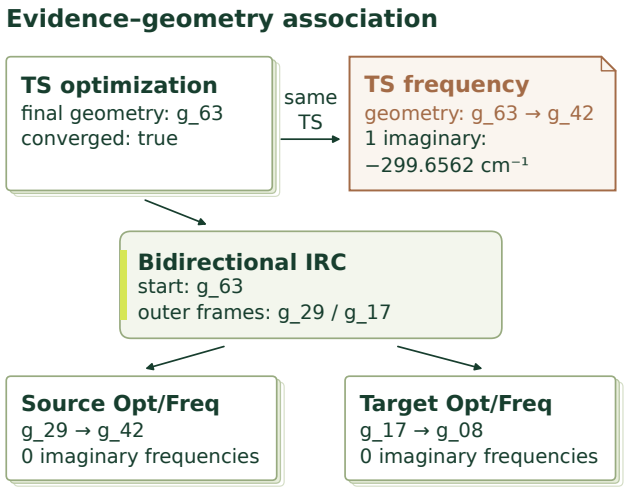


图 22. E1 源链中的证据与几何关联。受控输入将频率计算的几何引用从 g_63 改为 g_42，同时保持局部终止、收敛、能量和频率数值。图中保留从过渡态优化、双向 IRC 到端点优化与频率计算的关联。

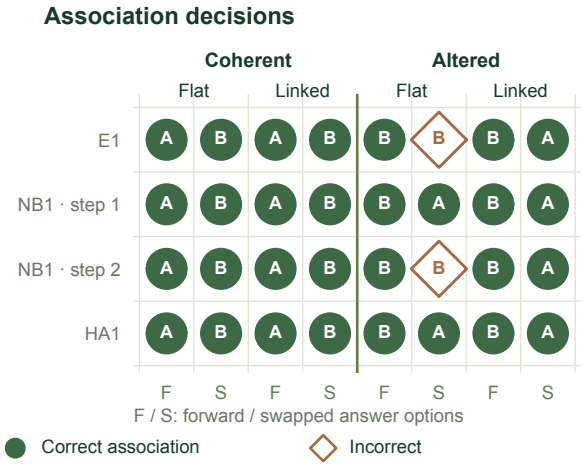


图 23. 四条源链共 32 个输入的关联判断，交叉比较一致或修改后的关联、平铺或关联式表示，以及原始（F）或交换（S）答案顺序。字母保留已保存的 A/B 回答；圆形表示正确关联，菱形表示错误关联。

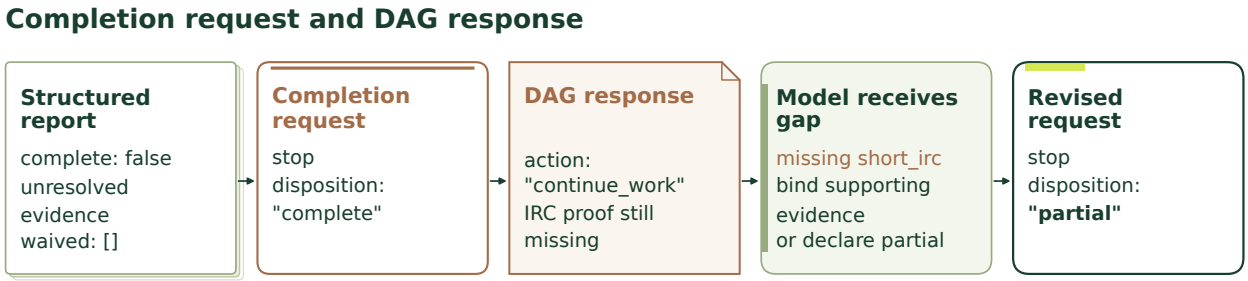


图 24. 原始 IA1 轨迹中的完成请求与 DAG 反馈。报告仍有未解决的证据后，模型请求完成；系统指出缺少 short_irc 证明并向模型反馈，随后模型改为请求部分完成。

绕 C2–C3 轴分别旋转 C3 一侧片段 +120° 与 −120°，构建候选 A 和 B，并将 C3–Cl4 距离调整到 2.35 Å。默认结构报告中的代表性二面角涉及 H5，而当前目标涉及 H7。模型随后主动计算两候选的 H7–C2–C3–Cl4，获得约 59.4° 和 179.4°，并在下一次实际提交中采用候选 B。

图 16 给出由保存的候选坐标绘制的 C2→C3 方向 Newman 投影，图 17 汇总对应的目标角残差。

候选 B 的 H7 目标角距 180° 仅 0.6°，A 的相应残差为 120.6°；H5 比较量在两候选中的残差分别为 124.2° 和 115.8°。这组数据揭示了反馈的对象依赖性：一个读数的化学意义，来自它与当前指定原子及操作目的的对应关系。

围绕同一组测量值的局部对照进一步显示了信息与动作的连接。只提供 H5 时，三种循环选项排列均请求补测 H7；加入 H7 后，三种排列均选择 B。另两组充分性配对也随目标量的加入，从需要补测转为信息充分。由此，原子映射、内坐标、片段操作和反馈可以沿一条研究动作链理解：确定目标对象，执行空间改变，测量目标量，再选择下一候选。预组织、刚体对齐与路径准备也沿用这一对应关系，将反应意图传递到后续势能面探索。

3.2.4 测量事实的内部传递影响选择

局部对照可以单独考察一项几何事实怎样参与即时选择，并与研究轨迹中测量值经几何操作保留到后续判断的分析衔接。为进一步考察模型怎样使用已提供的测量值，我们在同一本地量化模型中进行了单位置激活替换。[39] 输入中的一个距离由 2.029 Å 改为 1.029 Å，另一距离保持 1.248 Å，对应的比较答案随之反转。随后把原始输入在数字 token 位置的残差状态，分别替换到改动输入的第 7、15、31 和 47 层，并读取原始事实所对应答案的全词表概率。

替换的影响随层和选项顺序变化（图 20）。在交换选项的输入中，原始事实答案 A 的概率由改动后的 0.074，在第 7 和 15 层替换后分别升至 0.956 和 0.718；第 31 和 47 层的值分别为 0.072 和 0.070。在原选项顺序中，答案 B 的概率由 0.009，在前两层替换后分别变为 0.029 和 0.015，后两层仍接近改动输入。

自替换及未改变前缀位置的控制替换中，全词表 logit 差均为零。

替换一个数字位置的残差状态，改变了本探针中的后续选择。两种选项顺序下的差异与 3.2.1 节观察到的位置敏感性一致。结合测量与证据关联对照，这些结果支持将几何量与其化学对象和操作保持关联，使后续选择仍可对照同一组已记录事实。

3.3 从局部计算结果到有证据的科学交付

3.3.1 DAG 保存结果之间的科学支持关系

几何对象进入计算之后，研究需要把优化结构、能量、频率与路径逐步组织成对同一反应步骤的支持。每份结果的局部有效性及其归属共同决定这条支持链：频率应对应所声明的鞍点，IRC 应从该鞍点出发，两侧末帧的优化与频率应对应相应端点。DAG 将这些关系保存在物种与基元步骤上，为不断增加的结果提供持续的研究索引。执行状态、数值收敛与科学支持分别记录，使后续研究能够据此等待计算、调整重算或继续补充证据。

我们从归档提取四条源证据链，分别构造保持关联与改变单一引用的版本，并交叉平铺表示、关联表示和两种答案顺序，得到 32 个输入。单一引用的变化分别涉及频率几何、IRC 起始几何、端点优化输入或目标物种；局部终止、收敛、能量和频率值保持不变。图 22 以 E1 为例：将频率的几何引用从鞍点改为一个已有的端点，便改变了这份频率对当前步骤的支持关系。

关联表示的 16 次判断均正确，平铺表示的 16 次中有 14 次正确；两处错误均出现在引用已改变且选项交换的条件，分别来自 E1 与 NB1 第二步。随后选择的两条源链原生跟进中，开启思考使全部 16 次关联判断正确，包括原先两处错误。这一结果提示，明确关联可以分担模型查找与拼接计算关系的工作，也与图编码方式影响语言模型关系推理的观察相呼应。[40] 在 Cloudra 中，这种表示进一步与真实计算产物绑定，使同一物种、步骤和尝试下的科学事实能够持续累积。

3.3.2 诊断将缺口转化为具体研究动作

诊断反馈把证据问题对应到需要修订的化学对象和计算。Cloudra 的结构化诊断指出具体问题，例如位阻冲突原子对、虚频模式对齐异常及路径端点连接问题，为下一次局部计算提供依据。

两条归档轨迹展示了这一过程。在 Brief-errors 的 HA1 试验中，简短错误代码替代了详细的 IRC 端点关联诊断。计算智能体反复更换源极小值引用，几何连接问题仍未解决。在 Guided 的 NB1 试验中，检查发现零虚频并返回模式诊断；协调智能体要求调整过渡态初猜参数和优化约束，计算智能体将这些改动用于下一次提交。这些案例说明诊断怎样把失败检查连接到需要处理的对象与参数。[41]

各角色处理同一组已记录的化学实体。计算智能体优化分配步骤的几何和路径，协调智能体管理假设、分支与路线选择，Supervisor 对照任务要求审核累计支持。中央异步执行与持久化账本保留这些角色使用的计算记录和共享上下文。

3.3.3 未完成项必须持续参与结束判断

IA1 的归档轨迹中，一次结束请求与已记录的科学要求发生冲突。反应步骤仍缺必要的双向 short_irc 验证，豁免清单为空。Supervisor 此前曾肯定中间体优化收敛，模型随后在 IRC 要求尚未满足时请求结束研究。

系统驳回该请求，并将尚缺的 short_irc 要求返回模型。下一次提交中，模型将状态改为部分完成（图 24）。这项要求在局部计算获得肯定和之后的结束请求中持续保留。

我们还检验模型能否依据记录状态辨认 IA1 的未完成要求。在最新摘要与 12 条消息历史两种条件、正反选项顺序组成的 6 对输入中，12 次判断均正确（100%）。模型在每个状态问题及两种选项顺序下识别出未满足项。Delivery DAG 保留已确证对象与未完成要求，为继续计算或交付阶段性结果提供依据。

3.4 工作流引导、科学判断与展望

主对照表明，Cloudra 通过使化学对象、计算结果与科学要求在探索中持续衔接，能够提高同一 backbone 的研究交付质量。Hard 任务中一致的改善及 Normal 任务的收益，将这一贡献定位到比较性立体化学研究和多步研究的推进。完整 50 题分解显示，证据闭合与目标准确度均有收益；Hard 中两项加权贡献分别为 +0.1353 和 +0.1274。HH1 和 HI1 进一步说明，即使已得到接近参考的能垒，数值结果与支撑其科学归属的路径证明仍是两个不同的研究成果。

归档案例提示，自主研究过程需要保持三种能力。首先，科学对象的身份需要超越当前语言描述而持续存在。一个反应物种可以包含多个构象，所要求步骤的初猜也可能优化至属于另一条路线的鞍点。HA8 需要将能量分母持续关联至稳定物种，同时保留 IRC 实际连接的局部端点；NU6 需要按优化后的连接关系判断新驻点，而非从初猜的预期名称继承身份。这些关系跨越了不同时间得到的计算结果。持续保存的研究图使模型能够在每次计算改变已知事实后，重新检查并更新这些关系。这一解释与语言模型研究中外部规划、检验及反馈的作用相呼应。[42]

其次，反馈需要指出研究应在哪一层改变。缺少端点优化与鞍点反复落到另一条路线需要不同动作，两者也不等同于方法无法描述目标电子态。语言模型依据当前上下文生成合理的后续动作；熟悉的化学表述可以保持连贯，而数值或路径证据已经发生变化。外部测量与结构化证据能够暴露这种失配，但智能体仍需判断应当修复计算、修改路径假设、重新选择参照，还是拒绝给出目标结论。Record 对照说明，使工具可用并不足以保证这些关系持续进入最终论证；Brief-errors 对照则说明，反馈中什么信息有用，取决于当前需要作出的决定；这一观察也呼应了外部反馈对推理修正作用的相关研究。[41, 43] 文本解释对既有判断的合理化也为这种语义与证据脱节提供了相关研究背景。[44]

第三，完成局部证明与判断科学主张的范围需要共同推进。Brief-errors 较高的 Impossible 均分来自 IA1 和 IA9 的特定目标结论，IG8 则呈相反结果。其 IC3 图提供了更具体的行为证据：运行保留已表征的闭壳层分支，同时拒绝将其当作所求最低开壳层单重态，或把其相对能量报告为目标能隙。这是一种有价值的科学判断：保留探索已经建立的结果，同时不让方便得到的结果替换原本不同的研究问题。交叉结果支持一个依赖任务的解释假说：详细诊断有助于补齐有效的局部证明，但当方法或目标本身需要重新审视时，持续修补当前证明可能无助于解决问题。本次最终结果对照并未确立诊断长度的因果作用，也未测量其背后的模型内部认知机制。

Easy 组的 G2 案例暴露了工作流之间的相互作用：伴随边通过检查前阻止数值声明，促使智能体删除了原生计算已经支持的数值；Supervisor 反馈曾恢复这些字段，后续拒绝又先于最终删除。这里需要区分保存暂定观测与接受该观测所支撑的机理主张。验证状态应限定归档数值的科学用途，同时保留数值及来源。这条轨迹区分了保留受支持的观测与接受相应机理主张，其部分自洽性贡献也与准确度失分分别解释。

科学主张需要按所求反应通道与电子态明确标识，仅凭端点的分子连接关系不足以确定其身份。Record/IA5 正确拒绝目标异旋路径，但归档裁定记录了匹配器选择另一条相同端点正路径的情况；Brief-errors/IC3 尽管明确区分目标开壳层态及独立闭壳层分支，准确度仍为 0。本文保留定稿分数，并与保存的科学主张一同解释。评价过程在将结果归属到任务目标时，必须像研究工作流一样保留路径与电子态的区别。

SI 按原有负目标计分规则，对 IA5 与 IC3 的所求对象开展条件性匹配分析，固定两例的图分、自洽分及其余 198 次运行。每次对象归属修正使一例综合分由 0.4 变为 1.0，对应配置的 Impossible 均分增加 0.0600。两项同时修正时，Brief、Guided、Record 和 Standard 的条件均分分别为 0.54294、0.44506、0.29250 和 0.24733。Brief、Guided、Record 之间的排序不变，Record 超过 Standard；Guided 与 Standard 的每一对比较均不变。正文报告最终评价分数，条件分析表将对象匹配与智能体最终科学判断分别呈现。

P2 每题每配置保留一次运行，任务簇 bootstrap 区间反映抽样题目构成的变化，不刻画同一任务独立重复运行的随机方差。另行开展的 P1b 研究在四题、四配置的每个组合上重复三次，共 48 次运行，并未为 P2 的全部 50 题提供重复测量。完整整理后的 P2 表覆盖 200 次运行及其三项评分分量。部分 Hard 任务的准确度目标是定性通道身份，因此收益包括路径识别、证据闭合和数值能垒。后续对完整题库重复评估，可以进一步刻画运行间变异及不同研究路线的选择频率。

Impossible 组考察在题目允许的当前方法下认为物理不存在的目标，这类判断限定于相应的方法描述。其分量还采用负目标规则，显式负结论的自洽性 1 与正路径的 TS—IRC—端点证明分别解释。14 例自洽性 1、准确度 0 因而需要结合目标主张与来源理解。NU6 能量指纹吻合则定位到可达路径中的相关问题：当鞍点身份与所要求步骤没有持续关联时，同一个能差可能被赋予不同科学含义。这些案例支持在研究假设改变时，持续检查每次计算实际回答了什么。

耗时与投入同样按实际观测单位报告。12 个先导批次测量并发度 2 的四题真实耗时，包含原始失败与停止结果；P2 投入档案覆盖选定的深挖研究，四配置共有 15 题。累计 job-hours 代表记录的量子化学进程时长，Standard/M1 另有已注明的原生日志重构；它与核时、费用及 P2 端到端研究耗时分别记录。并发计算共享资源，CPU 排队可能延迟个别结果。因此，这些测量支持已观察工作流与投入之间的比较；进一步区分排队、计算及智能体活跃时间，有助于明确实际耗时花在何处。

交付案例还给出了与科学改进相对应的系统方向。等待计算、收到完成事件、恢复研究及形成最终产物，需要共享连续的任务生命周期。Standard 的缺图源于计算尚未完成时的提前结束；Guided/HI1 也暴露了通知没有唤醒等待会话的问题。使未完成目标持续跨越这些状态变化，才能把新完成计算变成可用的研究信息。科学层面还需要让反复返回同一驻点区域的现象保持可见，

帮助智能体判断再做一次局部尝试是否足以解决目标路径。更好的候选选择及研究假设修订，可以进一步补充证据保存能力的改善。

Cloudra 的默认预组织采样 32 个刚体相对放置，进行局部 MMFF94 松弛，再按能量与聚类选择候选。这一流程采样局部排布。频率确证的极小值表明驻点性质合格，不能据此判断所有更低构象均已搜索。HA8 说明需要同时保留规定的稳定参照与局部活性构象，而全局最低点的主张还需要单独评估构象覆盖。CREST 通过独立的可选后端提供，本次 200 次运行并未建立统一的 CREST 覆盖。高柔性体系可能需要更广的构象采样与更多量子化学计算。后续需要测量构象覆盖程度，并改进相互竞争候选之间的计算资源分配。

本基准比较纯电子能差，未加入零点能、热与熵、标准态校正，也未量化溶剂化对自由能的贡献。NI5 的题设为弱酸性水溶液，NU5 则为高浓度二氯甲烷条件，这一区别对二者尤为重要。其分数评价规定的电子能参照。对于缔合与解离，熵及浓度相关的标准态项进入 $\Delta G^{\ddagger}$；溶剂参与还可能改变描述路径所需的化学模型。推断溶液条件下的控速步骤或立体选择性，需要对相关物种和路径采用一致的自由能处理。本研究未开展溶剂敏感性对照，因此不据此推断实际溶剂影响的大小或方向。

原子映射系数与歧义窗口，以及分支拥挤描述符的衰减、深度和拥挤设置，在各工作流对照中保持固定。本研究未通过参数扫描测量各项设置的敏感性或独立贡献。虚频模式对齐比值 0.5 仅用于提示，科学有效性由驻点与 IRC 端点证据决定。P2 各配置均使用 DeepSeek-v4.1-flash（1017），归档 API 别名为 `deepseek-v4-flash`，请求设置另行保留。采用更多 backbone 进行比较，可以检验工作流收益在不同模型间的适用范围。

我们的长期目标是将 Cloudra 从小分子机理计算扩展至更广泛的计算化学领域。多种计算引擎支持、共享执行基础设施及持续保存的科学记录，已为这一扩展提供基础；面向新的问题类型，还需要相应的科学表示、计算方法与验证准则。我们希望 Cloudra 最终成为计算化学家的强大研究工具，以及实验团队的计算专家。Cloudra 将以 GNU Affero General Public License（AGPL）开源，支持系统的公开检查、复用与社区共同发展。

数据获取。Cloudra 公开研究数据目录提供 P2、48 次 P1b 实验、Gold 参考证据和 SI 复现材料；内容、版本与校验值见 SI 第 S7 节及下载说明。

参考文献

[1] K. Fukui. Formulation of the reaction coordinate. *The Journal of Physical Chemistry*, 74:4161–4163, 1970. doi: 10.1021/j100717a029.

[2] S. Maeda, Y. Harabuchi, Y. Ono, T. Taketsugu, and K. Morokuma. Intrinsic reaction coordinate: Calculation, bifurcation, and automated search. *International Journal of Quantum Chemistry*, 115:258–269, 2015. doi: 10.1002/qua.24757.

[3] Yunheng Zou et al. El Agente: An autonomous agent for quantum chemistry. *Matter*, 8:102263, 2025. doi: 10.1016/j.matt.2025.102263.

[4] Jinming Hu, Hassan Nawaz, Yi-Fan Hou, Lijie Chi, Xin-Yu Tong, Yuting Rui, Yuxinxin Chen, Arif Ullah, and Pavlo O. Dral. Aitomia: An Agentic Framework for AI-Driven Atomistic and Quantum Chemical Simulations. *Journal of Chemical Theory and Computation*, 22(13):6557–6571, 2026. doi: 10.1021/acs.jctc.6c00591. URL `https://doi.org/10.1021/acs.jctc.6c00591`.

[5] Jiaru Bai, Abdulrahman Aldossary, Thomas Swanick, Marcel Müller, Yeonghun Kang, Changhyeok Choi, Naruki Yoshikawa, Zijian Zhang, Jin Won Lee, Tsz Wai Ko, Aiwei Yin, Mohammad Ghazi Vakili, Chris Crebolder, Varinia Bernales, and Alán Aspuru-Guzik. El Agente Gráfico: A Semantic Execution Runtime for Scientific Agents, 2026. URL `https://arxiv.org/abs/2602.17902v2`. Version 2, 7 August 2026.

[6] Changhyeok Choi, Yunheng Zou, Marcel Müller, Han Hao, Yeonghun Kang, Juan B. Pérez-Sánchez, Ignacio Gustin, Hanyong Xu, Andrew Wang, Mohammad Ghazi Vakili, Chris Crebolder, Alán Aspuru-Guzik, and Varinia Bernales. El Agente Estructural: An Artificially Intelligent Molecular Editor, 2026. URL `https://arxiv.org/abs/2602.04849`.

[7] Dong Li, Sixuan Mi, Zihao Ye, Huan Xiong, Tao Xu, Tong Zhu, Aijia Zhang, Junqi Gao, Kaiyan Zhang, Shijie Wang, Bowen Zhou, Yuqiang Li, and Biqing Qi. Autonomous Chemical Mechanistic Discovery through Agentic Reasoning and Validation, 2026. URL `https://arxiv.org/abs/2609.11147`.

[8] Juan B. Pérez-Sánchez, Yunheng Zou, Jorge A. Campos-Gonzalez-Angulo, Marcel Müller, Ignacio Gustin, Andrew Wang, Han Hao, Tsz Wai Ko, Changhyeok Choi, Eric S. Isbrandt, Mohammad Ghazi Vakili, Hanyong Xu, Chris Crebolder, Varinia Bernales, and Alán Aspuru-Guzik. El Agente Quntur: A research collaborator agent for quantum chemistry. *Chem*, page 103259, 2026. doi: 10.1016/j.chempr.2026.103259. URL `https://doi.org/10.1016/j.chempr.2026.103259`.

[9] S. Riniker and G. A. Landrum. Better Informed Distance Geometry: Using What We Know To Improve Conformation Generation. *Journal of Chemical Information and Modeling*, 55:2562–2574, 2015. doi: 10.1021/acs.jcim.5b00654.

[10] Shuzhe Wang, Jagna Witek, Gregory A. Landrum, and Sereina Riniker. Improving conformer generation for small rings and macrocycles based on distance geometry and experimental torsional-angle preferences. *Journal of Chemical Information and Modeling*, 60(4):2044–2058, 2020. doi: 10.1021/acs.jcim.0c00025.

[11] RDKit. Getting Started in Python: Conformer Generation and Maximum Common Substructure, 2026. URL `https://www.rdkit.org/docs/GettingStartedInPython.html`. Online documentation; accessed 31 October 2026.

[12] Thomas A. Halgren. Merck molecular force field. I. basis, form, scope, parameterization, and performance of MMFF94. *Journal of Computational Chemistry*, 17(5–6):490–519, 1996. doi: 10.1002/(SICI)1096-987X(199604)17:5/6<490::AID-JCC1>3.0.CO;2-P.

[13] W. Kabsch. A discussion of the solution for the best rotation to relate two sets of vectors. *Acta Crystallographica Section A*, 34:827–828, 1978. doi: 10.1107/S0567739478001680.

[14] Søren Smidstrup, Andreas Pedersen, Kurt Stokbro, and Hannes Jónsson. Improved initial guess for minimum energy path calculations. *The Journal of Chemical Physics*, 140(21):214106, 2014. doi: 10.1063/1.4878664.

[15] Graeme Henkelman and Hannes Jónsson. Improved tangent estimate in the nudged elastic band method for finding minimum energy paths and saddle points. *The Journal of Chemical Physics*, 113(22):9978–9985, 2000. doi: 10.1063/1.1323224.

[16] Ask Hjorth Larsen, Jens Jørgen Mortensen, Jakob Blomqvist, Ivano E. Castelli, Rune Christensen, Marcin Dułak, Jesper Friis, Michael N. Groves, Bjørk Hammer, Cory Hargus, et al. The atomic simulation environment—a Python library for working with atoms. *Journal of Physics: Condensed Matter*, 29(27):273002, 2017. doi: 10.1088/1361-648X/aa680e.

[17] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations*, 2015. URL `https://arxiv.org/abs/1412.6980`.

[18] Cloudra. Cloudra source code, 2026. URL `https://github.com/yyywaa/Cloudra-mechanism-agent/tree/70daa5a`. Revision 70daa5a, 26 October 2026.

[19] Charles R. Harris, K. Jarrod Millman, Stéfan J. van der Walt, Ralf Gommers, Pauli Virtanen, David Cournapeau, Eric Wieser, Julian Taylor, Sebastian Berg, Nathaniel J. Smith, Robert Kern, Matti Picus, Stephan Hoyer, Marten H. van Kerkwijk, Matthew Brett, Allan Haldane, Jaime Fernández del Río, Mark Wiebe, Pearu Peterson, Pierre Gérard-Marchant, Kevin Sheppard, Tyler Reddy, Warren Weckesser, Hameer Abbasi, Christoph Gohlke, and Travis E. Oliphant. Array programming with NumPy. *Nature*, 585(7825):357–362, 2020. doi: 10.1038/s41586-020-2649-2.

[20] Noel M. O'Boyle, Adam L. Tenderholt, and Karol M. Langner. cclib: A library for package-independent computational chemistry

algorithms. *Journal of Computational Chemistry*, 29(5):839–845, 2008. doi: 10.1002/jcc.20823.

[21] Aric A. Hagberg, Daniel A. Schult, and Pieter J. Swart. Exploring network structure, dynamics, and function using NetworkX. In Gaël Varoquaux, Travis Vaught, and Jarrod Millman, editors, *Proceedings of the 7th Python in Science Conference*, pages 11–15, Pasadena, CA, 2008. URL https://aric.hagberg.org/papers/hagberg-2008-exploring.pdf.

[22] Jianlyu Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. M3-Embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 2318–2335, 2024. doi: 10.18653/v1/2024.findings-acl.137. URL https://aclanthology.org/2024.findings-acl.137/.

[23] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011. URL https://jmlr.org/papers/v12/pedregosa11a.html.

[24] Philipp Pracht, Fabian Bohle, and Stefan Grimme. Automated exploration of the low-energy chemical space with fast quantum chemical methods. *Physical Chemistry Chemical Physics*, 22(14):7169–7192, 2020. doi: 10.1039/C9CP06869D.

[25] Christoph Bannwarth, Sebastian Ehlert, and Stefan Grimme. GFN2-xTB—an accurate and broadly parametrized self-consistent tight-binding quantum chemical method with multipole electrostatics and density-dependent dispersion contributions. *Journal of Chemical Theory and Computation*, 15(3):1652–1671, 2019. doi: 10.1021/acs.jctc.8b01176.

[26] James J. P. Stewart. Optimization of parameters for semiempirical methods VI: more modifications to the NDDO approximations and re-optimization of parameters. *Journal of Molecular Modeling*, 19(1):1–32, 2013. doi: 10.1007/s00894-012-1667-x.

[27] Axel D. Becke. Density-functional thermochemistry. III. the role of exact exchange. *The Journal of Chemical Physics*, 98(7):5648–5652, 1993. doi: 10.1063/1.464913.

[28] Chengteh Lee, Weitao Yang, and Robert G. Parr. Development of the Colle–Salvetti correlation-energy formula into a functional of the electron density. *Physical Review B*, 37(2):785–789, 1988. doi: 10.1103/PhysRevB.37.785.

[29] P. J. Stephens, F. J. Devlin, C. F. Chabalowski, and M. J. Frisch. Ab initio calculation of vibrational absorption and circular dichroism spectra using density functional force fields. *The Journal of Physical Chemistry*, 98(45):11623–11627, 1994. doi: 10.1021/j100096a001.

[30] Stefan Grimme, Jens Antony, Stephan Ehrlich, and Helge Krieg. A consistent and accurate ab initio parametrization of density functional dispersion correction (DFT-D) for the 94 elements H–Pu. *The Journal of Chemical Physics*, 132(15):154104, 2010. doi: 10.1063/1.3382344.

[31] Stefan Grimme, Stephan Ehrlich, and Lars Goerigk. Effect of the damping function in dispersion corrected density functional theory. *Journal of Computational Chemistry*, 32(7):1456–1465, 2011. doi: 10.1002/jcc.21759.

[32] Florian Weigend and Reinhart Ahlrichs. Balanced basis sets of split valence, triple zeta valence and quadruple zeta valence quality for H to Rn: Design and assessment of accuracy. *Physical Chemistry Chemical Physics*, 7:3297–3305, 2005. doi: 10.1039/B508541A.

[33] Frank Neese. Software update: The ORCA program system—version 6.0. *WIREs Computational Molecular Science*, 15(2):e70019, 2025. doi: 10.1002/wcms.70019.

[34] M. J. Frisch, G. W. Trucks, H. B. Schlegel, G. E. Scuseria, M. A. Robb, J. R. Cheeseman, G. Scalmani, V. Barone, G. A. Petersson, H. Nakatsuji, et al. Gaussian 16. Gaussian, Inc., Wallingford, CT, 2016. URL https://gaussian.com/citation/.

[35] Jonathan E. Moussa and James J. P. Stewart. MOPAC: An open-source semiempirical molecular orbital program. *Journal of Open Source Software*, 11(119):8025, 2026. doi: 10.21105/joss.08025.

[36] FACCTs. ORCA 6.1 Manual, 2025. URL https://www.faccts.de/docs/orca/6.1/manual/. Online documentation; accessed 31 October 2026.

[37] DeepSeek-AI. DeepSeek V4 Model Card, 2026. URL https://fe-static.deepseek.com/chat/transparency/deepseek-V4-model-card-EN.pdf.

[38] Luyu Gao, Aman Madaan, Shuyan Zhou, Uri Alon, Pengfei Liu, Yiming Yang, Jamie Callan, and Graham Neubig. PAL: Program-aided language models. In *Proceedings of the 40th International Conference on Machine Learning*, volume 202, pages 10764–10799, 2023. URL https://proceedings.mlr.press/v202/gao23f.html.

[39] Fred Zhang and Neel Nanda. Towards Best Practices of Activation Patching in Language Models: Metrics and Methods. In *International Conference on Learning Representations*, 2024. URL https://proceedings.iclr.cc/paper_files/paper/2024/hash/06a52a54c8ee03cd86771136bc91eb1f-Abstract-Conference.html.

[40] Bahar Fatemi, Bryan Perozzi, and Jonathan Halcrow. Talk like a Graph: Encoding Graphs for Large Language Models. In *International Conference on Learning Representations*, 2024. URL https://research.google/pubs/talk-like-a-graph-encoding-graphs-for-large-language-models/.

[41] Zhibin Gou, Zhihong Shao, Yeyun Gong, Yelong Shen, Yujiu Yang, Nan Duan, and Weizhu Chen. CRITIC: Large language models can self-correct with tool-interactive critiquing. In *International Conference on Learning Representations*, 2024. URL https://arxiv.org/abs/2305.11738.

[42] Karthik Valmeekam, Matthew Marquez, Sarath Sreedharan, and Subbarao Kambhampati. On the planning abilities of large language models: A critical investigation. In *Advances in Neural Information Processing Systems*, 2023. URL https://arxiv.org/abs/2305.15771.

[43] Jie Huang, Xinyun Chen, Swaroop Mishra, Huaixiu Steven Zheng, Adams Wei Yu, Xinying Song, and Denny Zhou. Large language models cannot self-correct reasoning yet. In *International Conference on Learning Representations*, 2024. URL https://arxiv.org/abs/2310.01798.

[44] Miles Turpin, Julian Michael, Ethan Perez, and Samuel R. Bowman. Language models don't always say what they think: Unfaithful explanations in chain-of-thought prompting. In *Advances in Neural Information Processing Systems*, 2023. URL https://arxiv.org/abs/2305.04388.